Statistiques descriptives univariées

Dr Houda Boukheris

Faculté de Médecine de Béjaia

Les statistiques descriptives permettent une **première exploration** des données.

Elles sont basées sur **des graphiques et des calculs simples**.

Elles permettent d'avoir un premier aperçu des données qui peut montrer des tendances.

Elles permettent aussi de bien **caractériser les données**, ce qui est nécessaire pour choisir ensuite la manière de les analyser.

On commence par décrire les variables une par une (**statistiques univariées**) puis on peut explorer comment varie une variable en fonction d'une autre (**statistiques bivariées**).

1- Les distributions de fréquences

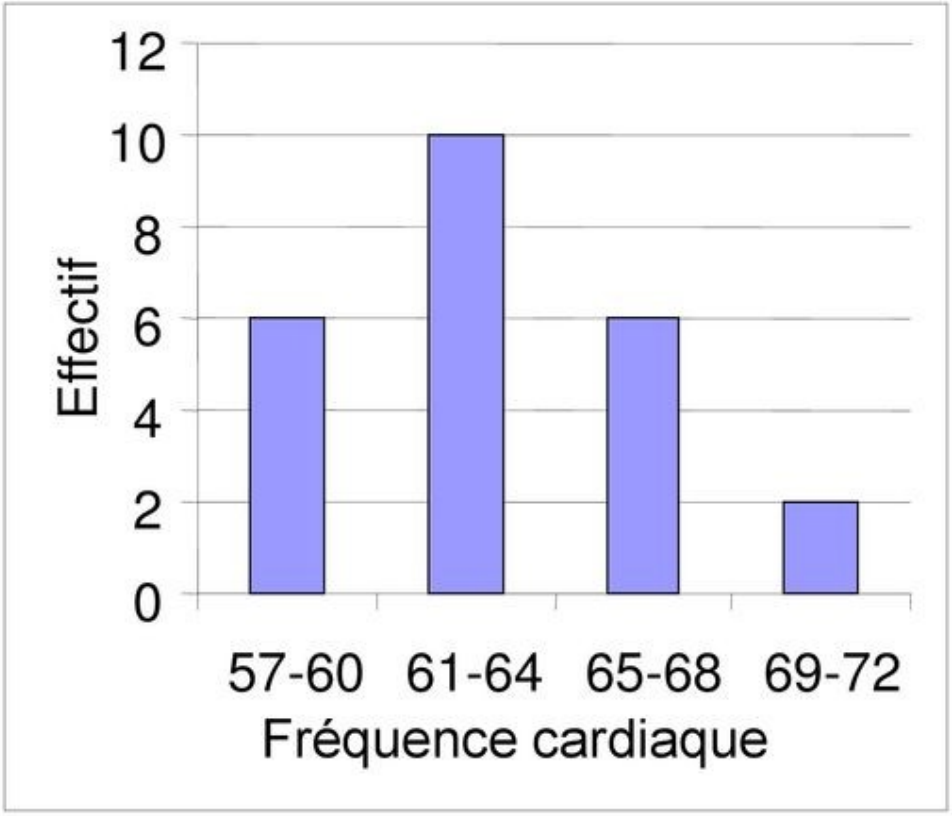
Pour une variable numérique, on définit des **intervalles de valeurs** (tous de même largeur) couvrant toute l'étendue des données et on compte le **nombre de données dans chaque intervalle.**

Ex : fréquences cardiaques : 64 ; 67 ; 72 ; 58 ; 60 ; 65 ; 64 ; 57 ; 72 ; 66 ; 65; 59; 66; 63 ; 62 ; 64 ; 62 ; 66 ; 60 ; 61 ; 59 ; 62 ; 64 ; 61

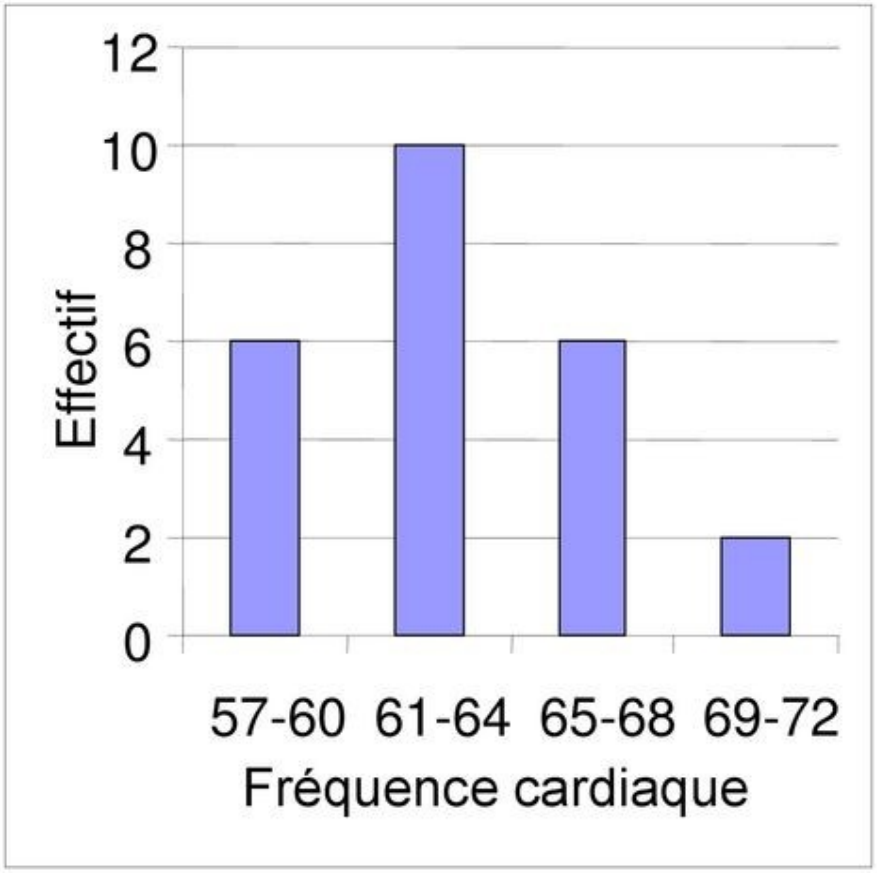
Fréquence cardiaque (pulsations/min)	Effectif ou fréquence
57-60	6
61-64	10
65-68	6
69-72	2

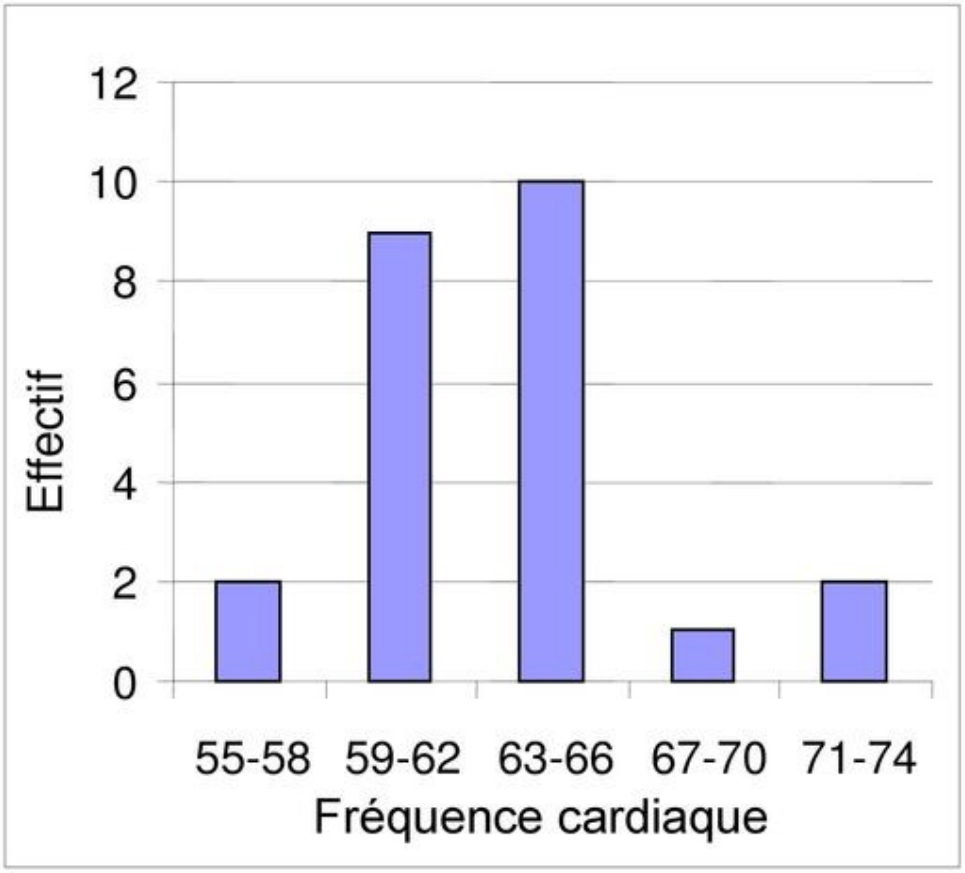
On trace **l'histogramme de la distribution des fréquences**.

Fréquence cardiaque (pulsations/min)	Effectif ou fréquence
57-60	6
61-64	10
65-68	6
69-72	2



On peut faire varier le point d'origine et la largeur des intervalles.

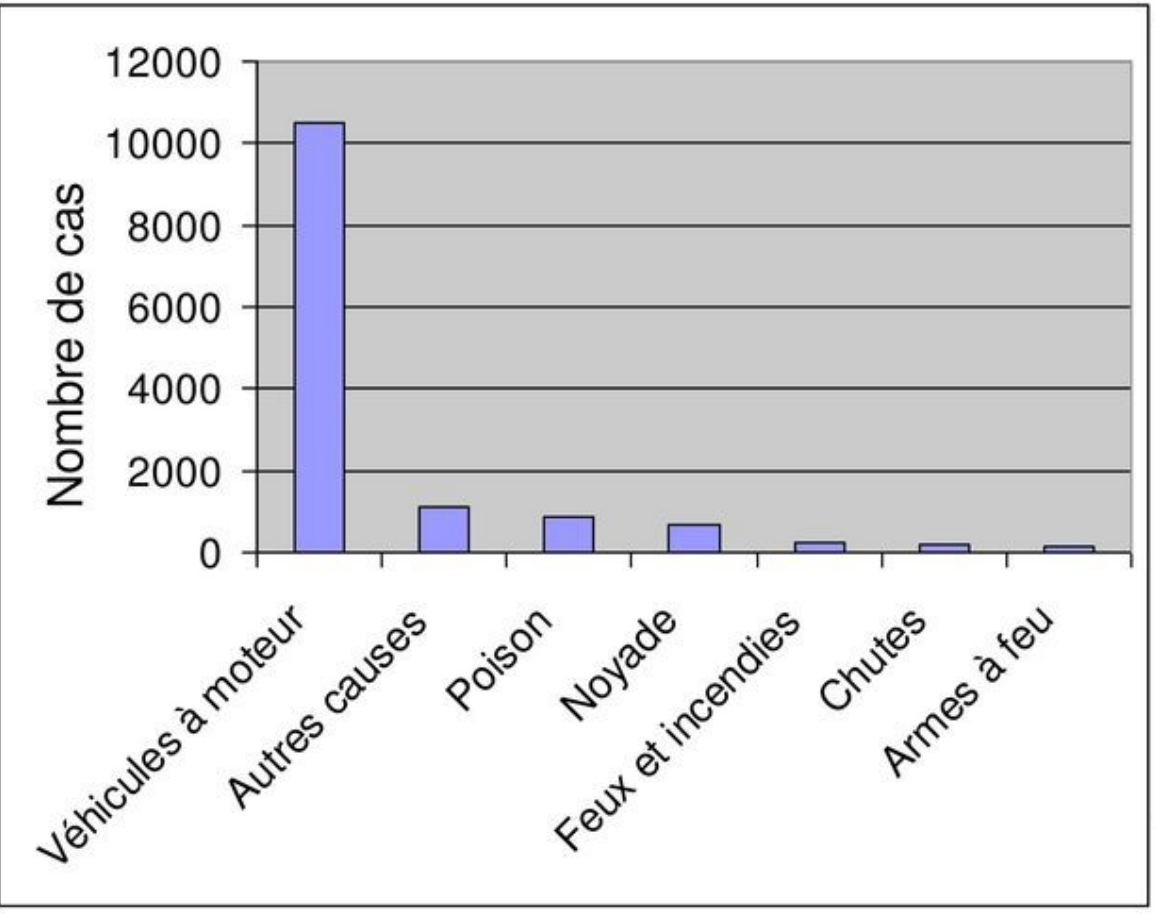




Règle de Moore : nombre d'intervalles environ égal à la racine carrée de l'effectif total

On peut aussi réaliser ce type de graphique pour des **données qualitatives**.

Causes de mort accidentelle chez les résidents américains de 15 à 24 ans :

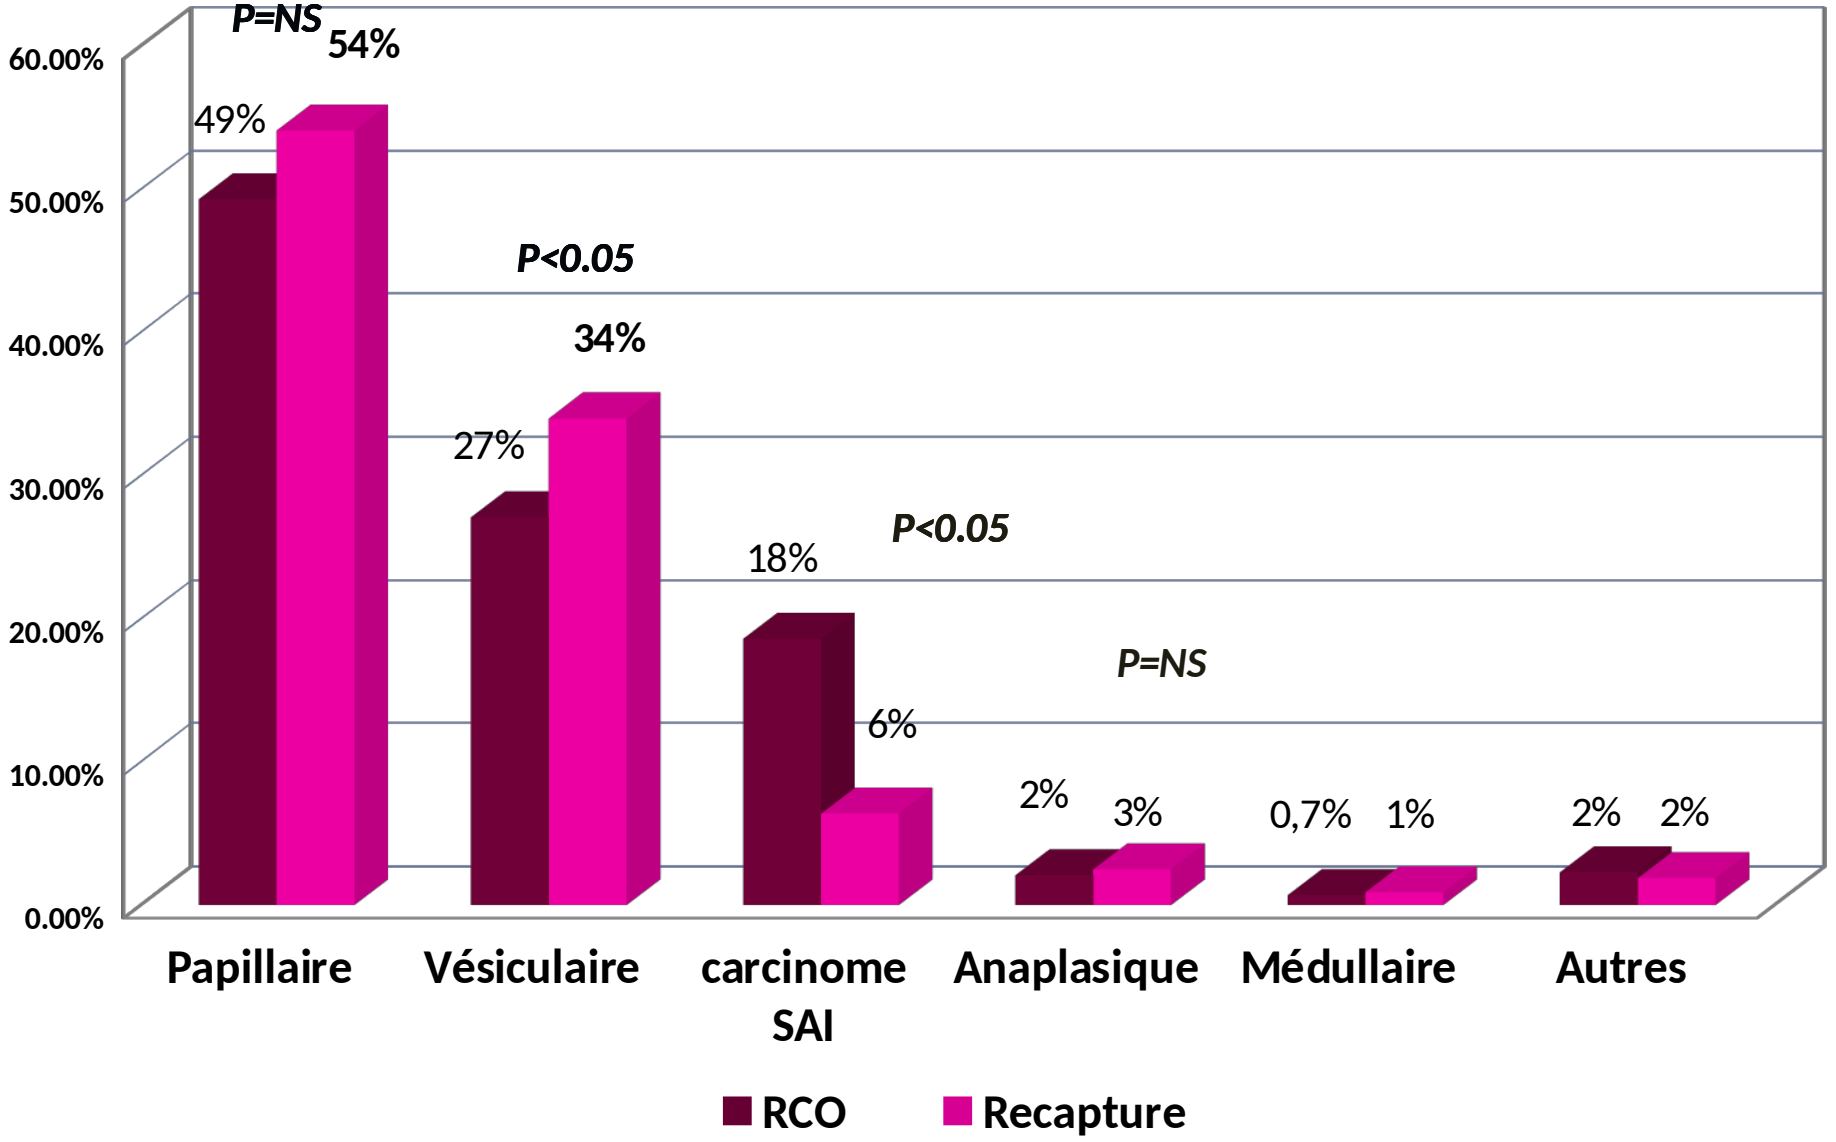


Cause de la mort	Nombre de cas
Véhicules à moteur	10500
Autres causes	1130
Poison	870
Noyade	700
Feux et incendies	240
Chutes	210
Armes à feu	150

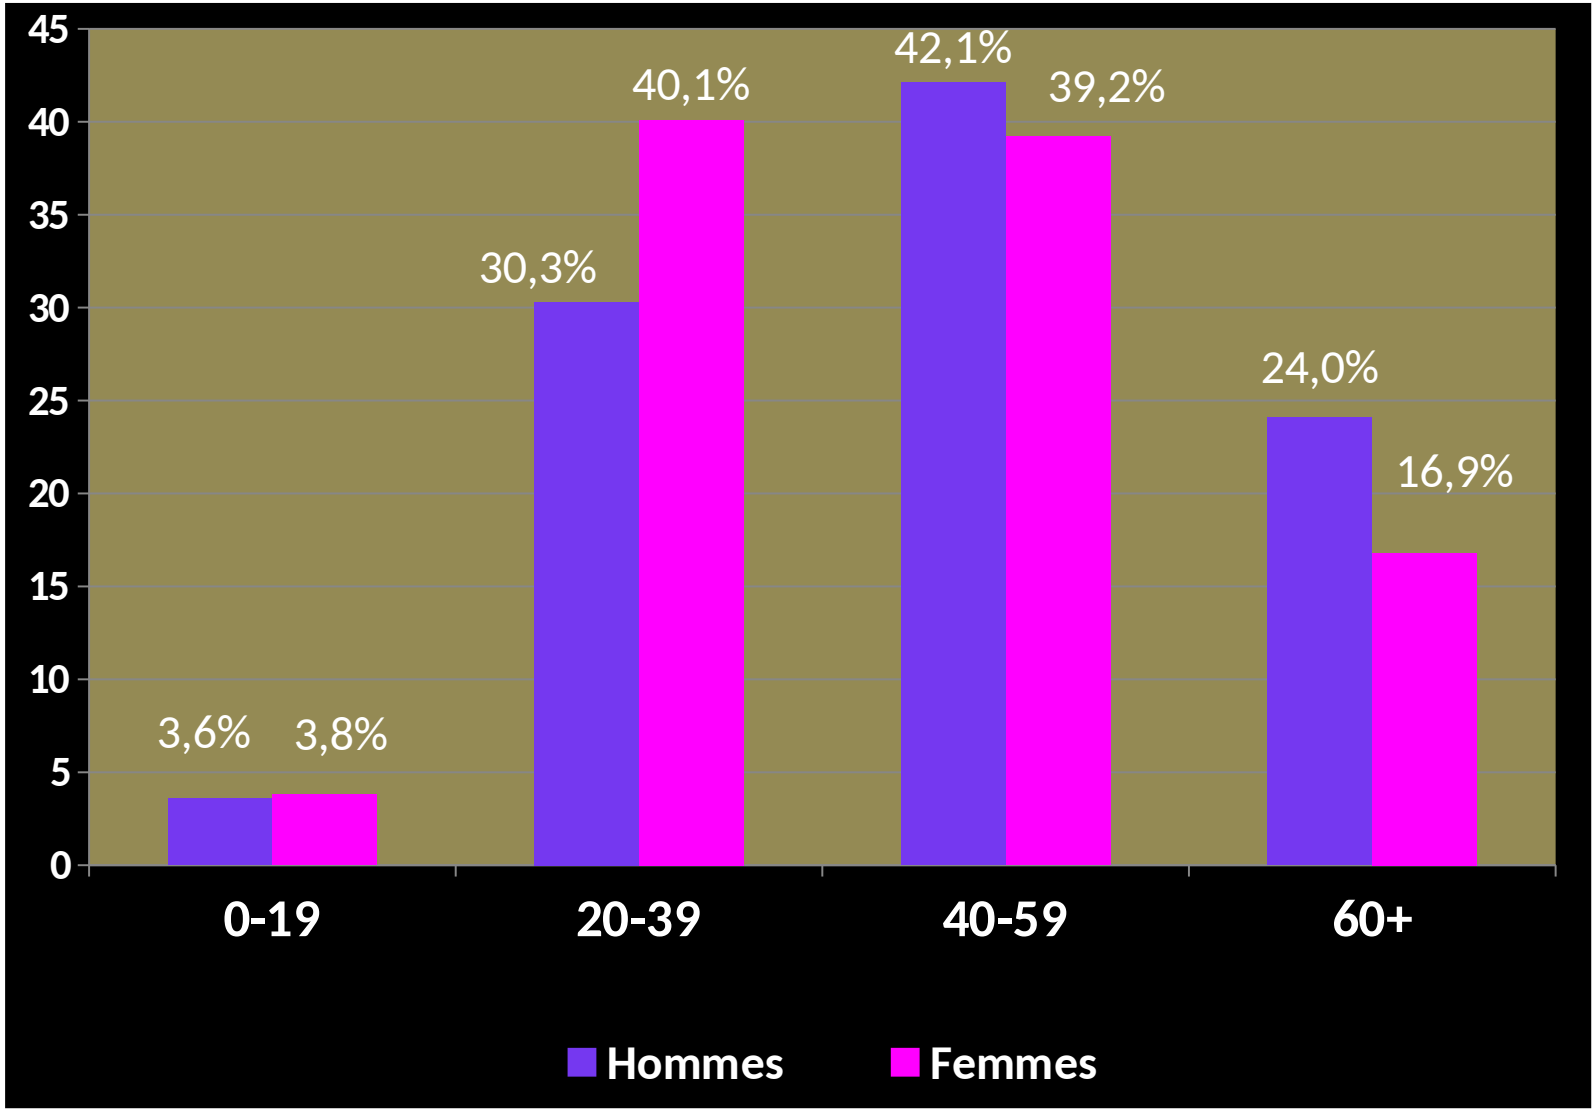
Diagramme en barres

Caractéristiques morphologiques

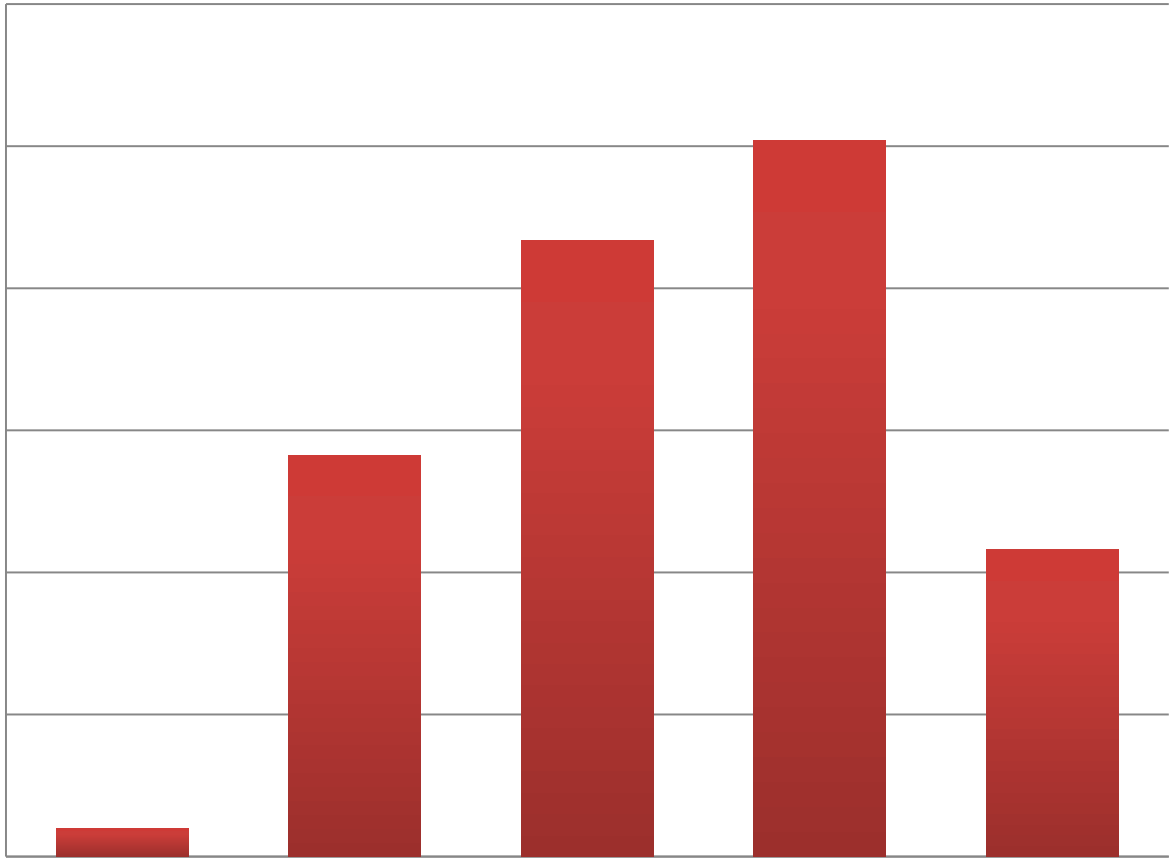
RCO *versus* Recapture



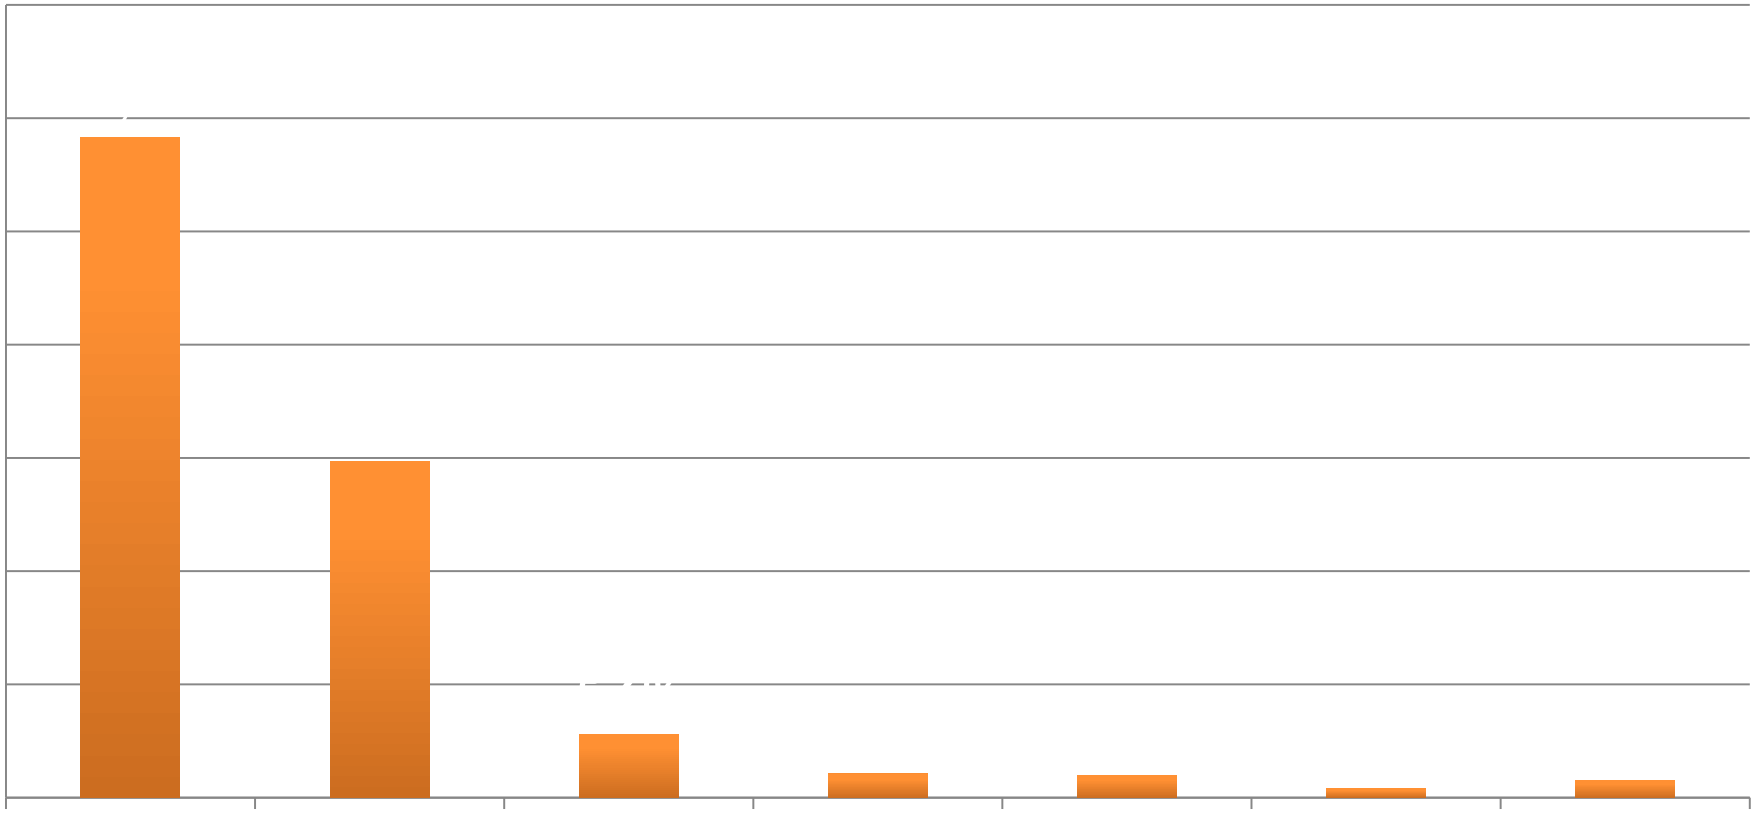
Distribution Selon le Sexe et l'Age



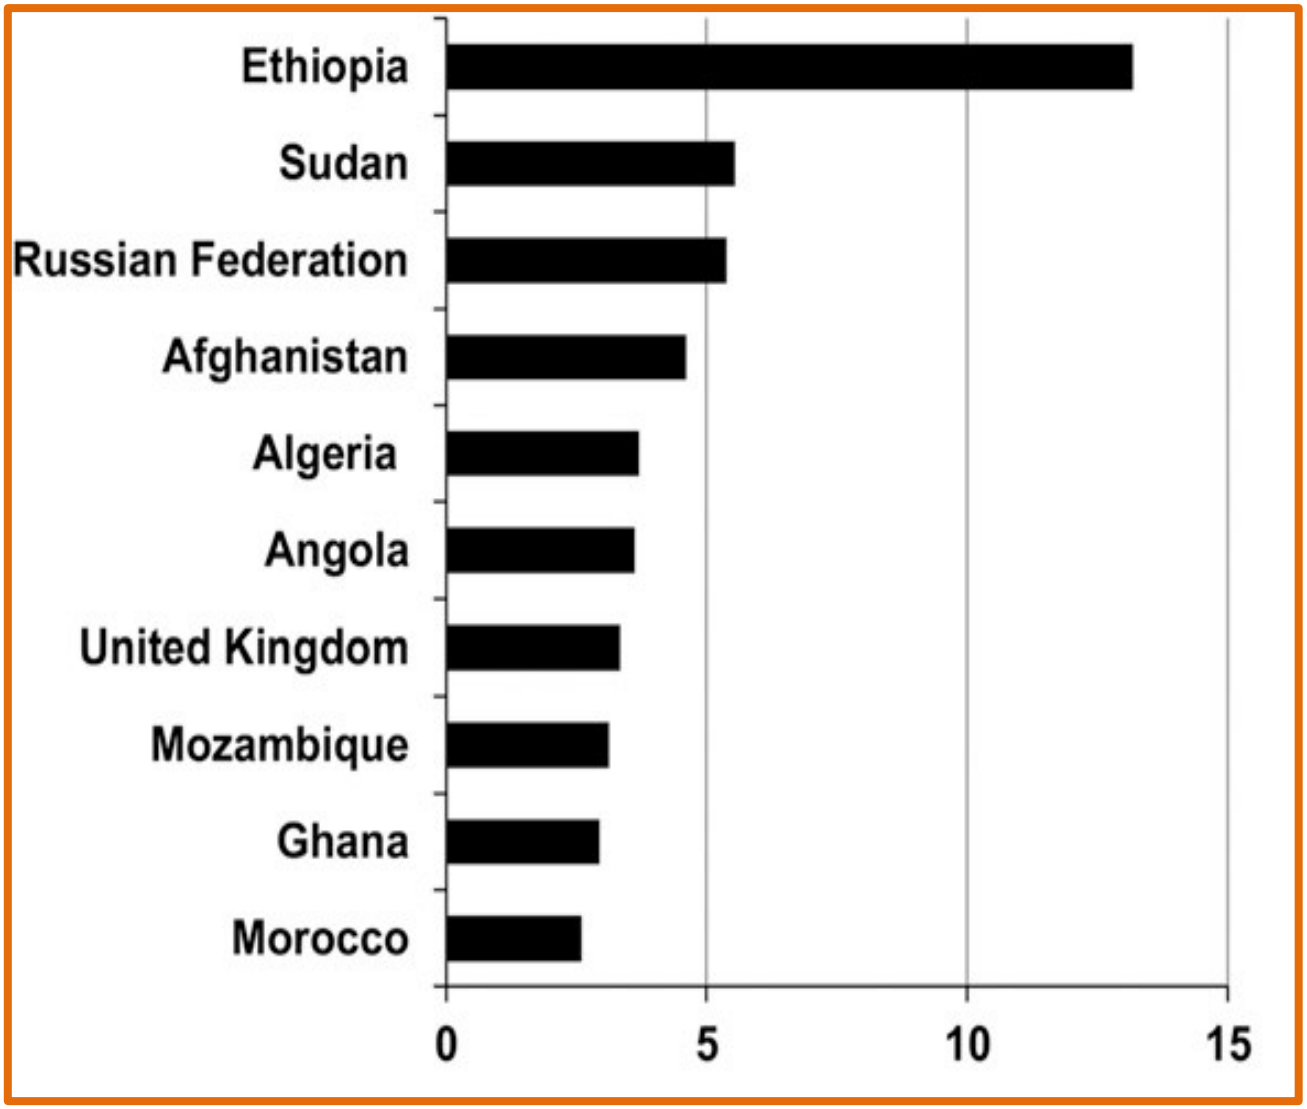
Distribution des tumeurs selon la Taille



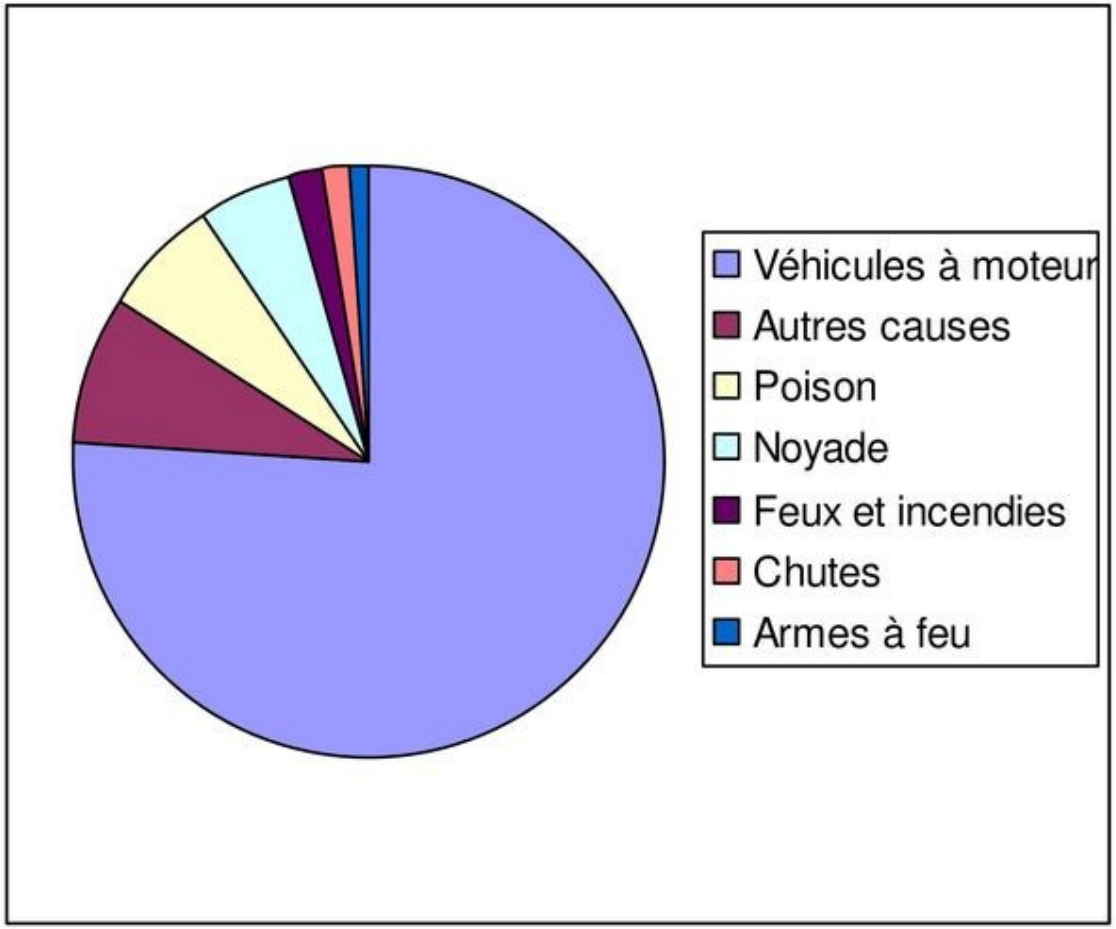
Distribution selon le type Histopathologique



Pays avec le Nombre d'Enfants à Faible Consommation d'Iode, 2011



Causes de mort accidentelle chez les résidents américains de 15 à 24 ans :

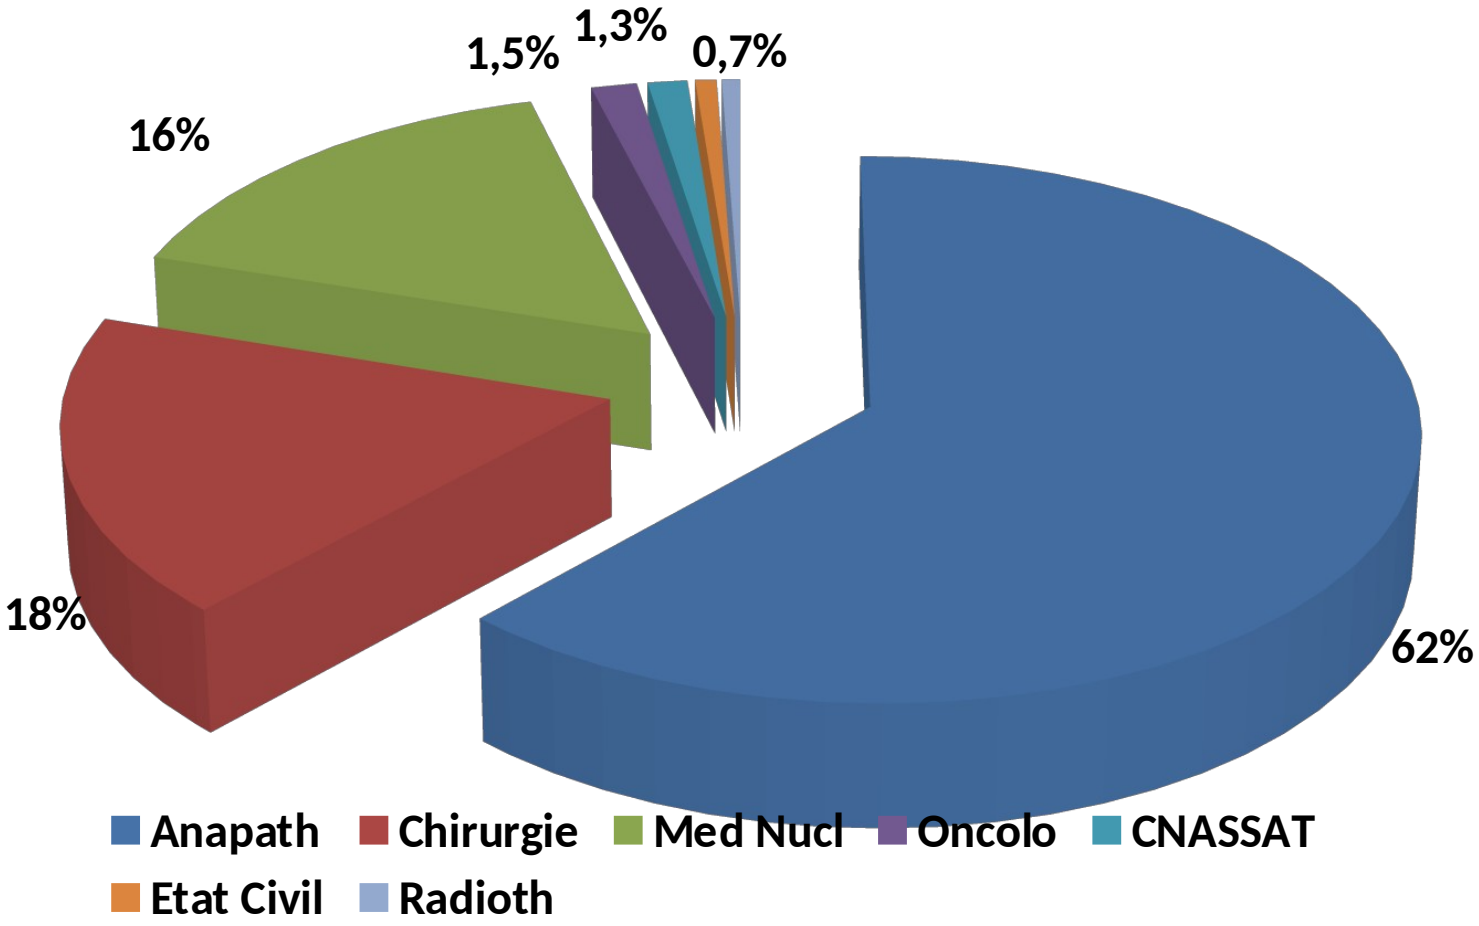


Cause de la mort	Nombre de cas
Véhicules à moteur	10500
Autres causes	1130
Poison	870
Noyade	700
Feux et incendies	240
Chutes	210
Armes à feu	150

Diagramme circulaire

Sources d'information - cancers

Registre du Cancer d'Oran



Pour les variables numériques, l'histogramme montre la distribution des données.

On peut caractériser en particulier :

Le centre : valeur moyenne, valeur médiane

La dispersion : comment les valeurs s'écartent du centre (étendue, variance, écart-type)

La symétrie : répartition des données de part et d'autre du centre

Les points extrêmes : valeurs beaucoup plus faibles ou plus fortes que les autres

- 2- Le centre

  - La **moyenne** arithmétique : somme des valeurs divisée par le nombre total de valeurs

$$\overline{X} = \frac{X_1 + X_2 + \ldots + X_n}{n}$$

La moyenne représente bien le centre des données quand la distribution est symétrique.

Elle est en revanche sensible aux valeurs extrêmes.

- La **médiane** : c'est la valeur centrale quand les données sont triées par ordre croissant (ou décroissant)

Quand le nombre de données est pair, la médiane prend la valeur de la moyenne des 2 valeurs centrales

Exemple 1 :

Données dans l'ordre croissant : 2.05 ; 3.56 ; **4.67** ; 6.90 ; 7.53

Médiane : 4.67

Exemple 2 :

Données dans l'ordre croissant : 2.05 ; 3.56 ; **4.67** ; **6.90** ; 7.53 ; 8.75

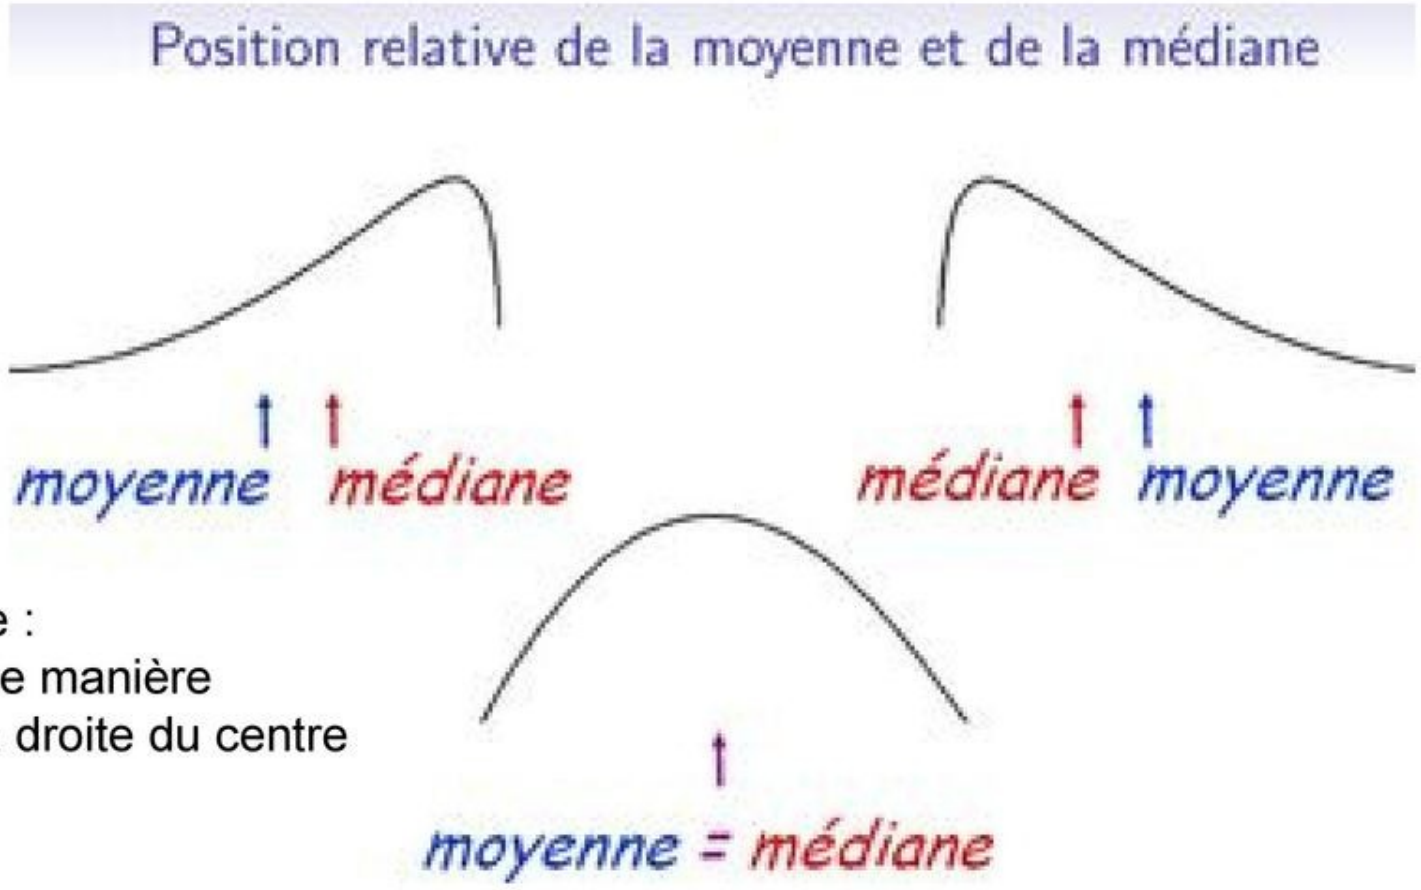
Médiane : (4.67+6.90) /2 = 5.785

La moitié des données a une valeur supérieure à la médiane, l'autre moitié a une valeur inférieure.

Aucune influence des valeurs extrêmes sur la valeur de la médiane
=> paramètre plus robuste que la moyenne.

Moyenne, médiane et symétrie

Distributions asymétriques



Distribution symétrique :
Données dispersées de manière similaire à gauche et à droite du centre

- 3- La dispersion

  - L'étendue : différence entre la valeur maximale et la valeur minimale

  Contrairement aux autres paramètres de dispersion, elle ne prend pas en compte l'ensemble des valeurs.

L'écart type

Il dépend de la déviation des valeurs par rapport à la moyenne ($x-\bar{x}$) et de l'effectif n de l'échantillon.

Sans biais :

$$S = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}}$$

Avec biais :

$$\sigma = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n}}$$

- La variance : écart type au carré

Sans biais :

$$S^2 = \frac{\sum (x_i - \bar{x})^2}{n-1}$$

Avec biais :

$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{n}$$

On utilise généralement plus l'écart type que la variance.

L'écart type a la même unité que les données.

Interprétation de l'écart type :

En général, la grande majorité des données est à moins de 2 écarts types de la moyenne (entre $\overline{x} - 2s$ et $\overline{x} + 2s$)

On utilise généralement plus l'écart type que la variance.

L'écart type a la même unité que les données.

Interprétation de l'écart type :

En général, la grande majorité des données est à moins de 2 écarts types de la moyenne (entre $\overline{x} - 2s$ et $\overline{x} + 2s$)

- Autres paramètres liés à la dispersion : les quartiles

Comme la médiane sépare les données triées par la moitié, les quartiles séparent les données triées en 4 parties égales.

Q1 (premier quartile) : sépare les premiers 25% des données triées des 75% restants (aussi : Q1 = médiane des données inférieures à la médiane)

Q2 (deuxième quartile) : sépare les premiers 50% des données triées des 50% restants => Q2 = médiane

Q3 (troisième quartile) : sépare les premiers 75% des données triées des 25% restants (aussi : Q3 = médiane des données supérieures à la médiane)

Exemple de calcul des quartiles :

Masses d'ours en kg :

156.0 ; 157.9 ; 99.8 ; 118.8 ; 163.3 ; 92.5 ; 150.6 ; 81.6 ; 92.5 ; 110.3 ; 130.7

Données triées :

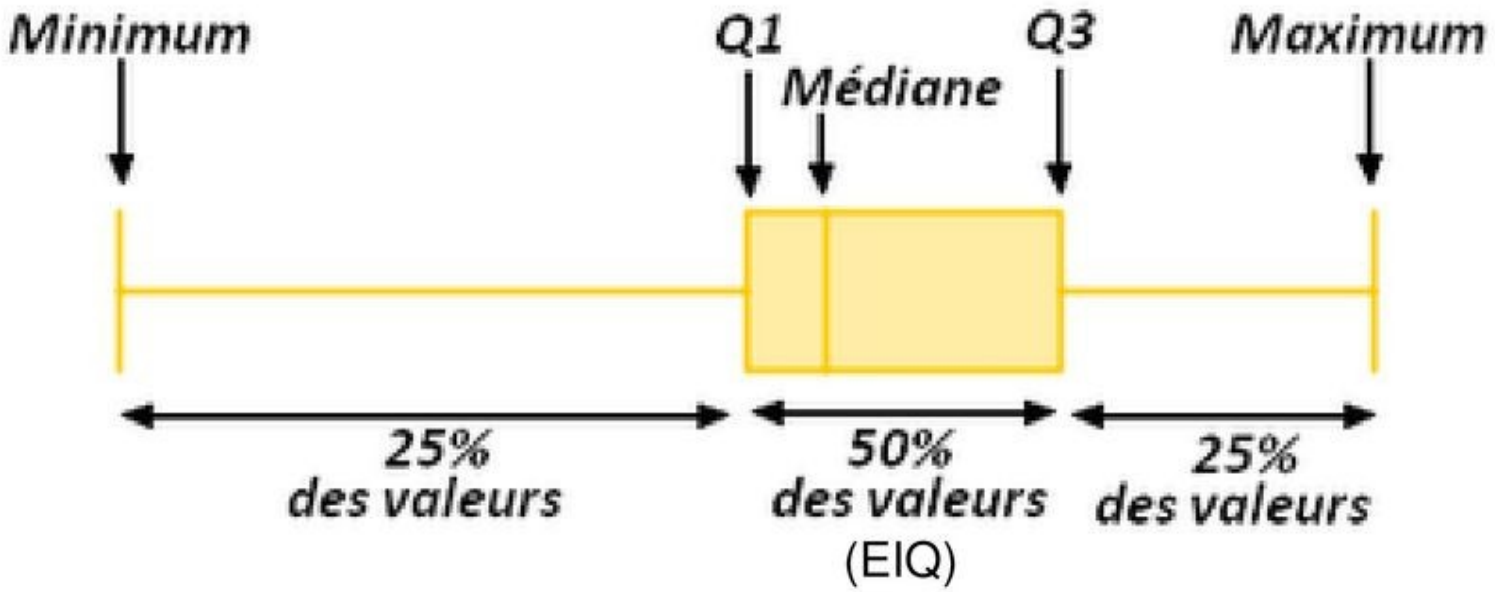
81.6 ; 92.5 ; 92.5 ; 99.8 ; 110.3 ; 118.8 ; 130.7 ; 150.6 ; 156.0 ; 157.9 ; 163.3

Q1 Médiane = Q2 Q3

Etendue inter-quartiles : EIQ = Q3 –Q1

Elle exprime la dispersion de la portion centrale des données

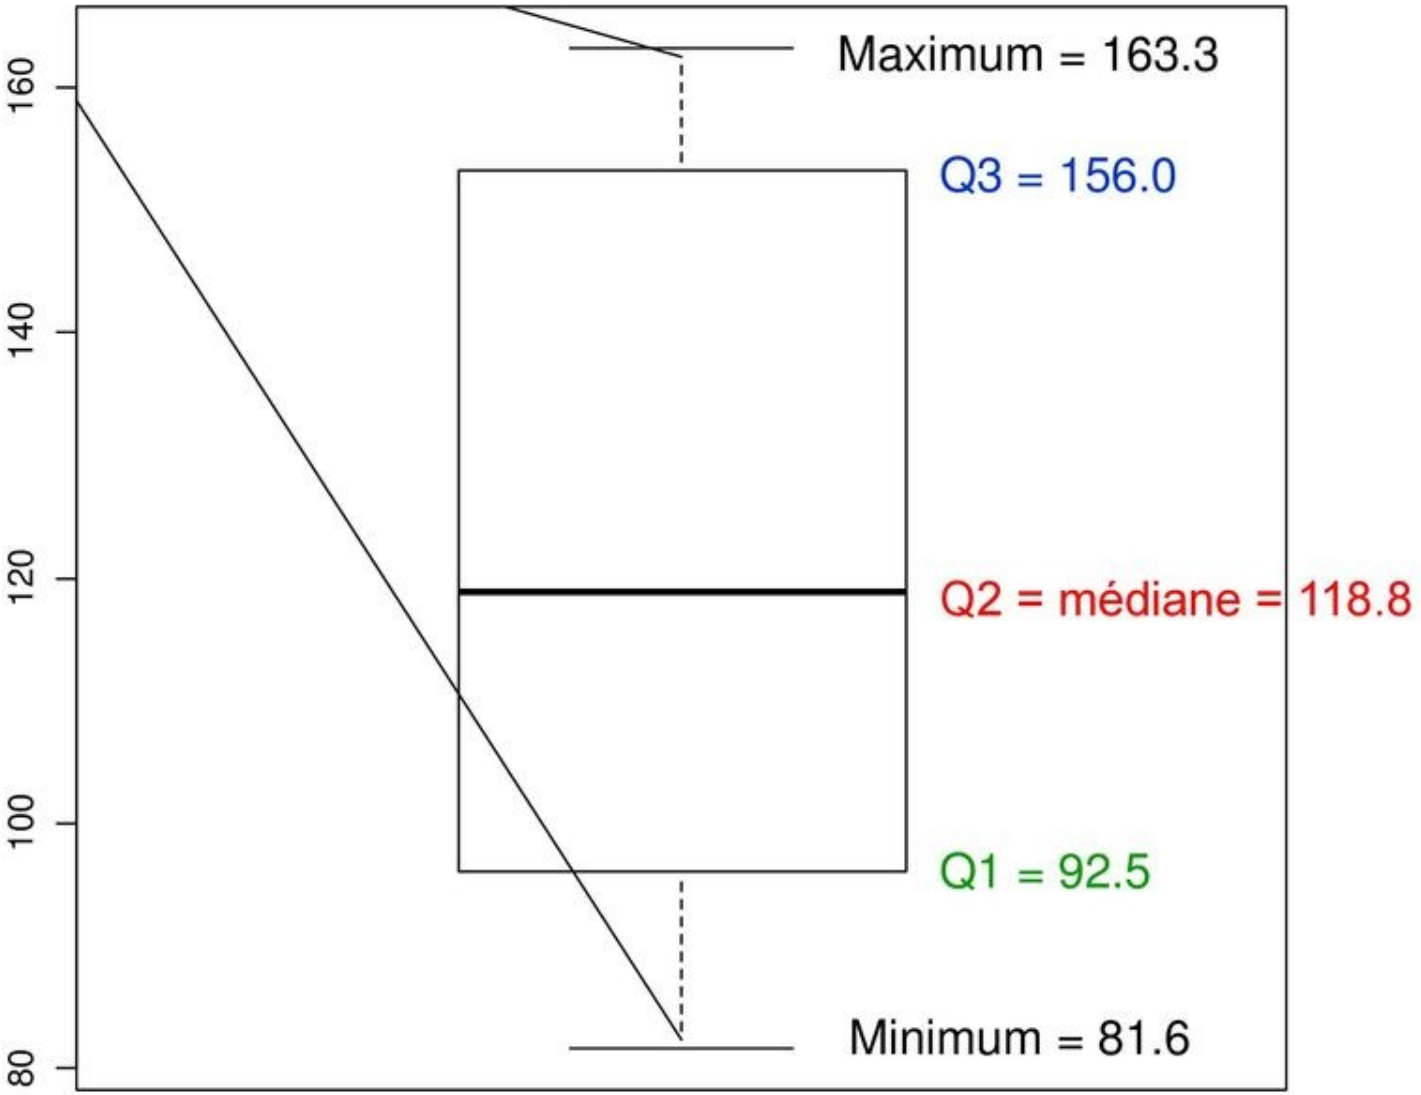
4- Graphique de synthèse : boîte à moustaches



Boîte délimitée par Q1 et Q3.

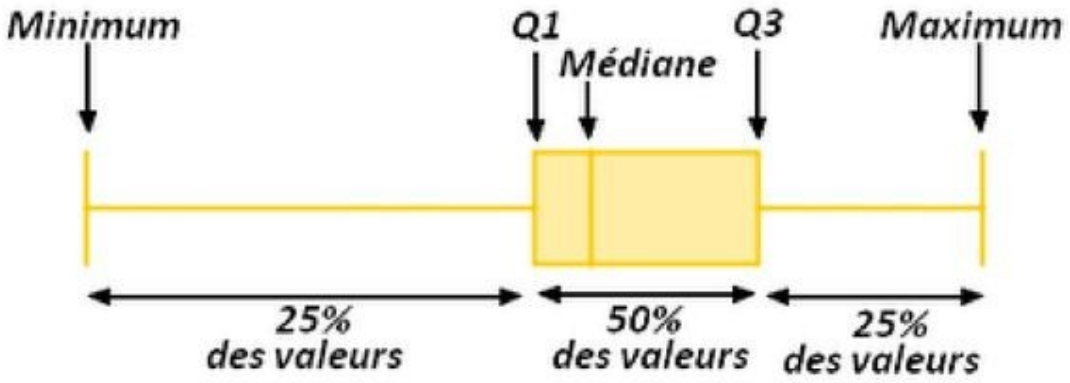
Moustaches délimitées par le minimum et le maximum

=> Donne une vue d'ensemble de la répartition des données

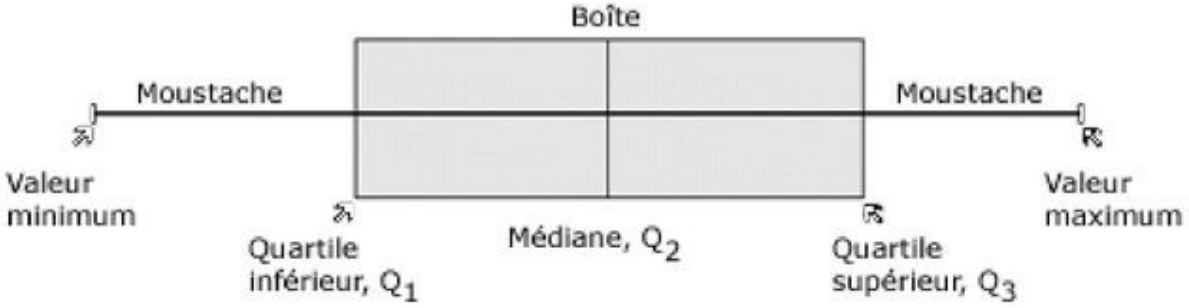


Boîte à moustaches de la masse des ours (kg)

Les boîtes à moustaches montrent bien si la distribution est symétrique ou non



Distribution asymétrique

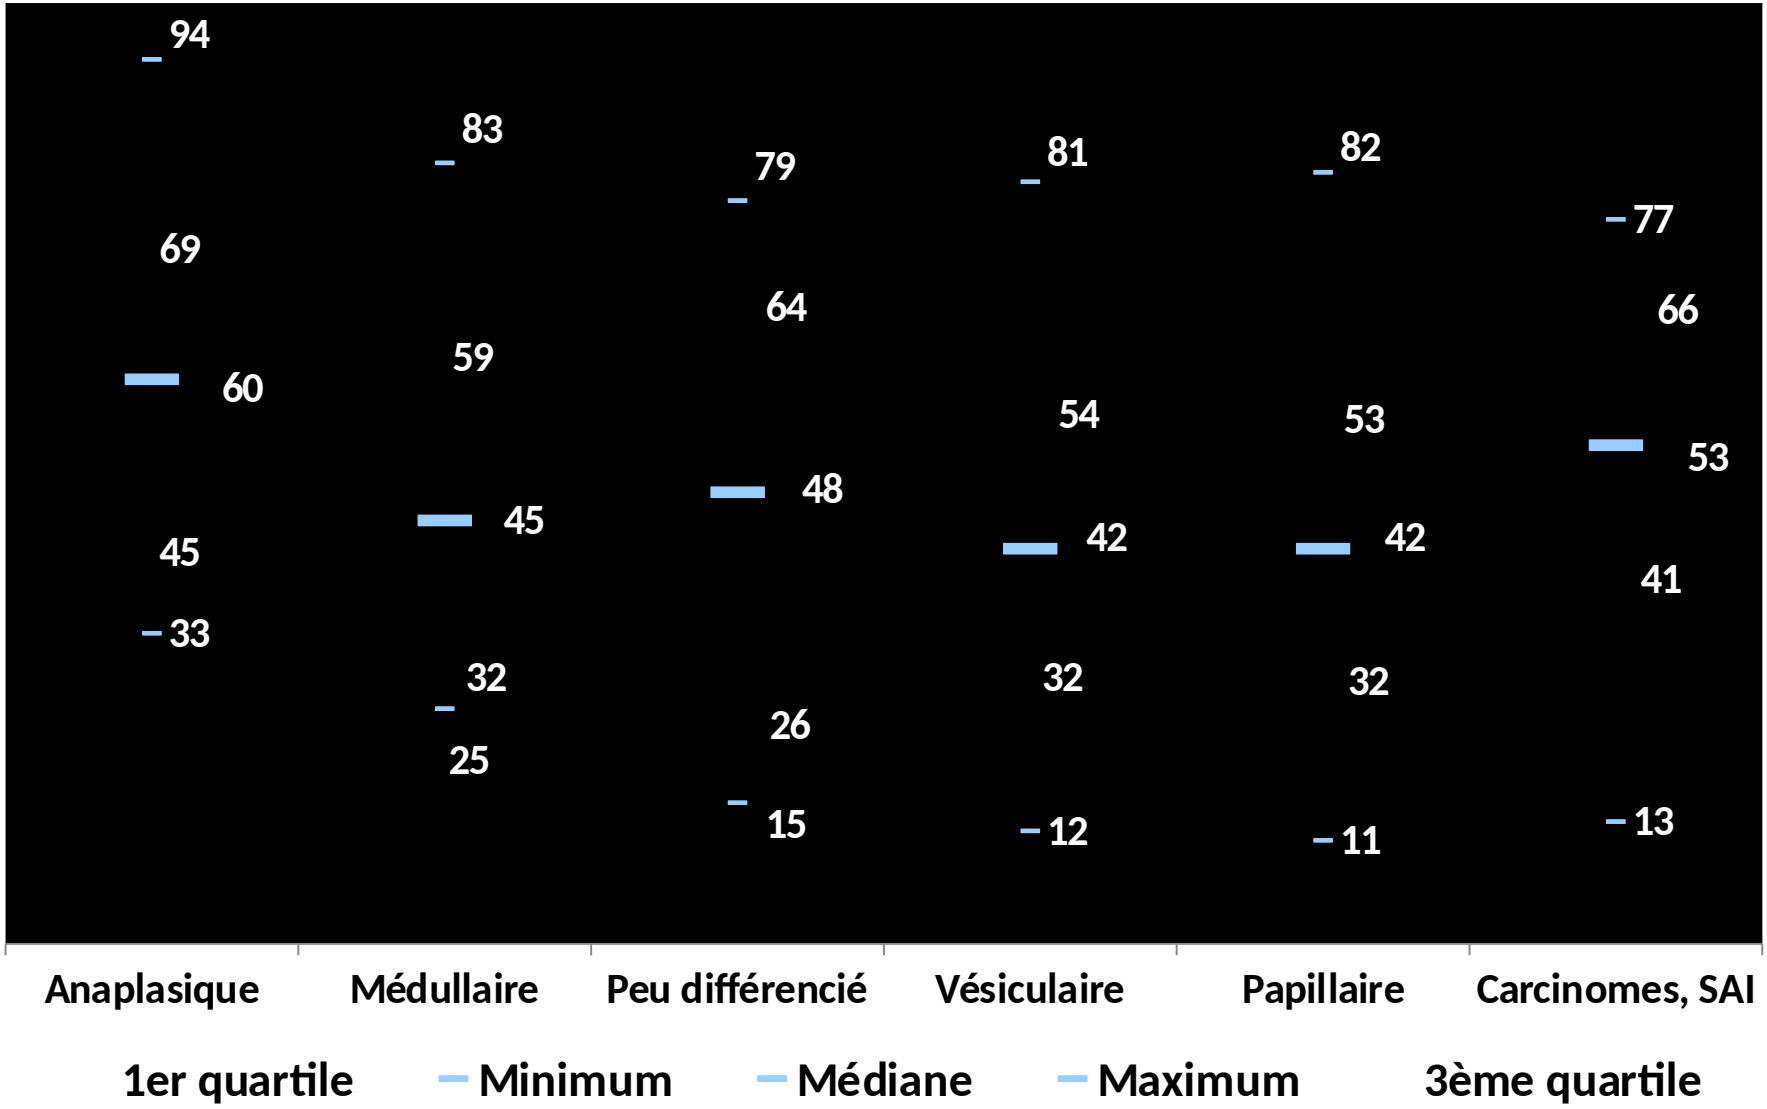


Distribution symétrique :

Q3-Q2 = Q2-Q1

Médiane = moyenne

Age Selon le Type Histopathologique



5- Les points extrêmes

Lorsqu'il y a des valeurs extrêment faibles ou fortes (par comparaison aux autres), elles méritent qu'on s'y intéresse.

- Possibilité d'erreur (de mesure, de frappe, …)
  => corriger ou retirer la valeur

- Si elles sont confirmées, ces valeurs exceptionnelles peuvent présenter un intérêt (cas particulier intéressant à étudier, …)

5- Les points extrêmes

Lorsqu'il y a des valeurs extrêment faibles ou fortes (par comparaison aux autres), elles méritent qu'on s'y intéresse.

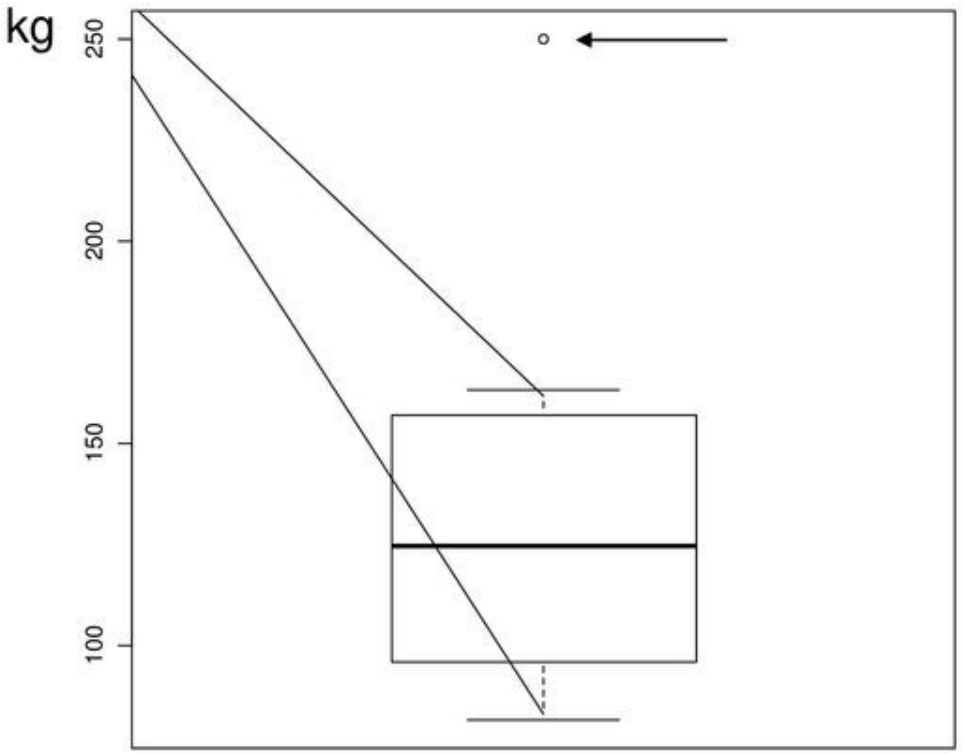
- Possibilité d'erreur (de mesure, de frappe, …)
  => corriger ou retirer la valeur

- Si elles sont confirmées, ces valeurs exceptionnelles peuvent présenter un intérêt (cas particulier intéressant à étudier, …)

On considère comme extrêmes les valeurs inférieures à Q1 - 1.5 EIQ ou supérieures à Q3 + 1.5 EIQ.

Sur une boîte à moustache, ces points sont représentés par des petits cercles à l'extérieur des moustaches.

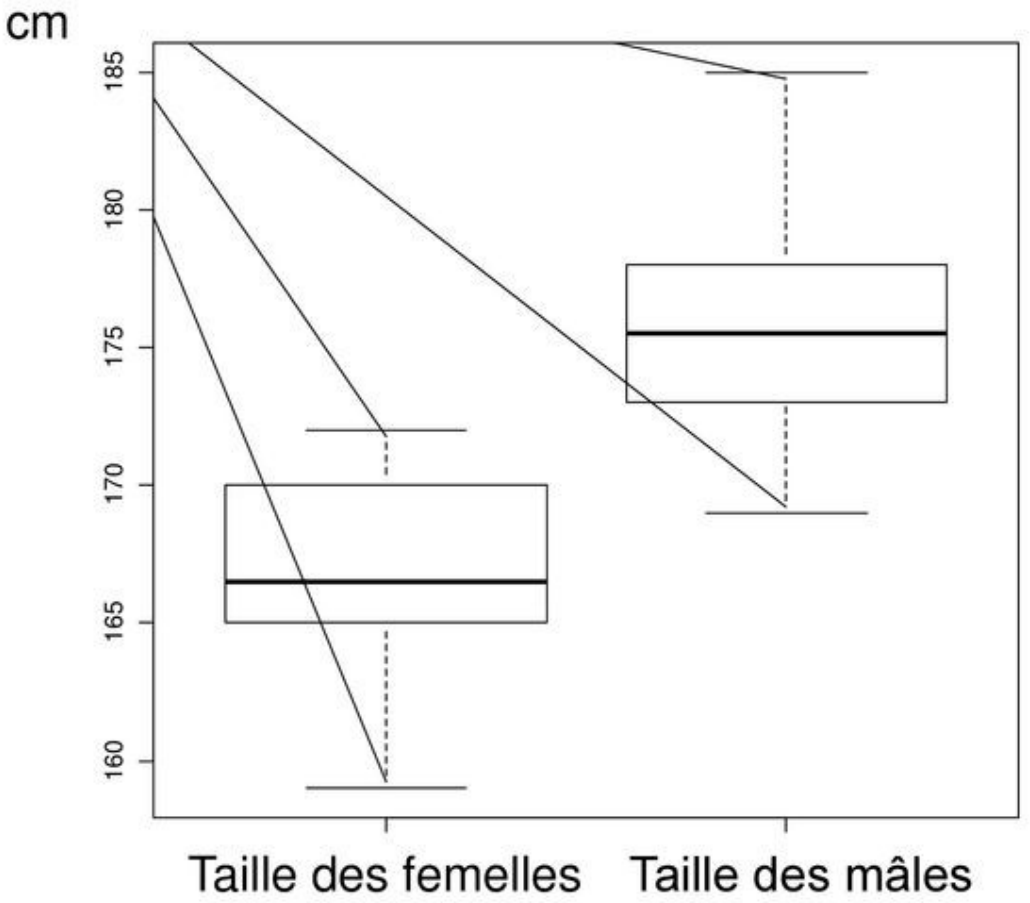
Ex : masse des ours avec un très gros ours en plus



6- Comparaison graphique de deux séries de données

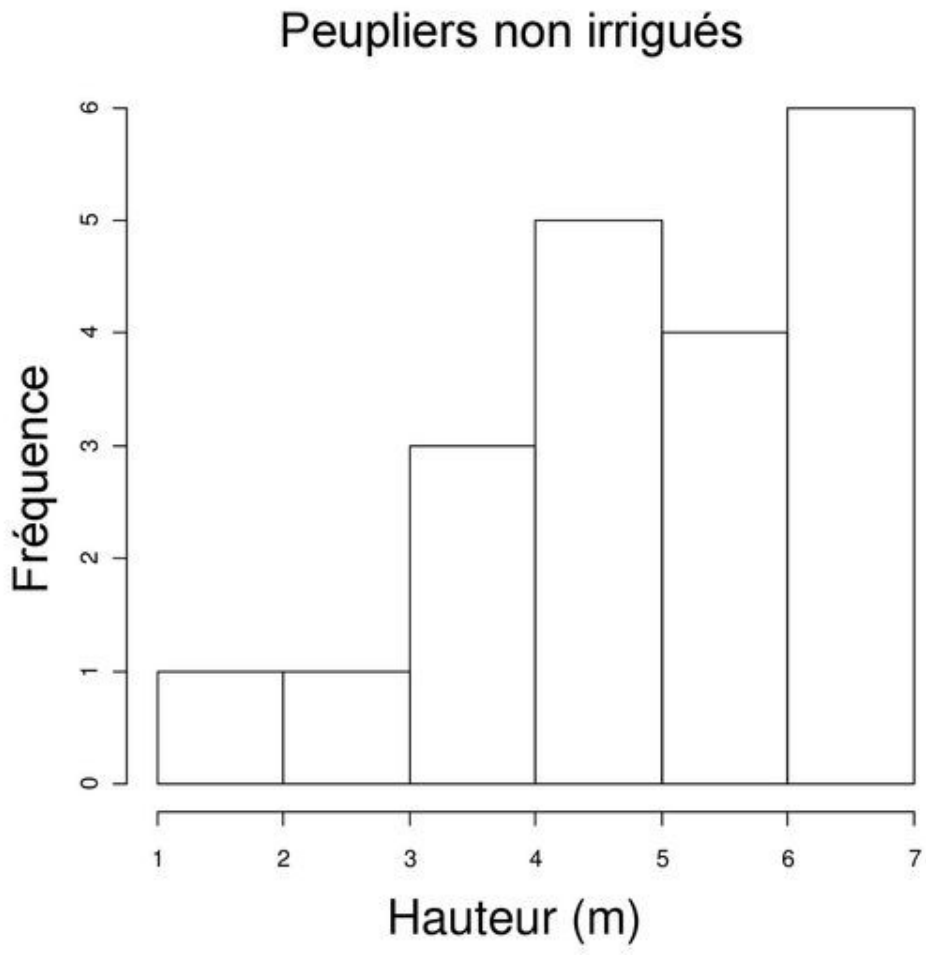
Boîte à moustaches

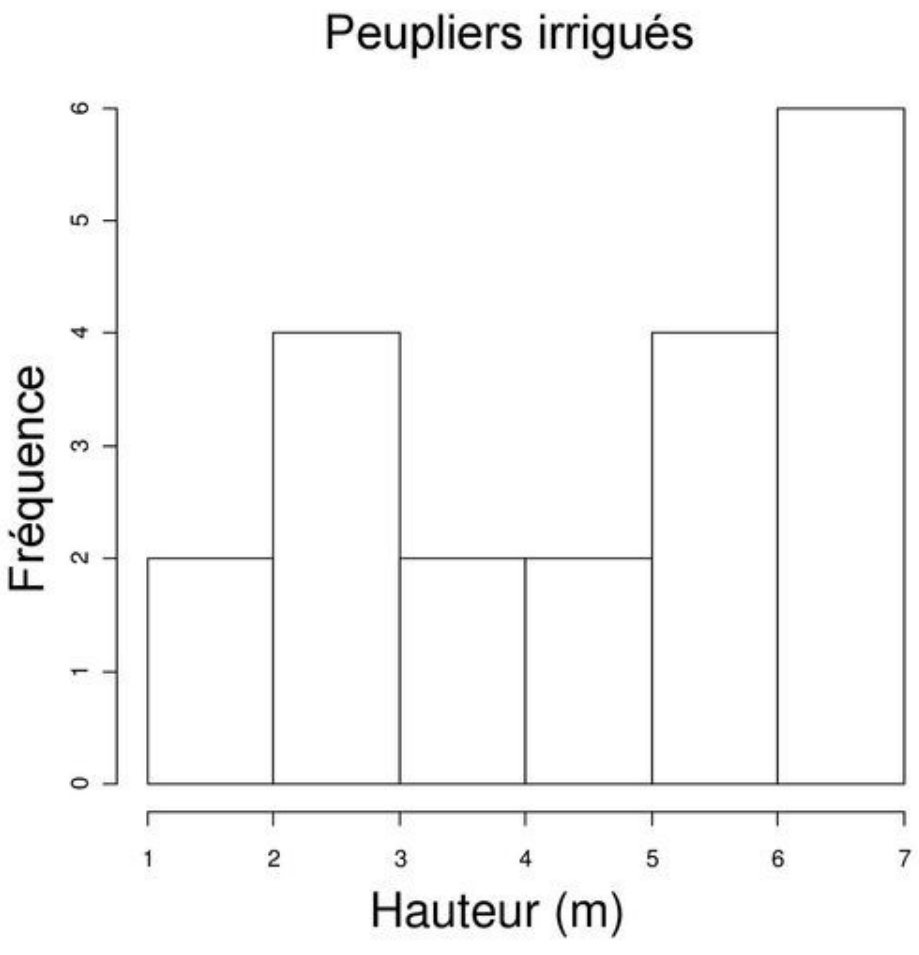
Comparaison des tailles des mâles et des femelles chez une espèce animale



Histogrammes

Hauteur de peupliers non irrigués / irrigués



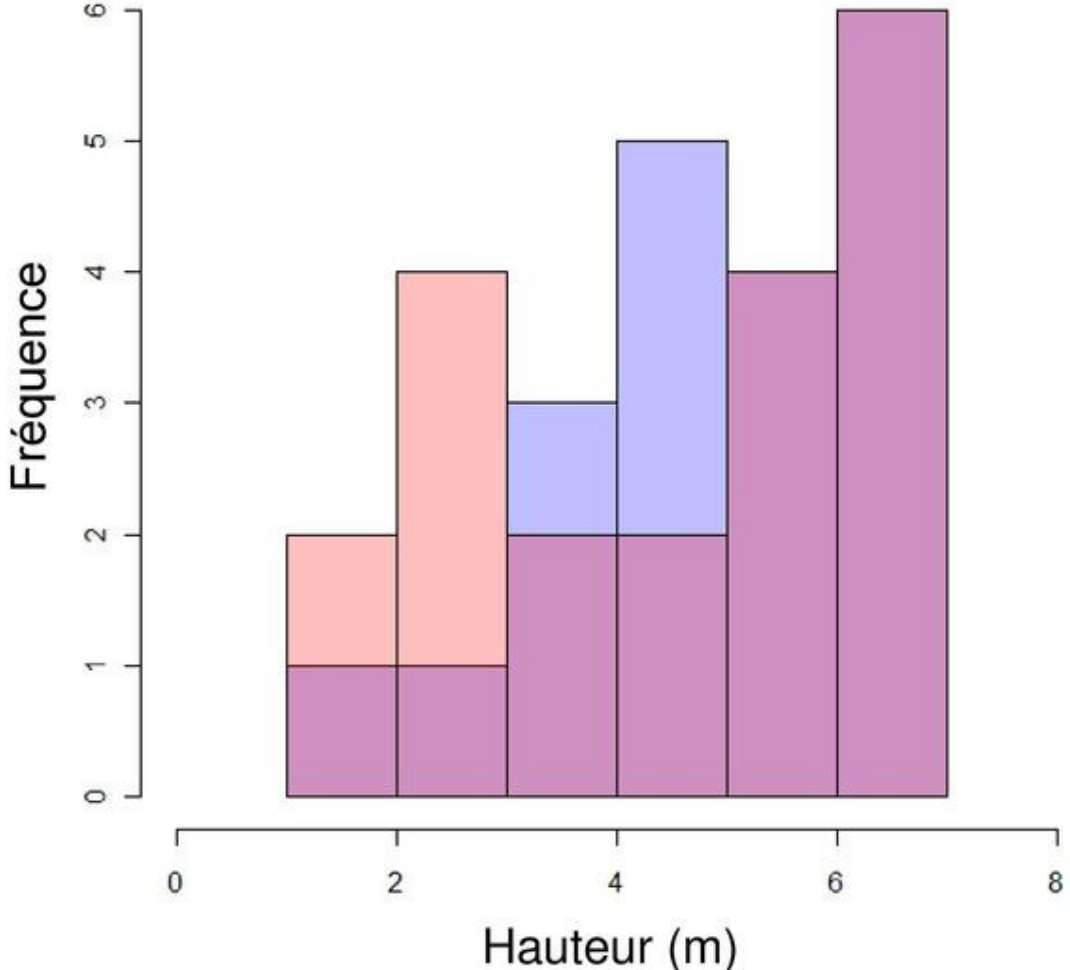


On peut superposer les deux graphiques pour les comparer

En bleu, peupliers non irrigués

En saumon, peupliers irrigués

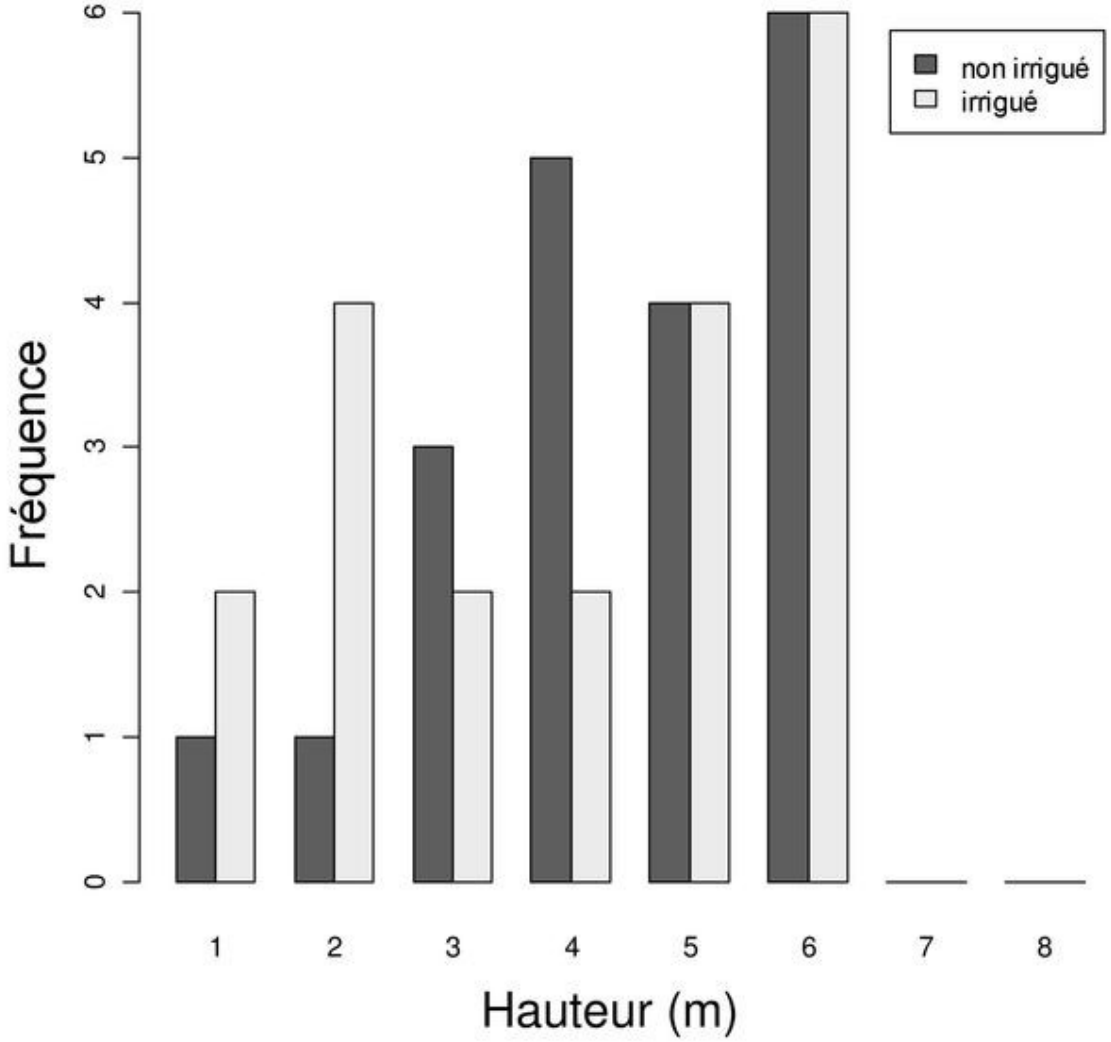
Pas toujours facile à lire



On peut aussi représenter les deux séries en alternance

Plus facile à lire en général

Ici : peu de différence
entre les deux traitements



Autres traitements

Ici : différence entre les traitements bien visible

