Analyse de variance

OBJECTIFS DU COURS

A la fin du cours l'étudiant doit connaître

1) Quand choisir le Test F

2) Connaître les conditions d'application du Test F.

3) Connaître le principe du test F.

4) Faire le calcule et l'interprétation du test F.

I. Introduction

- Dans un grand nombre de cas, on peut être amené à comparer entre non seulement deux moyennes mais plusieurs moyennes simultanément.

  Si on note les moyennes à comparer m1, m2, m3 ….mk.
- H0 = m1 =m2=m3=…..mk.
- H1= une des moyennes au moins est différente des autres moyennes.
- La technique sur laquelle repose le test d'hypothèse relatif à l'égalité de plusieurs moyennes s'appelle l'analyse de la variance.
- L'analyse de la variance (ou test ANOVA) Le nom de ce test s'explique par sa façon de procéder
- On décompose la variance totale de l'échantillon en deux variances partielles:

- La variance **inter-groupes**
- La variance **résiduelle (intra-groupes)**

Puis on compare ces deux variances.

II. Le choix du test F

- L'analyse de la variance s'applique lorsque on désire comparer les moyennes observées sur plusieurs échantillons.
- Les paramètres étudiés sont les **variances.**
- Hypothèse nulle (H0): les moyennes sont identiques, $Sg^2 = Sr^2$

III. *Les conditions d'application*

Les distributions des populations d'où proviennent les échantillons doivent être:

- normales et
- de même variance.

IV. Principe de l'analyse de la variance

Considérons plusieurs groupes, chacun est caractérisé par un effectif **ni**, une moyenne **mi**, et une variance **Si²**.

- L'analyse de la variance consiste à considérer le groupe total formé par l'ensemble des sous groupes et à comparer deux estimations de la variance de la population cible d'où a été le groupe total :
- L'une à partir de la variance des moyennes,
- L'autre à partir de la moyenne pondérée des variances (variance résiduelle ou intra-groupe).
- La comparaison des variances estimées s'effectue à l'aide du rapport de la variance entre séries (entre groupes) et de la variance résiduelle (entre individus)
- Sous H0: les individus proviennent de la même population.
- Elle suit une loi de Fisher à (c-1) et (n-c) ddl et qui va permettre de tester l'hypothèse nulle.
- La somme des carrés des écarts dans le groupe total est dissociée en une somme de deux termes :
- Somme des carrés dans le groupe total (SCT)

- Somme des carrés inter-groupes (**Sg ²)** Somme des carrés intragroupes (**Sr ²)**

- Le nombre de degrés de liberté (ddl) correspondant à chacune de ces sommes de carrés pour estimer la variance est N-1 pour SCt ; c-1 pour Sg ²

- Le rapport F permettant de comparer les moyennes entre elles s'écrit :
  F= [Sg ^{2} /(n-c)] / [Sr ^{2}/(c-1)].

Source de variation	**Somme des carrés**	**dl**	**variance**	**F**
Variance Entre groupes	**Sg ^{2}=∑ (Ti^2/ni) –Tg^2/N**	**K1= c-1**	**Sg ^{2}/ (c-1)**	**Sg ^{2} / (c-1)**
Variance Résiduelle (intra groupes)	**Sr ^{2}=∑X^2 -∑(Ti^2/ni)**	**K2= N - c**	**Sr ^{2}/ (N-c)**	**Sr ^{2}/ (N-c)**
Variance Totale	**SCt= ∑X^2 – Tg^2/N**	**N -1**		

c : nombre de groupes à comparer

ni : nombre de mesures dans le groupe (effectifs)

Ti : somme des mesures dans le groupe

N : ∑ni : nombre total de mesures (des observations)

Tg= ∑Ti : somme des mesures de tous les groupes

V. *Calcul du test*

Exemple:

On désire comparer un indicateur mesuré en **g/l** entre trois groupes de patients atteints de 3 formes cliniques d'une maladie notées A,B et C .

Les résultats sont les suivants :

A	B	C
19,5	44,1	76,6
38	29,5	88,3
33,2	68,8	83,4
52,2	34,9	88,2

77,4	51,2	87,3
92,6	42,5	96
77,4	32	85,6
48,3	92,2	100,2
95,6	84,5	84,8
51,5	61,2	93,5
34,3	65,8	134,6
	53,1	124,7
	87,2	

Peut-on affirmer que les taux de cet indicateur ne diffère pas entre les formes clinique de la maladie?

H0: les 03 moyennes sont identiques.

H1: les 03 moyennes sont différentes.

Conditions d'application:

Distribution normale,

Egalité des variances

	A	B	C
	19,5	44,1	76,6
	38	29,5	88,3
	33,2	68,8	83,4
	52,2	34,9	88,2
	77,4	51,2	87,3
	92,6	42,5	96
	77,4	32	85,6
	48,3	92,2	100,2

	95,6	84,5	84,8
	51,5	61,2	93,5
	34,3	65,8	134,6
		53,1	124,7
		87,2	
n_i	11	13	12
$\Sigma x_i = T_i$	620	747	1143,2
$(\Sigma x)^2 = T_i^2$	384400	558009	1306906
T_i^2/n_i	34945,5	42924	108909
Σx^2	41509	48358	112204

$Tg = \Sigma T_i$ Tg= 2510,2

Tg^2 = 6301104,04 N = 36 T_g^2/N = 175031

Variance	Somme des carrés	ddl	variance	F
Entre groupe	Sg^2=186778 – 175031 = 11747	K1= 3-1=2	5873,5	12,68
Résiduelle	Sr^2=202071 – 186778 =15293	K2= 36 - 3=33	463,4	

F = 12,68 (F calculé)

k_1= 2 k_2=33

Dans les tables de F, on ne dispose pas des valeurs pour k_2=33

Pour k_1= 2 k_2=30, la valeur de F trouvée (12,68) est encore supérieure à $F_{0,001}$ qui est de 8,77.

F calculé > F table , donc on rejette H0.

Conclusion: les trois moyennes diffèrent significativement avec p < 0,001

Je vous demande de faire tout d'abord les calculs manuellement ensuite vous utilisez le logiciel open epi pour faire les calculs et les interprétations (il faux savoir que le logiciel open epi il donne deux résultats pour l'ANOVA en cas d'égalité des variances et en cas de variances inégales)

Bon courage prenez soin de vous et de vos familles appliquez les mesures barrières afin d'éviter toute contamination et il faut pas oublier de toujours aérer