Corrélation et régression linéaire simple

Plan

I- Corrélation et régression linéaire

I-1 Nature des variables

I-2 Corrélation versus régression : exemples

I-3 Conditions d'application

II. Coefficient de corrélation

II-1 Covariance

II-2 Coefficient de corrélation et interprétation

II-3 Estimation du coefficient de corrélation

II-4 Test du coefficient de corrélation

III. Régression linéaire simple

III-1 Régression linéaire simple

III-2 Estimation par la méthode des moindres carrés

III-3 Test de la pente de la droite de régression

I- Corrélation et régression linéaire

I-1 Nature des variables

- Le terme de corrélation est utilisé dans le langage courant pour désigner la liaison (relation / association) entre 2 variables quelconques.
- En statistique, le terme de corrélation est réservé pour désigner la liaison entre 2 variables **quantitatives** (le plus souvent continues).
- Corrélation / régression : liaison entre 2 variables quantitatives

I-2 Corrélation versus régression

- **Corrélation :**
- Liaison entre 2 variables quantitatives X et Y
- Rôle **symétrique** (on peut permuter X et Y)

- **Régression :**
- Liaison entre 2 variables quantitatives X et Y
- Rôle **asymétrique** uniquement :
  – X = variable explicative / Y = variable expliquée
  – X = variable indépendante / Y = variable dépendante
- (on ne peut pas permuter X et Y)

1. Exemple : corrélation (positive)

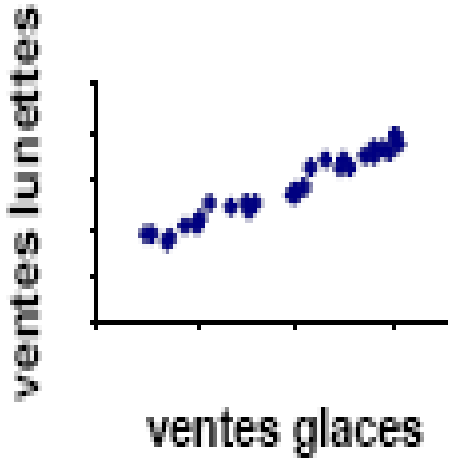
- X = ventes de paires de lunettes de soleil en été
- Y = ventes de crèmes glacées en été
- **Il existe une liaison entre X et Y :**

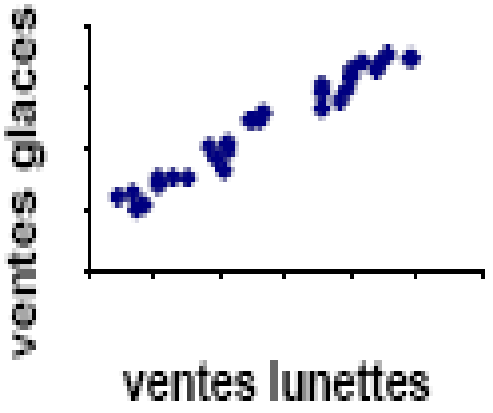
– Quand X augmente, Y augmente (météo estivale)
– Quand X diminue, Y diminue (météo pluvieuse)

- **La liaison est symétrique :**

– X est liée à Y, et Y est liée à X
– mais X ne dépend pas de Y et Y ne dépend pas de X
– on peut permuter X et Y en abscisses et en ordonnées

- **Y ne peut pas être prédite par X**





2. Exemple : corrélation (négative)

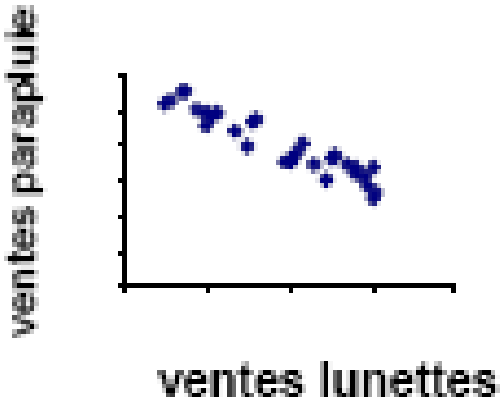
- X = ventes de paires de lunettes de soleil en été
- Y = ventes de parapluies en été
- **Il existe une liaison entre X et Y :**

– Quand X augmente, Y diminue (météo estivale)
– Quand X diminue, Y augmente (météo pluvieuse)

- **La liaison est symétrique :**

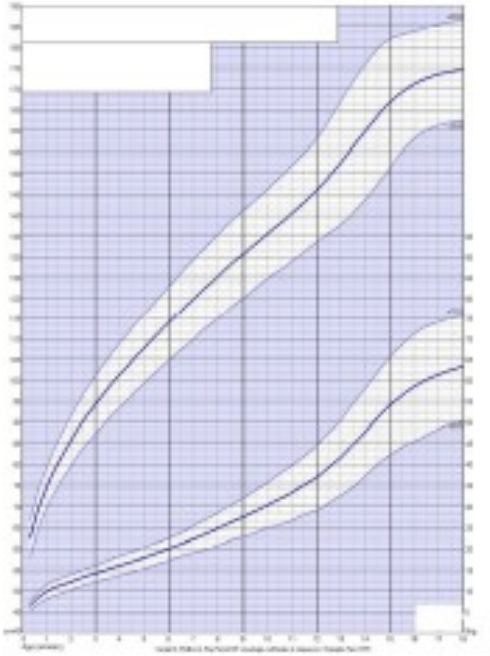
– X est liée à Y, et Y est liée à X
– mais X ne dépend pas de Y et Y ne dépend pas de X
– on peut permuter X et Y en abscisses et en ordonnées

- **Y ne peut pas être prédite par X**





3. Exemple : régression



- X = âge (de 0 à 15 ans)
- Y = taille (cm)
- **Il existe une liaison entre X et Y :**

– Quand l'âge augmente, la taille augmente
– Quand l'âge diminue, la taille diminue

- **La liaison est asymétrique :**

– la taille dépend de l'âge mais l'âge ne dépend pas de la taille
– on ne peut pas permuter X et Y en abscisses et en ordonnées

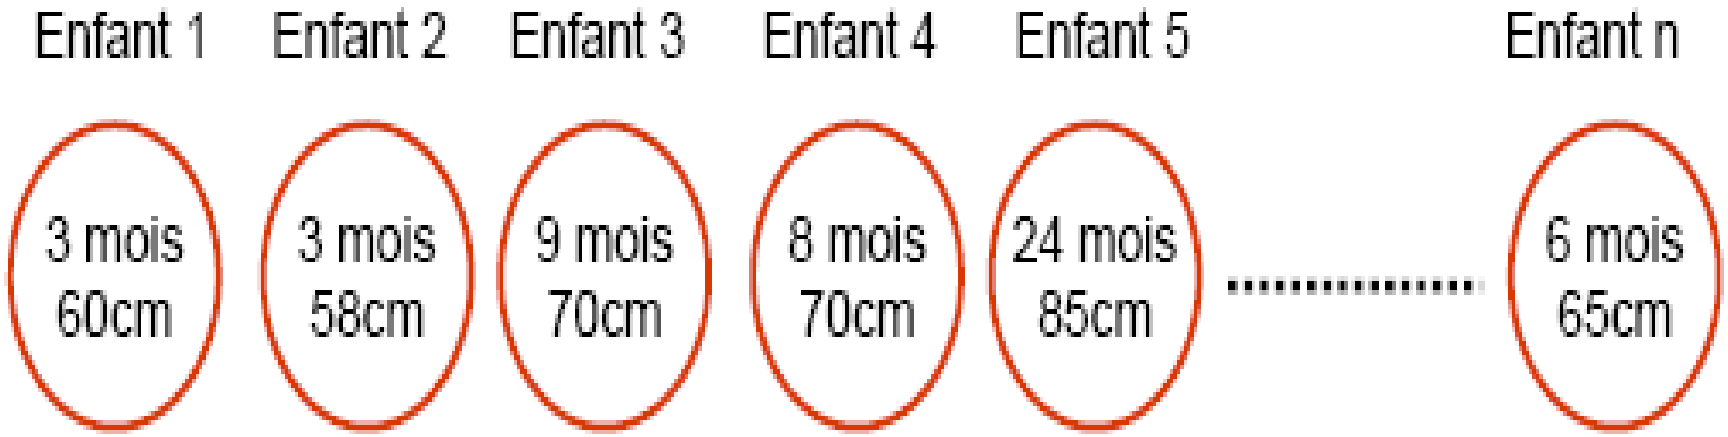
- On peut **prédire** la taille par l'âge à l'aide d'une équation de droite ou de courbe de régression (cf carnet de santé)

	Corrélation	Régression
Variables	X = quantitative Y = quantitative	X = quantitative Y = quantitative
Symétrie de la liaison	Oui / Non Y liée à X X liée à Y	Non Y dépend de X -
Exemples	Y = conso. cannabis X = température moyenne annuelle	Y= taille X = âge
Prédiction	Non	Oui (équation)

I-3 Conditions d'application de la corrélation et de la régression linéaire simple

- Indépendance des observations
- Liaison linéaire entre X et Y
- Distribution conditionnelle normale et de variance constante

1. Indépendance des observations



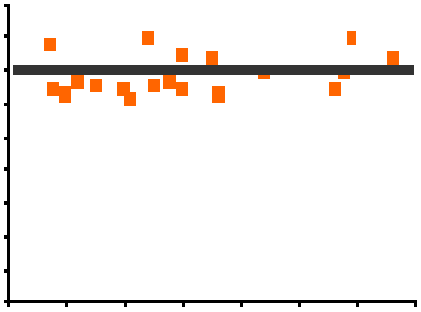
Observations indépendantes (et variables corrélées)

2. Liaison linéaire entre X et Y

Avant d'appliquer le test du coefficient de corrélation ou d'estimer la droite de régression, il faut vérifier -empiriquement (graphiquement) - que la liaison entre les 2 variables est de nature linéaire.

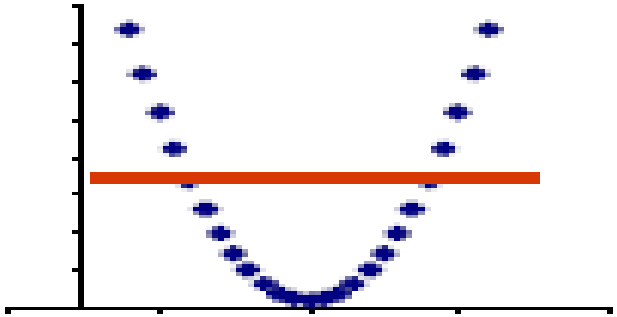
.

- **Cas 1**



La nature de la liaison est linéaire (le nuage de points est résumé au mieux par une droite horizontale d'équation y = a)
La condition d'application est vérifiée
Il est possible d'utiliser le coefficient de corrélation et la régression linéaire simple pour quantifier la liaison entre les 2 variables (conclusion : X et Y sont indépendants [Y constant quelle que soit la valeur de X])

- **Cas 2**



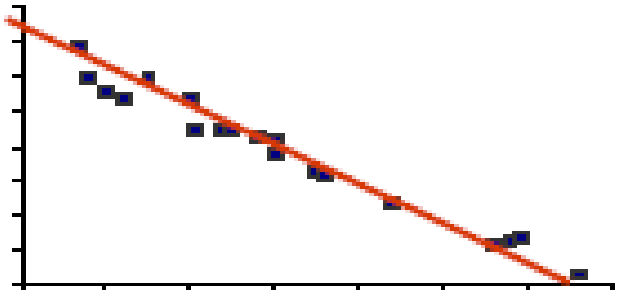
Il existe une liaison entre X et Y mais cette liaison n'est pas linéaire :Y varie avec les valeurs de X.

Le nuage de points n'est pas résumé au mieux par une droite mais plutôt par une fonction quadratique.

La condition d'application n'est pas vérifiée

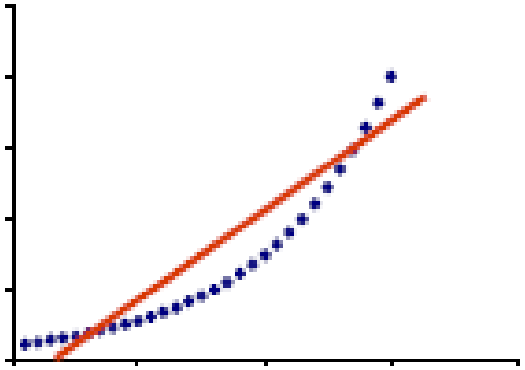
→ Il ne faut pas utiliser le coefficient de corrélation ni la régression linéaire simple pour quantifier la liaison entre les 2 variables

- **Cas 3**



La nature de la liaison est linéaire (le nuage de points est résumé au mieux par une droite d'équation y = a+bx)
La condition d'application est vérifiée
Il est possible d'utiliser le coefficient de corrélation et la régression linéaire simple pour quantifier la liaison entre les 2 variables (conclusion : il existe une liaison linéaire entre X et Y)

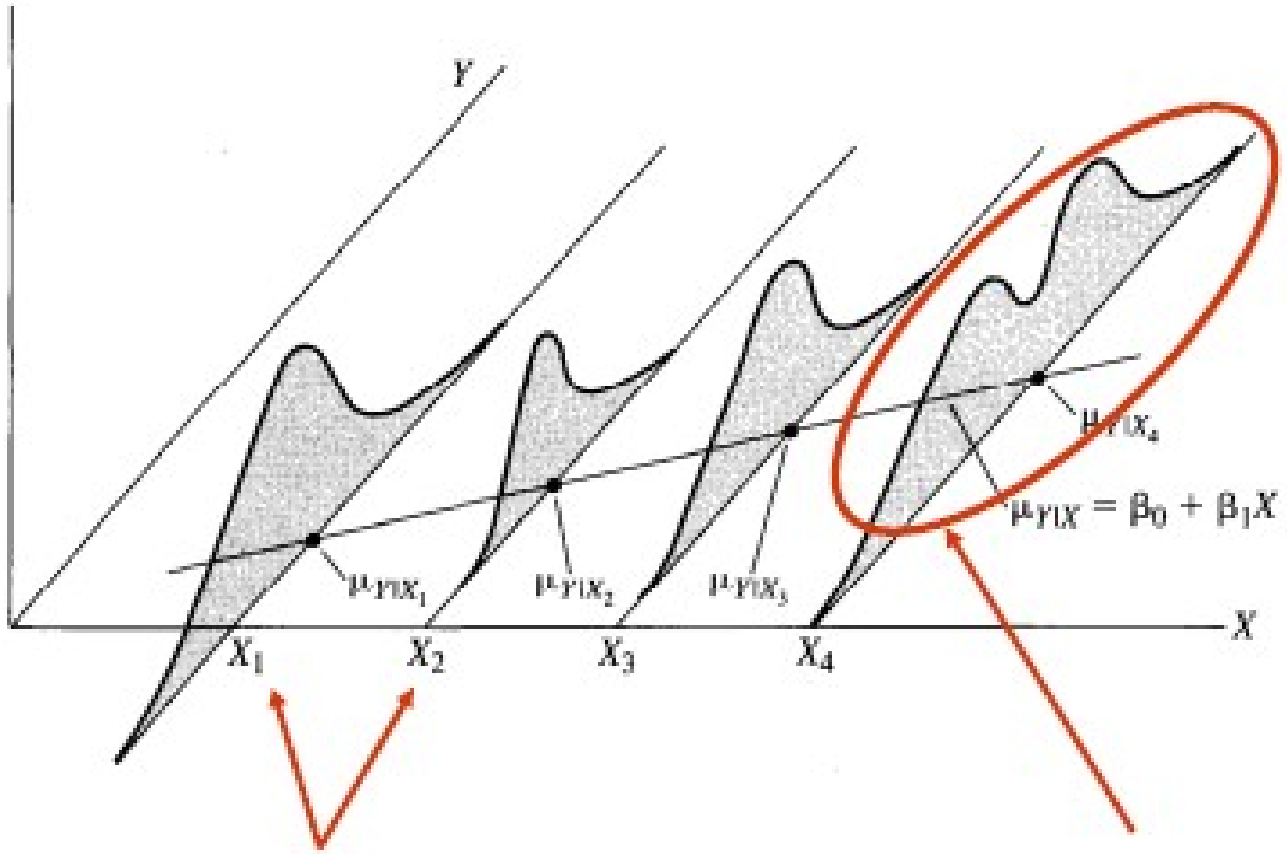
- **Cas 4**



La nature de la liaison n'est pas linéaire (le nuage de points n'est pas résumé au mieux par une droite mais plutôt par une fonction exponentielle)
La condition d'application n'est pas vérifiée
→ Il ne faut pas utiliser le coefficient de corrélation ni la régression linéaire simple pour quantifier la liaison entre les 2 variables

3. Distribution conditionnelle normale et de variance constante

- Distribution de Y normale et de variance constante pour chaque valeur de X
- (difficilement vérifiable en pratique)



La variance de Y n'est pas constante pour les différentes valeurs de X

La distribution de Y n'est pas normale pour X = x4

La condition d'application n'est pas vérifiée

II- Coefficient de corrélation

II-1 Covariance

- **Variance conjointe de 2 variables X et Y**

$$\mathrm{cov}(X,Y) = \frac{\sum_{i=1}^{N}(X_i - \mu_X)(Y_i - \mu_Y)}{N}$$

- **Cas particulier : X = Y → cov(X,Y) = cov(X,X) = var(X)**

$$\mathrm{cov}(X,X) = \frac{\sum_{i=1}^{N}(X_i - \mu_X)(X_i - \mu_X)}{N} = \frac{\sum_{i=1}^{N}(X_i - \mu_X)^2}{N} = \mathrm{var}(X)$$

- **Équivalent de la formule de Huyghens pour la covariance**

$$\operatorname{cov}(X,Y) = \frac{\sum_{i=1}^{n} x_i y_i - \frac{\left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n}}{n}$$

Rappel

- **La moyenne arithmétique en x et en y**

$\mu_X = 1/n \sum x_i$ et $\mu_Y = 1/n \sum Y_i$

- **La variance en x et en y**

- $S^2_X = 1/n \sum (X_i - \mu_X)^2 = 1/n \sum X_i^2 - (\mu_X)^2$

- $S^2_Y = 1/n \sum (Y_i - \mu_Y)^2 = 1/n \sum Y_i^2 - (\mu_Y)^2$

- **La covariance →** C'est la variance commune entre les deux variables x et y

- $Cov(x, y) = 1/n \sum (X_i - \mu_X)(Y_i - \mu_Y)$ Ou encore

- $Cov(x, y) = 1/n \sum X_i Y_i - \mu_X . \mu_Y$

Rappel

- **Variance**

$$\mathrm{var}(x) = \left(\frac{1}{n}\sum x^2\right) - \left(\frac{1}{n}\sum x\right)^2$$

$$\mathrm{var}(x) = \frac{\sum_{i=1}^{n} x_i^2 - \frac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}}{n}$$

- **Covariance**

$$\mathrm{cov}(x, y) = \left(\frac{1}{n}\sum xy\right) - \left[\left(\frac{1}{n}\sum x\right) \times \left(\frac{1}{n}\sum y\right)\right]$$

$$\mathrm{cov}(X, Y) = \frac{\sum_{i=1}^{n} x_i y_i - \frac{\left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n}}{n}$$

II-2 Coefficient de corrélation

Le coefficient de corrélation entre 2 variables quantitatives X et Y est égal au rapport de la covariance de X et Y divisé par le produit des écart- types de X et Y.

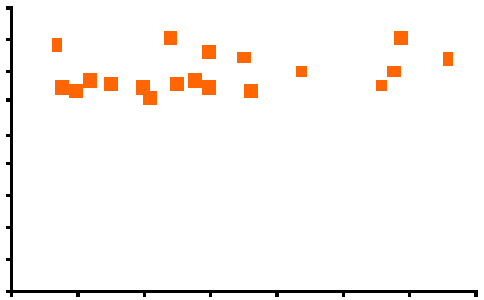
Le coefficient de corrélation est noté ρ dans la population.

$$\rho = \frac{\mathrm{cov}(X,Y)}{\sqrt{\mathrm{var}(X)\,\mathrm{var}(Y)}}$$

$$-1 \leq \rho \leq +1$$

II-2 Interprétation du coefficient de corrélation

1. X et Y indépendantes : ρ = 0

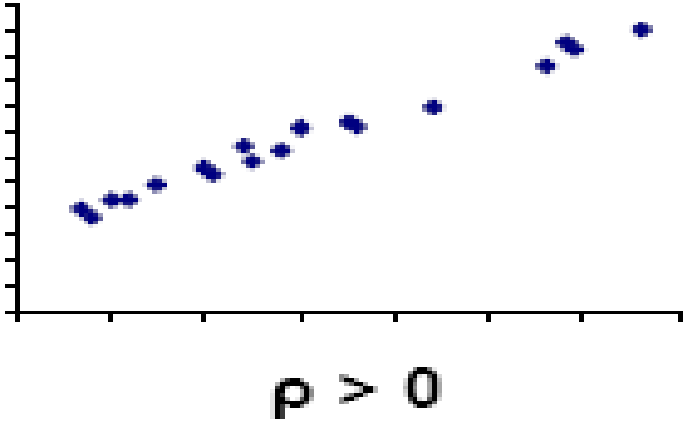


ρ = 0

- Y = fluctue autour d'une constante quelle que soit la valeur de X
- Nuage de points horizontal
- cov(X, Y) = 0

$$\rho = \frac{\mathrm{cov}(X, Y)}{\sqrt{\mathrm{var}(X)\,\mathrm{var}(Y)}} = 0$$

2. X et Y corrélées : ρ > 0

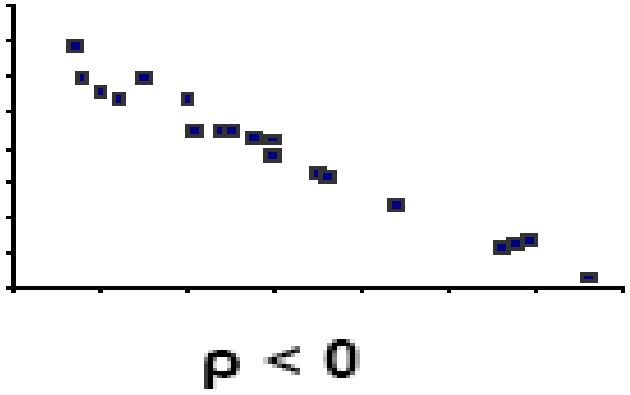


- Liaison linéaire croissante entre X et Y
- cov(X, Y) > 0

$$\rho = \frac{\mathrm{cov}(X,Y)}{\sqrt{\mathrm{var}(X)\,\mathrm{var}(Y)}} > 0$$

NB : si Y = X → cov(X,Y) = var(X) et var(Y) = var(X) → **ρ =1**

3. X et Y corrélées : ρ < 0



- Liaison linéaire décroissante entre X et Y
- cov(X, Y) <0

$$\rho = \frac{\mathrm{cov}(X,Y)}{\sqrt{\mathrm{var}(X)\,\mathrm{var}(Y)}} < 0$$

NB : si Y = - X → cov(X,Y) = - var(X) et var(Y) = var(X) → **ρ =-1**

II-3 Estimation du coefficient de corrélation



Le coefficient de corrélation estimé sur un échantillon issu d'une population est noté r.

Il s'interprète comme le coefficient de corrélation ρ mesuré sur la population.

Il est calculé à partir des estimations de la covariance et des variances de X et de Y sur l'échantillon.

$$\mathrm{cov}(X,Y) = \frac{\sum_{i=1}^{n}(x_i - m_x)(y_i - m_y)}{(n-1)}$$

$$s_x^2 = \frac{\sum_{i=1}^{n}(x_i - m_x)^2}{(n-1)}$$

$$s_y^2 = \frac{\sum_{i=1}^{n}(y_i - m_y)^2}{(n-1)}$$

on obtient l'expression de l'estimateur du ncoefficient de corrélation r à partir d'un échantillon.

$$r = \frac{\sum_{i=1}^{n}(x_i - m_x)(y_i - m_y)}{\sqrt{\sum_{i=1}^{n}(x_i - m_x)^2 \sum_{i=1}^{n}(y_i - m_y)^2}}$$

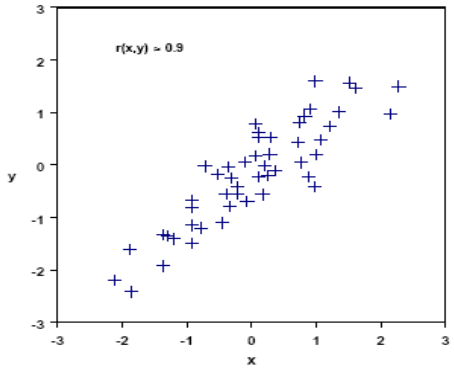
A partir de la formule de Huyghens l'estimation de r à partir d'un échantillon devient:

$$r = \frac{\sum_{i=1}^{n} x_i y_i - \frac{\left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n}}{\sqrt{\left[\sum_{i=1}^{n} x_i^2 - \frac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}\right]\left[\sum_{i=1}^{n} y_i^2 - \frac{\left(\sum_{i=1}^{n} y_i\right)^2}{n}\right]}}$$

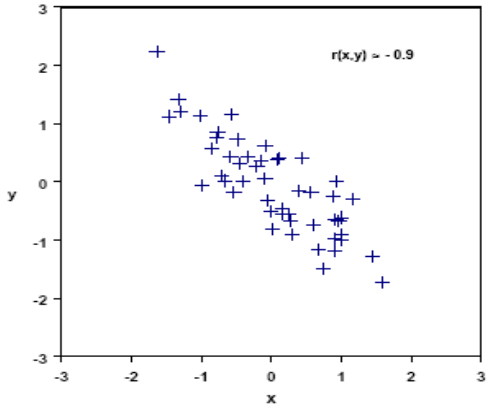
Coefficient de corrélation linéaire r (x; y): Propriétés

- **-1 ≤ r (x; y) ≤ 1**
- **r (x; y) > 0 → relation linéaire croissante**
- **r (x; y) < 0 → relation linéaire décroissante**
- **r (x; y) = 0 → pas de relation linéaire**
- **r (x; y) = ±1 → relation linéaire parfaite**

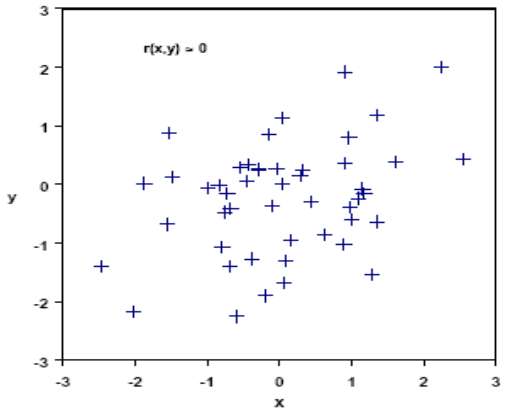
Relation linéaire Croissante



Relation linéaire décroissante

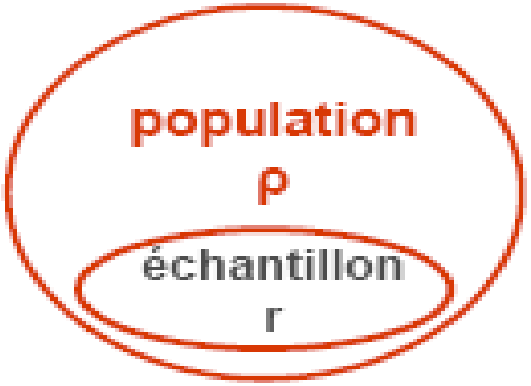


Pas de relation linéaire



II-4 Test du coefficient de corrélation

Après le calcul du coefficient de corrélation r estimé sur un échantillon,il faut déterminer si le coefficient de corrélation ρ est Significativement différent de 0.



$r \approx \rho$

H_0 : $\rho = 0$ (absence de liaison [linéaire] entre X et Y)

H_1 bilatérale : $\rho \neq 0$ (existence d'une liaison entre X et Y)

Sous l'hypothèse nulle (H_0) :

Le rapport de l'estimateur du coefficient de corrélation r sur son Écart-type suit une loi de Student à (n-2) degrés de liberté.

n est l'effectif de l'échantillon.

$$\frac{r}{s_r} \rightarrow t_{(n-2)ddl}$$

L'estimateur de l'écart-type du coefficient de corrélation est égal à

$$s_r = \sqrt{\frac{1 - r^2}{n - 2}}$$

Le test du coefficient de corrélation consiste à calculer la grandeur To et à la comparer à la valeur seuil tα sur la table de la loi de Student à (n-2) degrés de libertés.

$$t_o = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

Conditions d'application

- indépendance des observations
- liaison linéaire entre X et Y
- distribution conditionnelle normale et de variance constante

Détermination du degré de signification associé à to (*P*- value)

Exemple :

- to = 2.12
- n = 20

0.02 < *P* <0.05

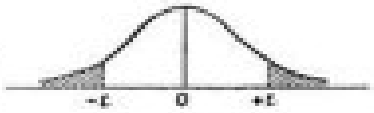
P < α → rejet de H0

(n-2) = 18 ddl

Rappel : P- value = probabilité d'observer une valeur plus grande Que to sous l'hypothèse nulle H0

Table de *t* (*).

La table donne la probabilité α pour que *t* égale ou dépasse, en valeur absolue, une valeur donnée, en fonction du nombre de degrés de liberté (d.d.l.).



d.d.l. \ α	0,90	0,50	0,30	0,20	0,10	0,05	0,02	0,01	0,001
1	0,158	1,000	1,963	3,078	6,314	12,706	31,821	63,657	636,619
2	0,142	0,816	1,386	1,886	2,920	4,303	6,965	9,925	31,598
3	0,137	0,765	1,250	1,638	2,353	3,182	4,541	5,841	12,924
4	0,134	0,741	1,190	1,533	2,132	2,776	3,747	4,604	8,610
5	0,132	0,727	1,156	1,476	2,015	2,571	3,365	4,032	6,869
6	0,131	0,718	1,134	1,440	1,943	2,447	3,143	3,707	5,959
7	0,130	0,711	1,119	1,415	1,895	2,365	2,998	3,499	5,408
8	0,130	0,706	1,108	1,397	1,860	2,306	2,896	3,355	5,041
9	0,129	0,703	1,100	1,383	1,833	2,262	2,821	3,250	4,781
10	0,129	0,700	1,093	1,372	1,812	2,228	2,764	3,169	4,587
11	0,129	0,697	1,088	1,363	1,796	2,201	2,718	3,106	4,437
12	0,128	0,695	1,083	1,356	1,782	2,179	2,681	3,055	4,318
13	0,128	0,694	1,079	1,350	1,771	2,160	2,650	3,012	4,221
14	0,128	0,692	1,076	1,345	1,761	2,145	2,624	2,977	4,140
15	0,128	0,691	1,074	1,341	1,753	2,131	2,602	2,947	4,073
16	0,128	0,690	1,071	1,337	1,746	2,120	2,583	2,921	4,015
17	0,128	0,689	1,069	1,333	1,740	2,110	2,567	2,898	3,965
18	0,127	0,688	1,067	1,330	1,734	2,101	2,552	2,878	3,922
19	0,127	0,688	1,066	1,328	1,729	2,093	2,539	2,861	3,883
20	0,127	0,687	1,064	1,325	1,725	2,086	2,528	2,845	3,850
21	0,127	0,686	1,063	1,323	1,721	2,080	2,518	2,831	3,819
22	0,127	0,686	1,061	1,321	1,717	2,074	2,508	2,819	3,792
23	0,127	0,685	1,060	1,319	1,714	2,069	2,500	2,807	3,767
24	0,127	0,685	1,059	1,318	1,711	2,064	2,492	2,797	3,745
25	0,127	0,684	1,058	1,316	1,708	2,060	2,485	2,787	3,725
26	0,127	0,684	1,058	1,315	1,706	2,056	2,479	2,779	3,707
27	0,127	0,684	1,057	1,314	1,703	2,052	2,473	2,771	3,690
28	0,127	0,683	1,056	1,313	1,701	2,048	2,467	2,763	3,674
29	0,127	0,683	1,055	1,311	1,699	2,045	2,462	2,756	3,659
30	0,127	0,683	1,055	1,310	1,697	2,042	2,457	2,750	3,646
∞	0,126	0,674	1,036	1,282	1,645	1,960	2,326	2,576	3,291

III- Régression linéaire simple

III-1 Régression linéaire simple

La régression s'adresse à un type de problème où les 2 Variables quantitatives continues X et Y ont un rôle asymétrique : la variable Y dépend de la variable X.

La liaison entre la variable Y dépendante et la variable X Indépendante peut être modélisée par une fonction de type

$Y = \alpha + \beta X$, représentée graphiquement par une droite.

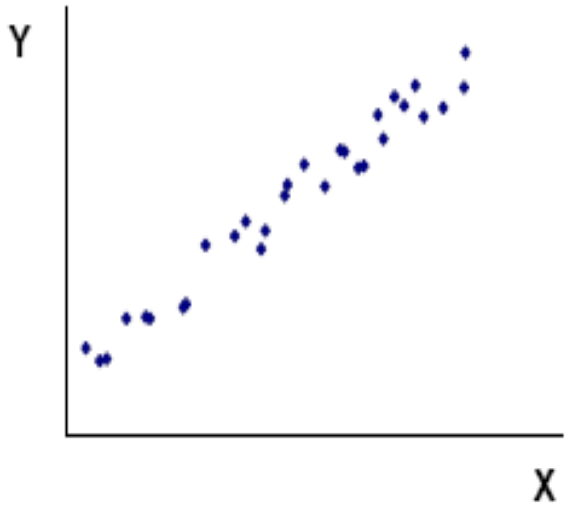
$Y = \alpha + \beta X$

Y : variable dépendante (expliquée)

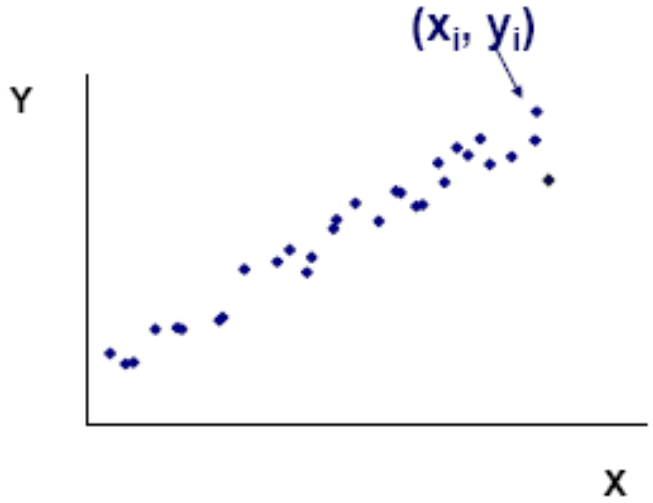
X : variable indépendante (explicative)

α : ordonnée à l'origine (valeur de Y pour x = 0)

β : pente (variation moyenne de la valeur de Y pour une augmentation d'une unité de X)

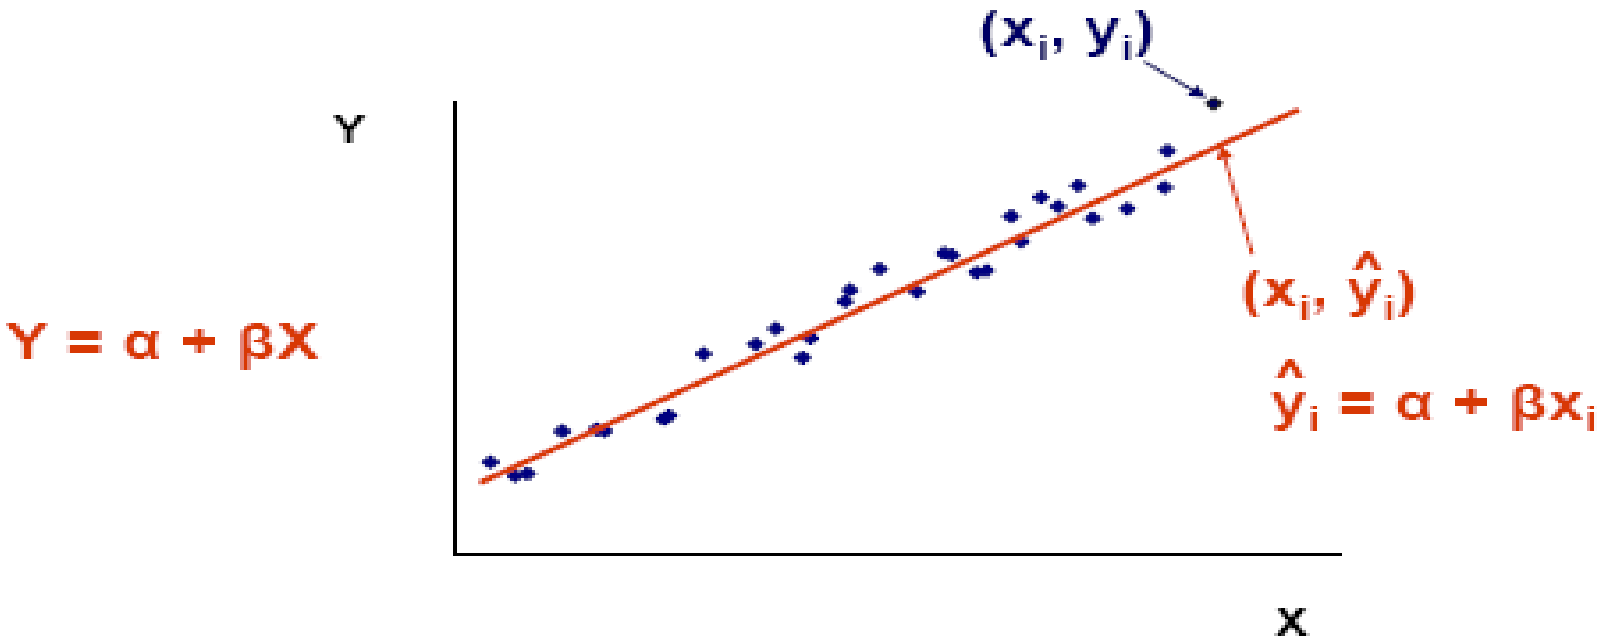


III-2 Estimation par la méthode des moindres carrés

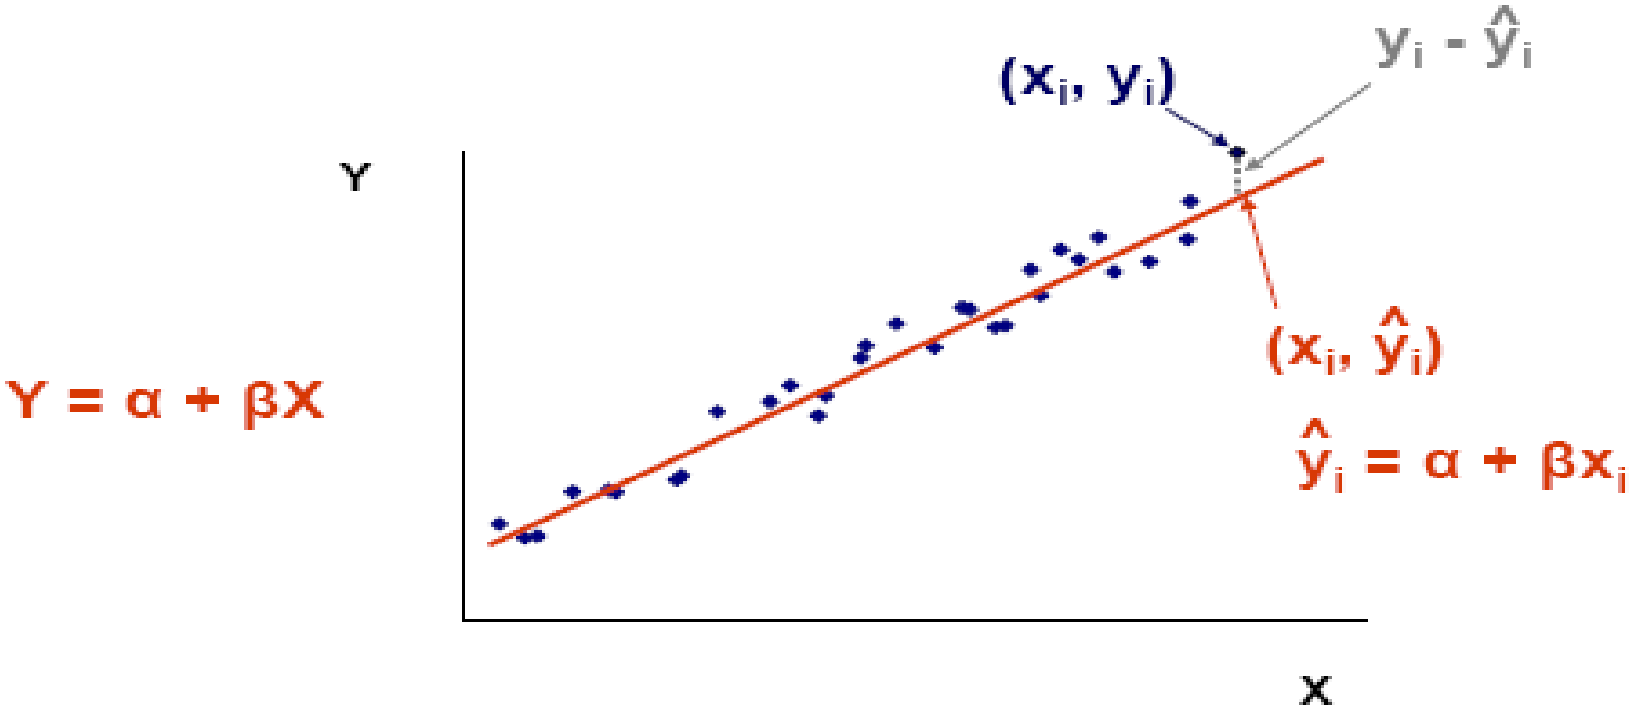


Chaque individu i est caractérisé par un couple de coordonnées (xi,yi) et est représenté par un point sur le graphique.

L'ensemble des individus forme un nuage de points.

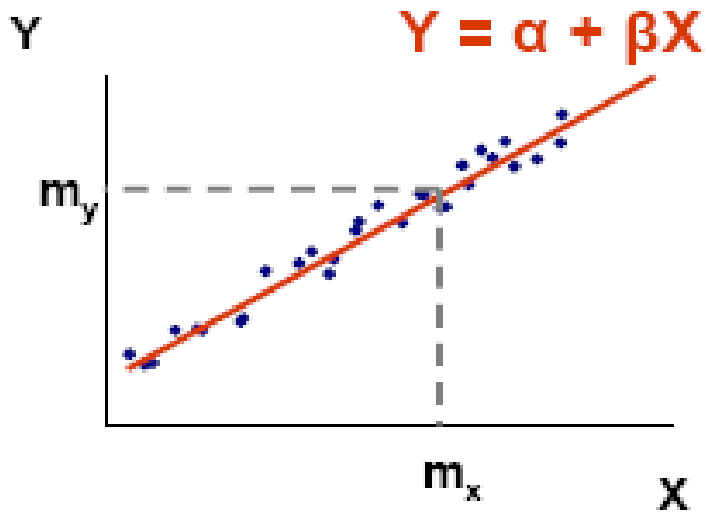


La droite de régression Y = α + βX est la droite qui résume le mieux Le nuage de points. Intuitivement, il s'agit de la droite dont les points du nuage sont en moyenne les plus proches (c'est-à-dire la droite qui passe à la plus faible distance de chaque point du nuage, En moyenne).



$$SCE = \Sigma_i (y_i - \hat{y}_i)^2$$

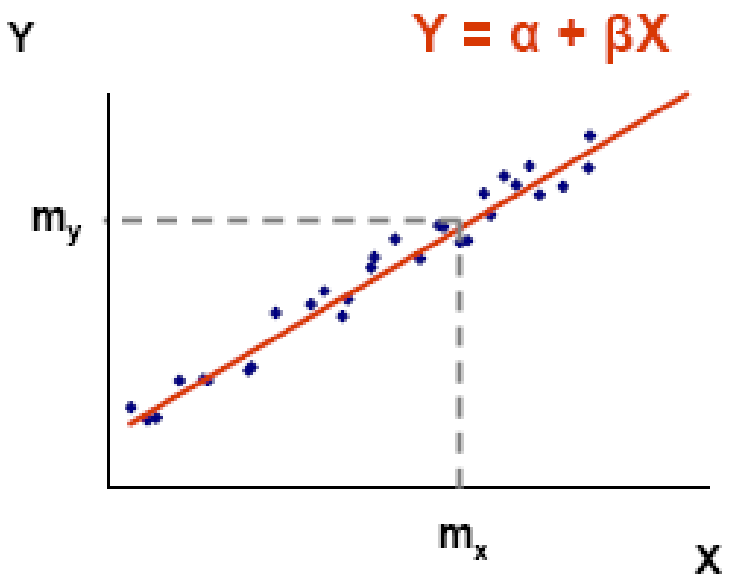
on calcule la somme des carrés des distances de chaque point à la droite. La droite de régression est la droite qui minimise la somme des carrés des écarts. Elle est aussi appelée droite des moindres carrés.



Une particularité de la droite de régression est de passer par le point moyen théorique de coordonnée (mx, my).

a et b sont les estimations de l'ordonnée à l'origine α et de la pente β de la droite de régression.

L'estimation de la pente de la droite de régression b est égale au rapport de la covariance de X et Y sur la variance de X.

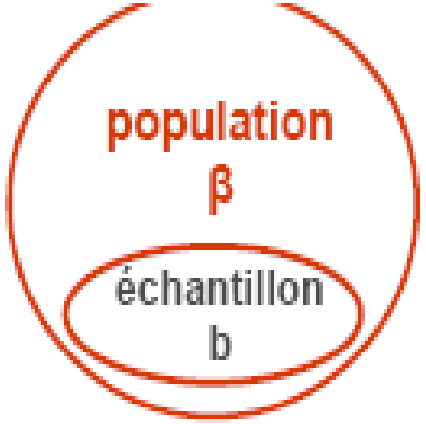


$$b = \frac{\mathrm{cov}(X, Y)}{\mathrm{var}(X)}$$

$$b = \frac{\sum_{i=1}^{n} (x_i - m_x)(y_i - m_y)}{\sum_{i=1}^{n} (x_i - m_x)^2}$$

III-3 Test de la pente de la droite de régression

$b \approx \beta$



La droite de régression d'équation $Y = \alpha + \beta X$ comporte 2 paramètres (α et β).

L'hypothèse nulle est que la pente β de la droite de Régression de Y en X est égale à 0 (soit Y est égal à α, c'est-à-dire que la droite de régression est horizontale et qu'il n'y a pas de liaison entre X et Y).

H_0 : $\beta = 0$ (droite de régression horizontale : $Y = \alpha$)

H_1: $\beta \neq 0$

Sous l'hypothèse nulle (H0) :

Le rapport de l'estimateur de la pente b sur son écart-type suit une loi de Student à (n-2) degrés de liberté.

n est l'effectif de l'échantillon.

$$\frac{b}{s_b} \rightarrow t_{(n-2)ddl}$$

L'estimateur de l'écart-type de la pente est égal à :

$$s_b = \sqrt{\frac{\frac{s_y^2}{s_x^2} - b^2}{n-2}}$$

Le test de la pente consiste à calculer la grandeur to et à la comparer à la valeur seuil tα sur la table de la loi de Student à (n-2) degrés de libertés

$$t_o = \frac{b}{\sqrt{\frac{\frac{s_y^2}{s_x^2} - b^2}{n-2}}}$$

- **Conditions d'application**
  - indépendance des observations
  - liaison linéaire entre X et Y
  - distribution conditionnelle normale et de variance constante

Corrélation et régression

	Corrélation	Régression
Variables	Quantitatives symétriques/asymétriques	Quantitatives asymétriques
Test	Coefficient de corrélation $-1 \leq r \leq 1$	Pente de la droite de régression
Prédiction	non	oui
Conditions	Indépendance des observations Liaison linéaire Distribution conditionnelle normale et de variance constante	

Les références:

- Schwartz D. Méthodes statistiques.1992
- Bouyer J. Méthodes statistiques.1996
- Ancelle T. Statistique Épidémiologie. Édition 2002
- Abrouk S. Biostatistique. INSP octobre 2005
- Mesli MF, Mokhtari A. Biostatistique. Édition mai 2007
- Causeur D. Régression linéaire. Laboratoire de Mathématiques Appliquées.Agrocampus Rennes
- Labarere J. Corrélation et régression

linéaire simple. Université Joseph Fourier de Grenoble. 2010-2011