Etude de deux Variables Statistiques

I.MEDKOUR,
Maitre assistant en épidémiologiste
Université Mira Abderrahmane,
Faculté de Médecine
CHU Bejaia

- si X et Y sont des variables **quantitatives discrètes** : x_i et y_j sont les valeurs prises.

- si X et Y sont des variables **quantitatives continues** : x_i et y_j désignent les centres des classes.

Principales caractéristiques

1. Moyennes des distributions

- Moyenne de X :

$$\mu(X) = \frac{1}{N} \sum_{i=1}^{k} n_{i\bullet} x_i$$

- Moyenne de Y :

$$\mu(Y) = \frac{1}{N} \sum_{j=1}^{\ell} n_{\bullet j} y_j$$

2. Variances des distributions

- Variance et écart-type de X :

$$V(X) = \left(\frac{1}{N} \sum_{i=1}^{k} n_{i\bullet} x_i^2 \right) - \mu(X)^2$$

$$\sigma(X) = \sqrt{V(X)}$$

- Variance et écart-type de Y :

$$V(Y) = \frac{1}{N} \sum_{j=1}^{\ell} n_{\bullet j} y_j^2 - \mu(Y)^2$$

$$\sigma(Y) = \sqrt{V(Y)}$$

Exemple

- Le tableau ci-dessous permet de suivre l'évolution de l'espérance de vie à la naissance (en années) de 1990 à 1999 pour les femmes:

Année	1990	1991	1992	1993	1994	1995	1996	1997	1998	1999
Espérance de vie	80,9	81,1	81,3	81,4	81,8	81,9	82,0	82,3	82,4	82,4

  - Population : les femmes.
  - Caractère n°1 : l'année.
  - Caractère n°2 : l'espérance de vie.

Représentation graphique

- On peut représenter la distribution du couple (X, Y) par un nuage de points de coordonnées (x_i, y_j),

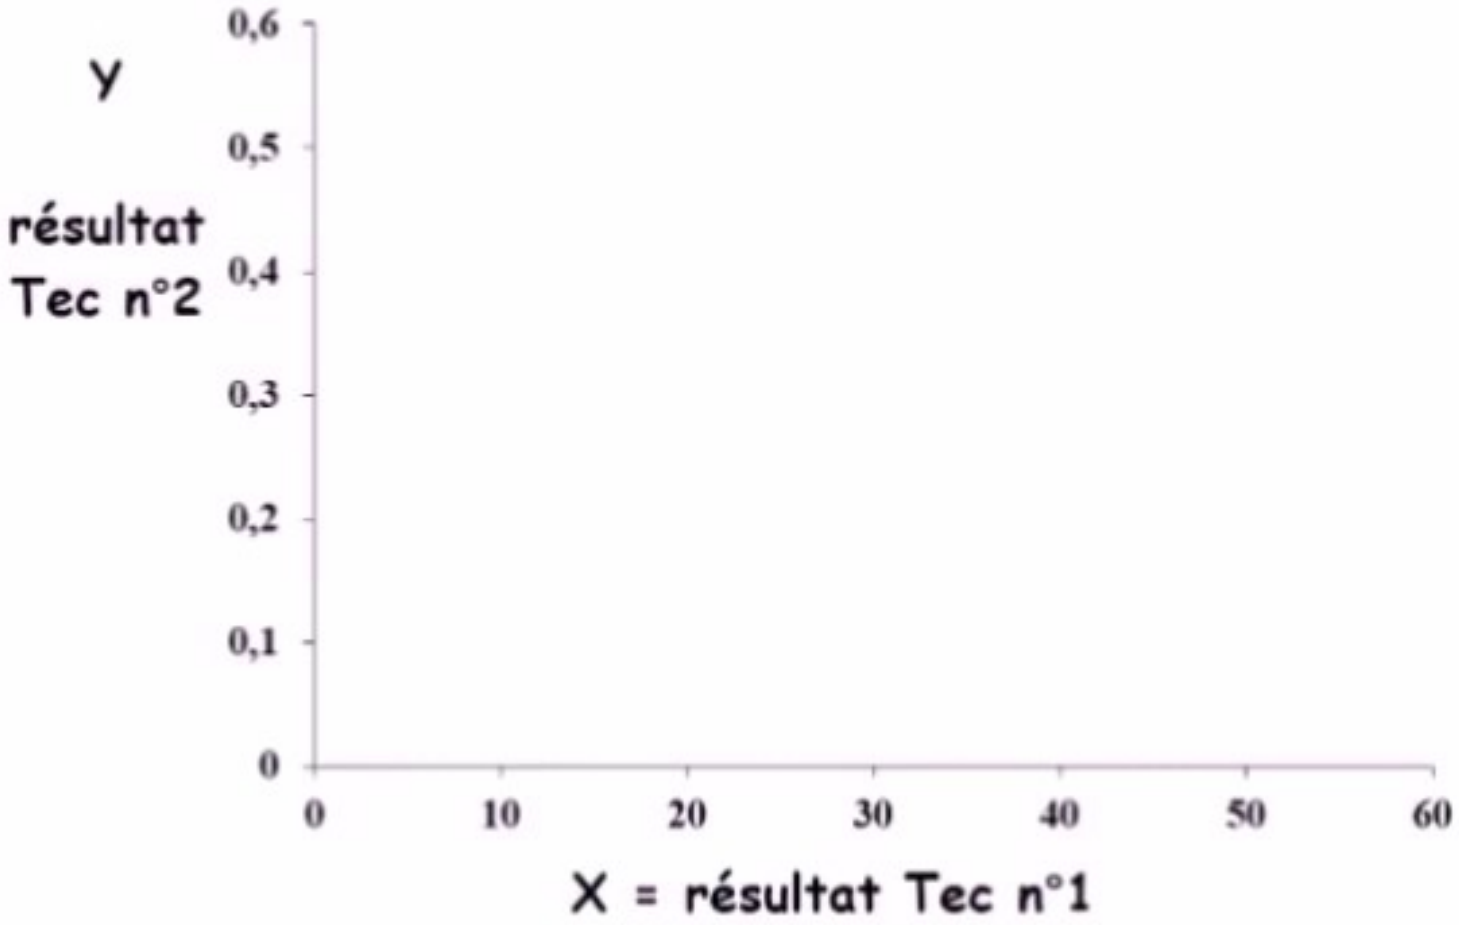
- chaque point étant affecte du “poids” n_{ij} .

- Le centre de gravité du nuage est alors le point de coordonnées (μ(X); μ(Y)).

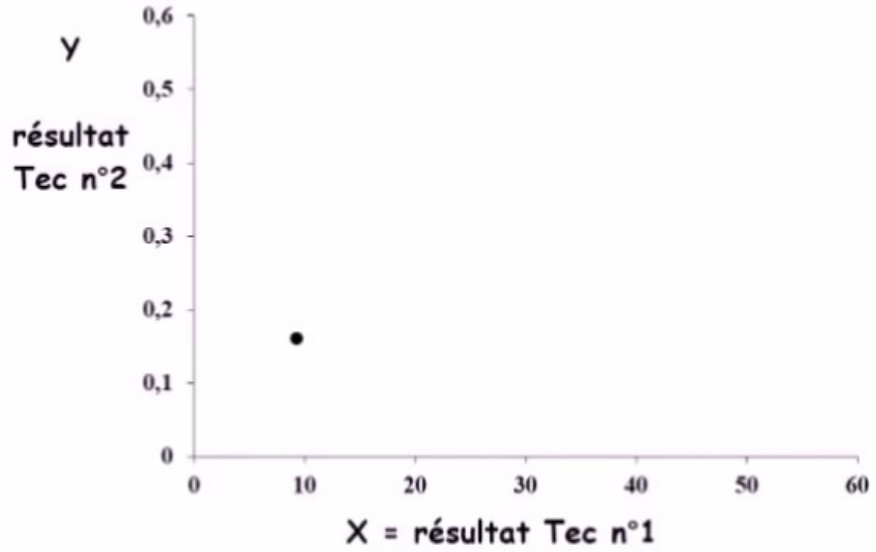
Dosage d'un paramètre biologique par les techniques n°1 et n°2

numéro sérum	résultat tec n°1	résultat tec n°2	numéro sérum	résultat tec n°1	résultat tec n°2	numéro sérum	résultat tec n°1	résultat tec n°2
1	9,30	0,16	11	28,00	0,36	21	36,00	0,28
2	13,00	0,18	12	28,20	0,18	22	38,00	0,34
3	14,40	0,17	13	29,30	0,28	23	40,00	0,37
4	16,00	0,12	14	31,50	0,22	24	41,70	0,31
5	16,60	0,14	15	32,00	0,33	25	42,00	0,44
6	20,00	0,23	16	32,50	0,42	26	44,00	0,42
7	22,00	0,32	17	33,30	0,32	27	44,00	0,40
8	22,80	0,20	18	34,40	0,38	28	47,00	0,40
9	25,10	0,35	19	34,80	0,40	29	48,50	0,43
10	27,80	0,29	20	35,20	0,25	30	50,20	0,44

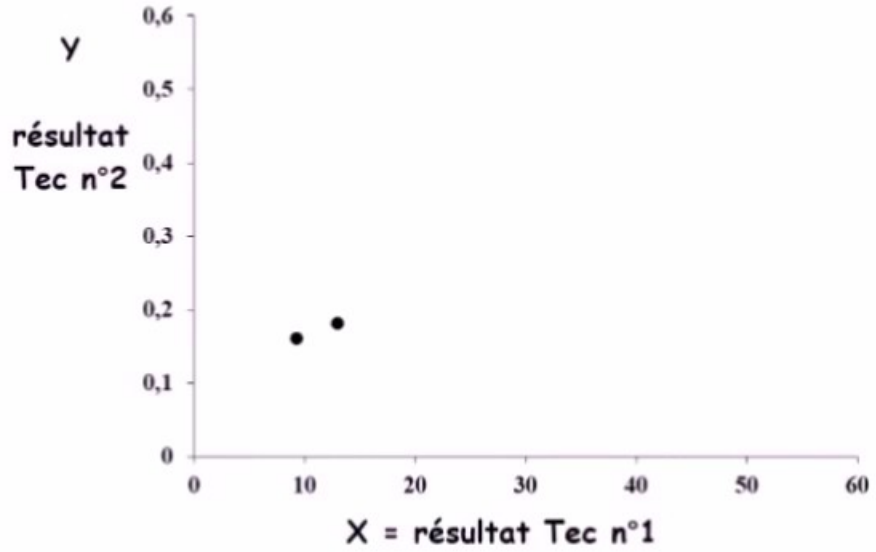
Représentation graphique des couples de résultats



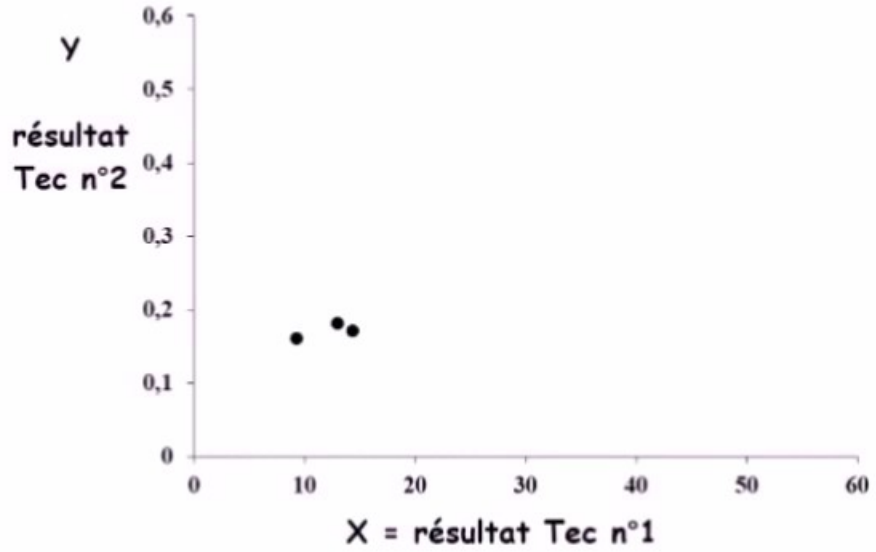
Représentation graphique des couples de résultats



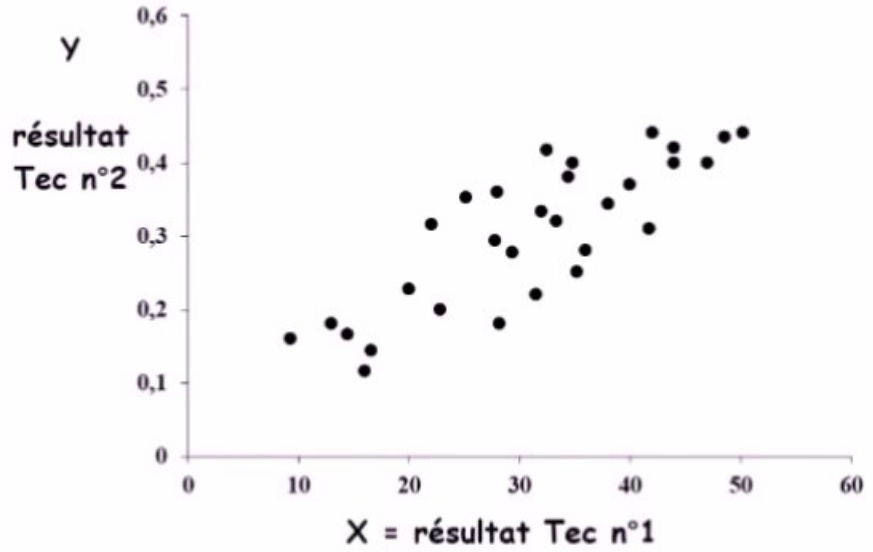
Représentation graphique des couples de résultats



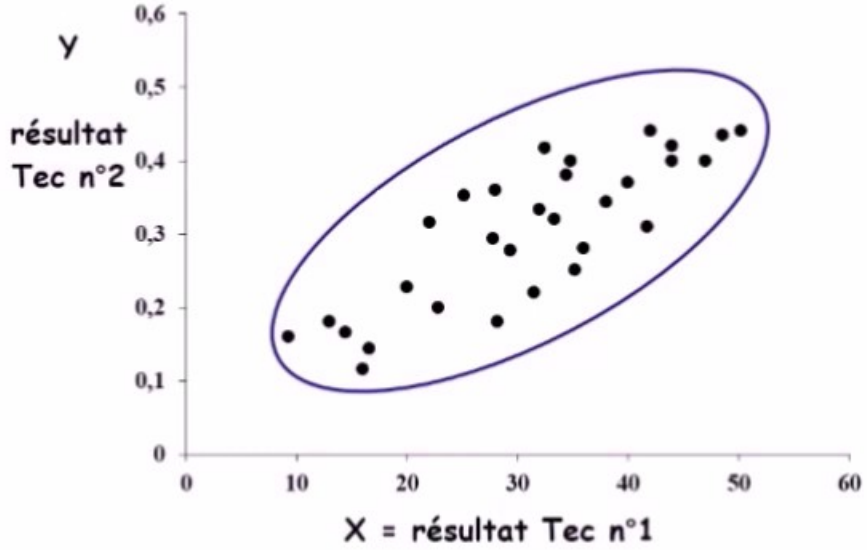
Représentation graphique des couples de résultats



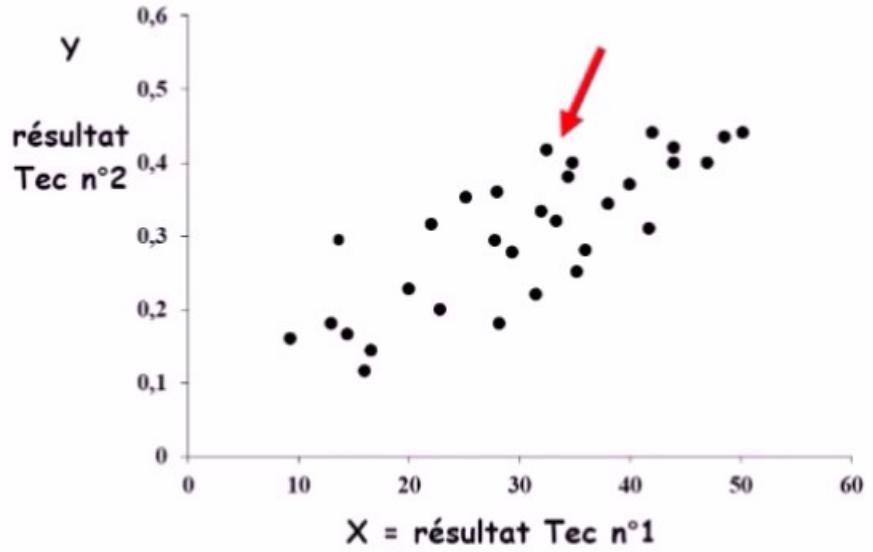
Représentation graphique des couples de résultats



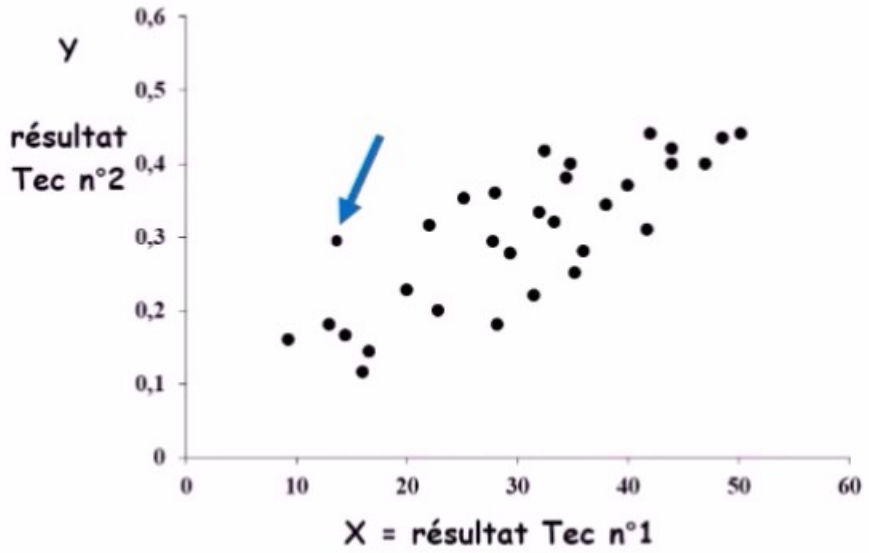
Représentation graphique des couples de résultats



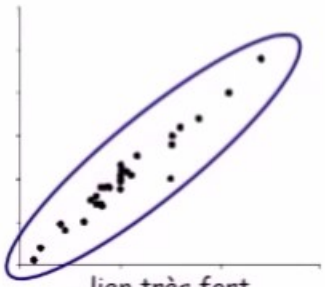
Interprétation visuelle d'un nuage de points



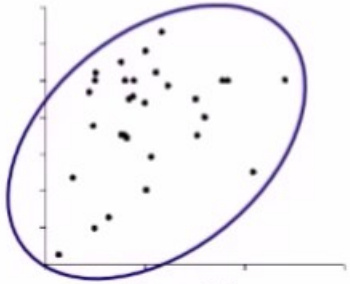
Interprétation visuelle d'un nuage de points



Interprétation visuelle d'un nuage de points

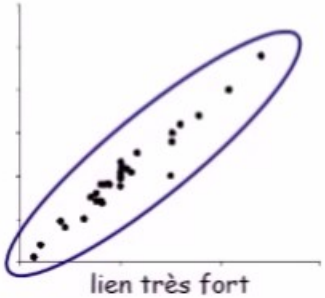


lien très fort

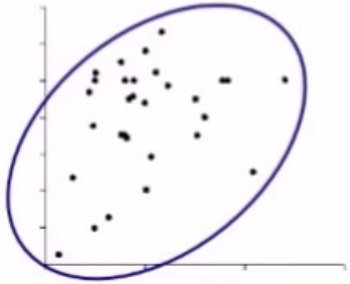


lien médiocre

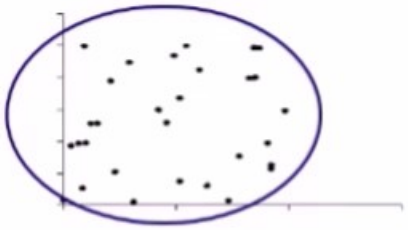
Interprétation visuelle d'un nuage de points



lien très fort

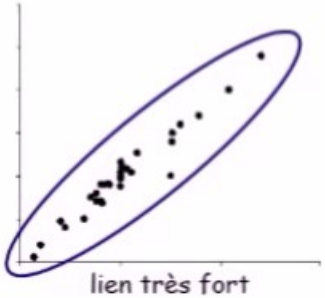


lien médiocre

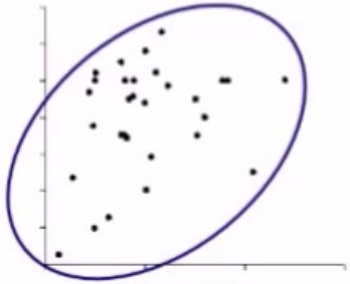


absence de lien

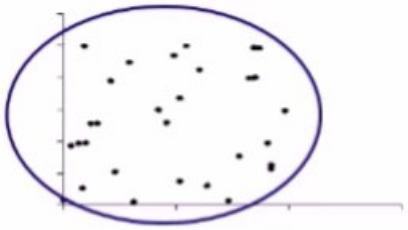
Interprétation visuelle d'un nuage de points



lien très fort



lien médiocre



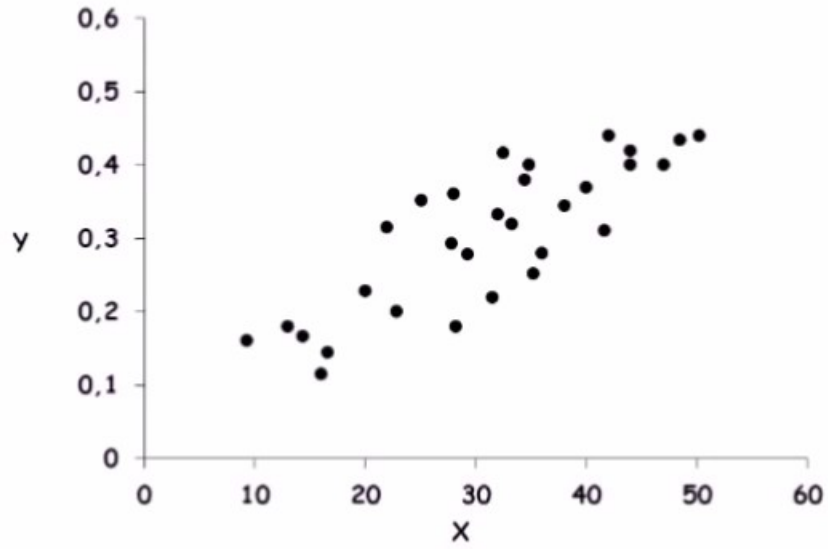
absence de lien



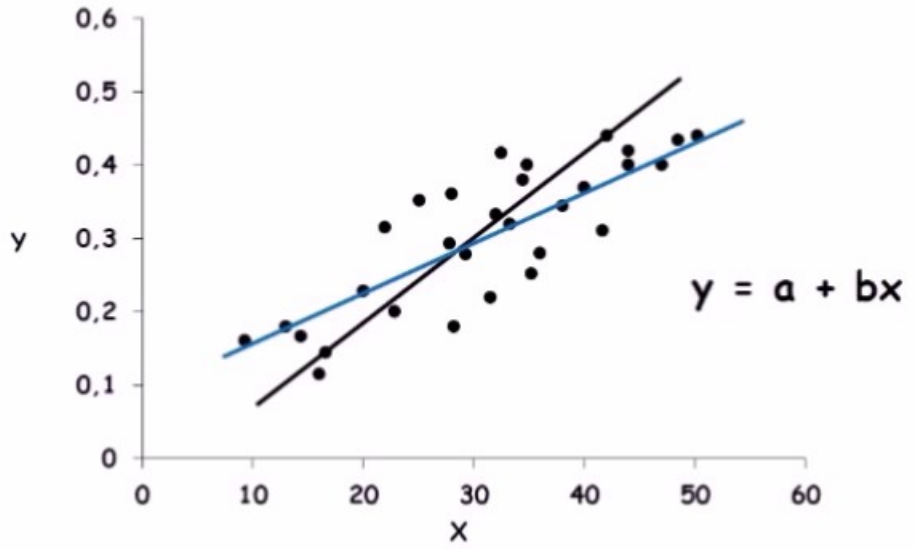
fort lien inversé

Mesure de la liaison entre deux variables quantitatives

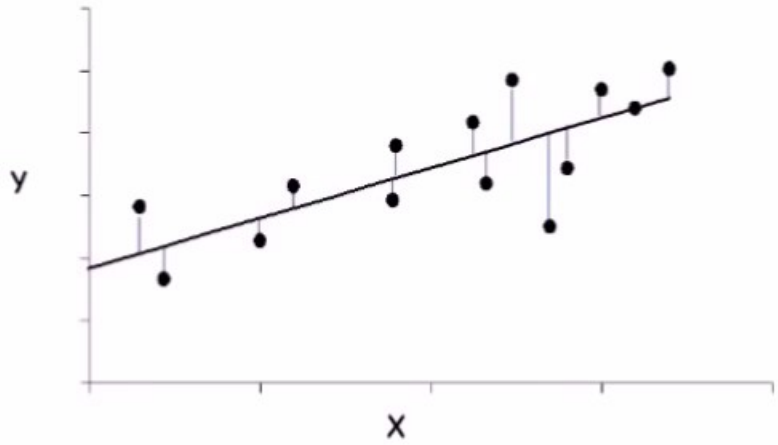
Tracé d'une droite



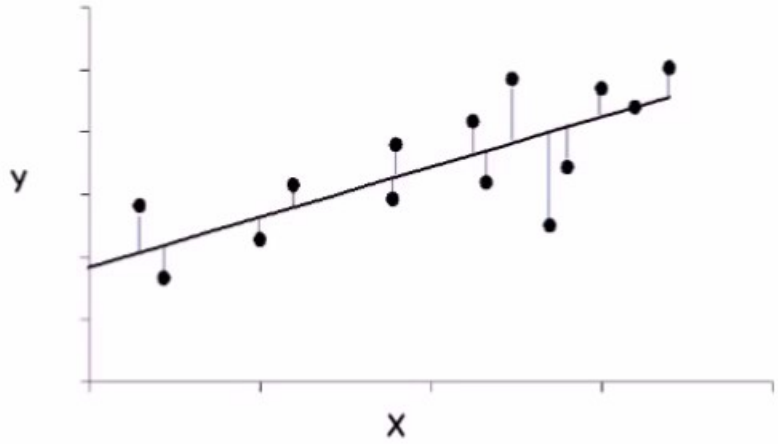
Tracé d'une droite



Droite des moindres carrés



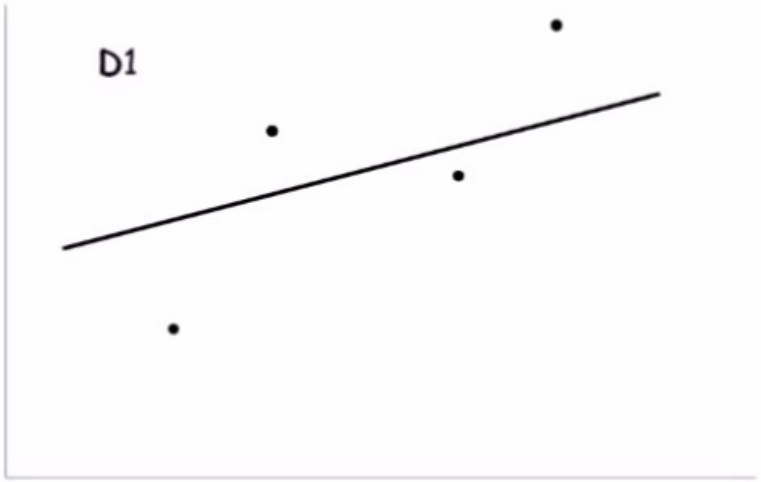
Droite des moindres carrés



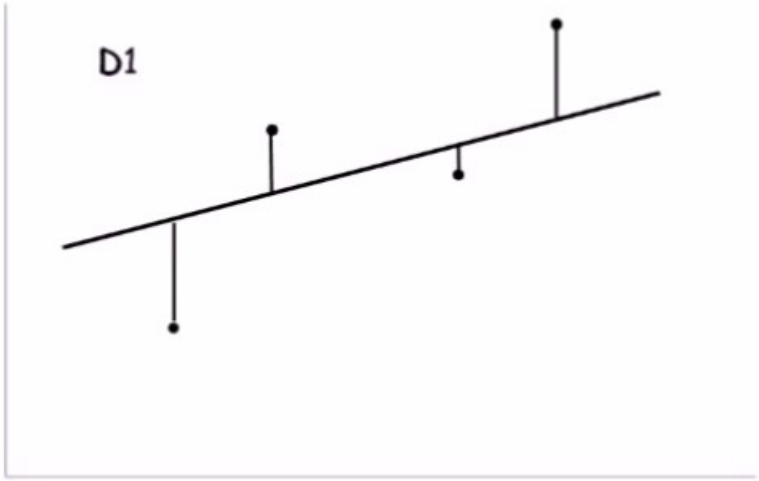
Recherche de la droite des moindres carrés



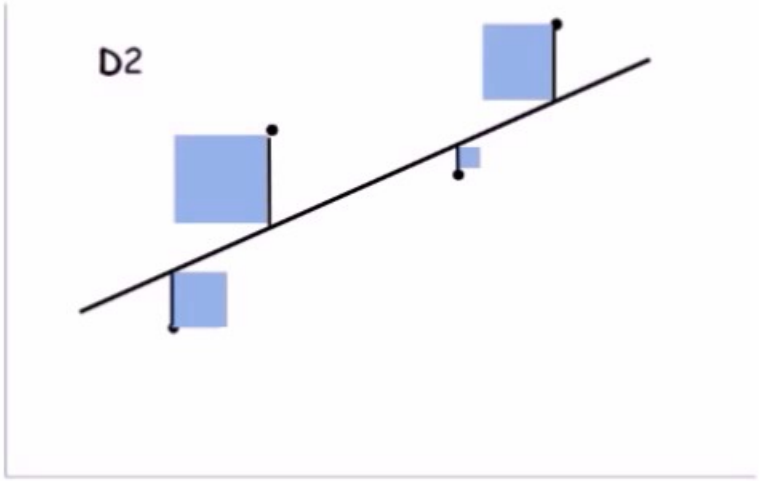
Recherche de la droite des moindres carrés



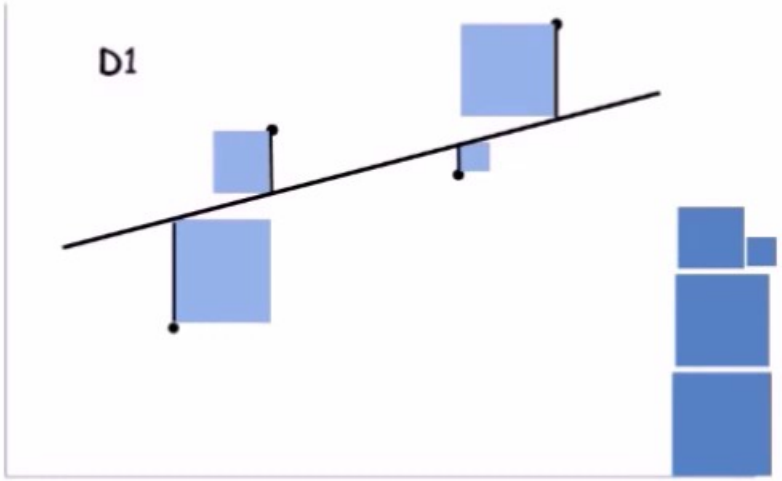
Recherche de la droite des moindres carrés



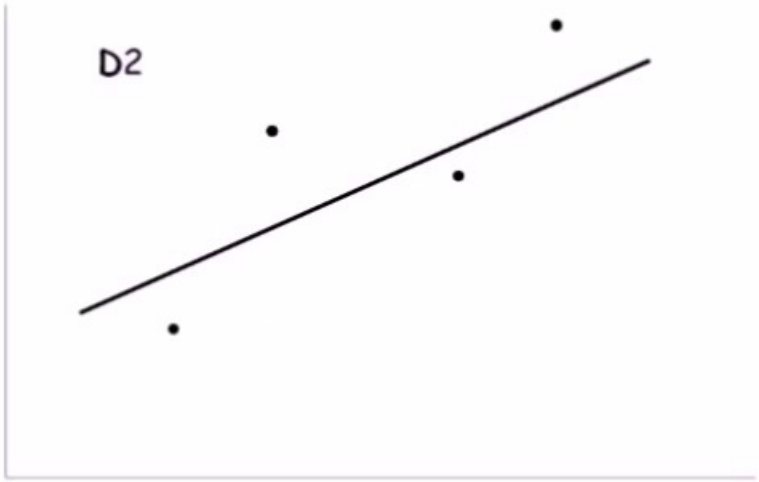
Recherche de la droite des moindres carrés



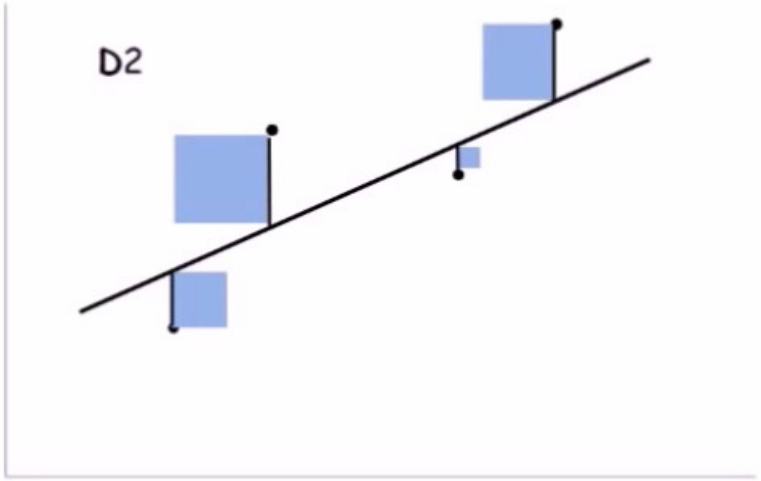
Recherche de la droite des moindres carrés



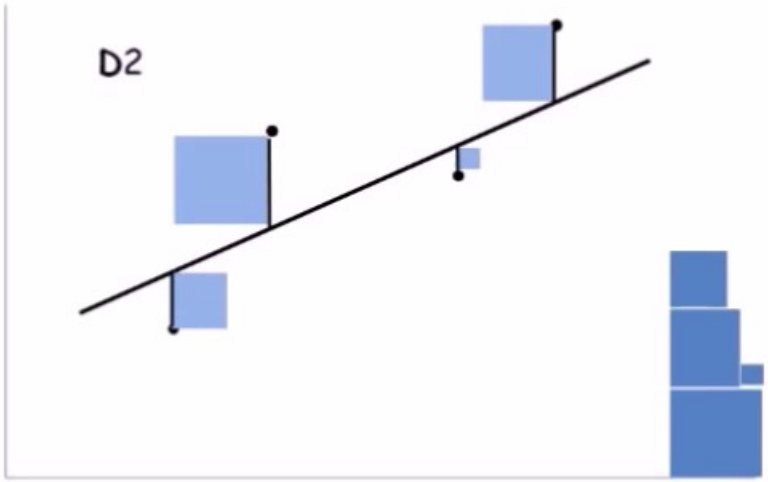
Recherche de la droite des moindres carrés



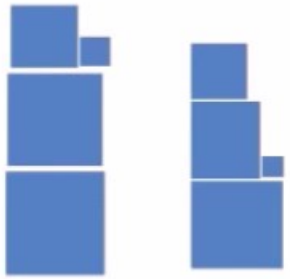
Recherche de la droite des moindres carrés



Recherche de la droite des moindres carrés



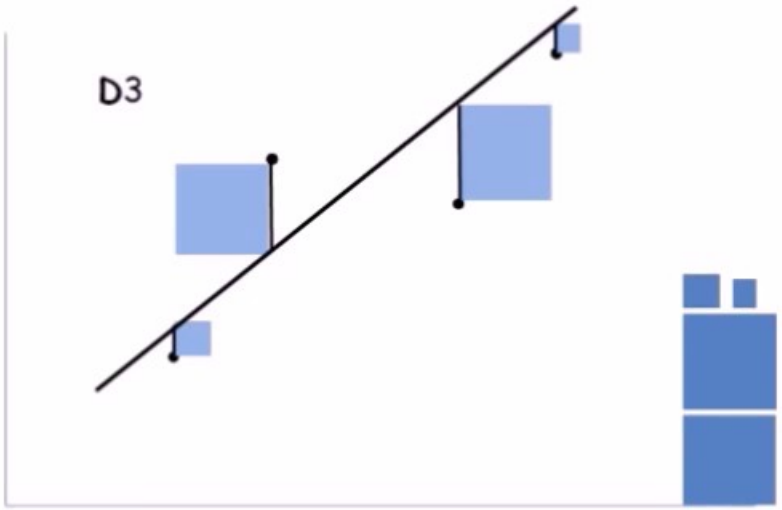
Recherche de la droite des moindres carrés



D1

D2

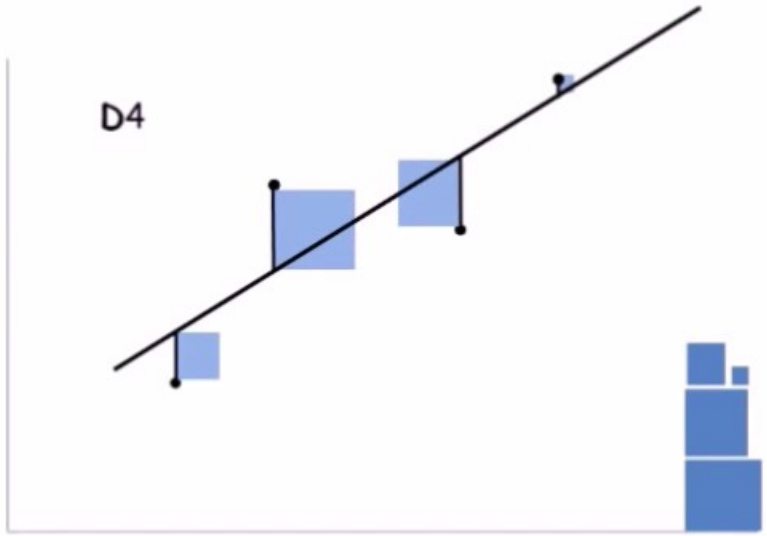
Recherche de la droite des moindres carrés



Recherche de la droite des moindres carrés



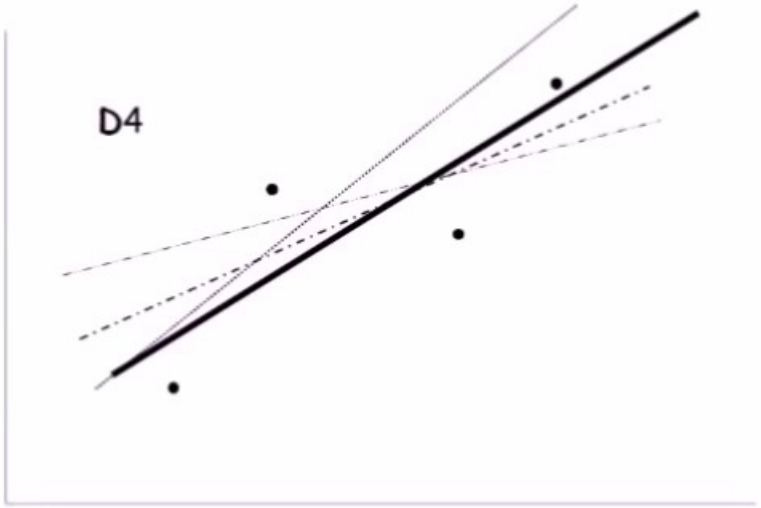
Recherche de la droite des moindres carrés



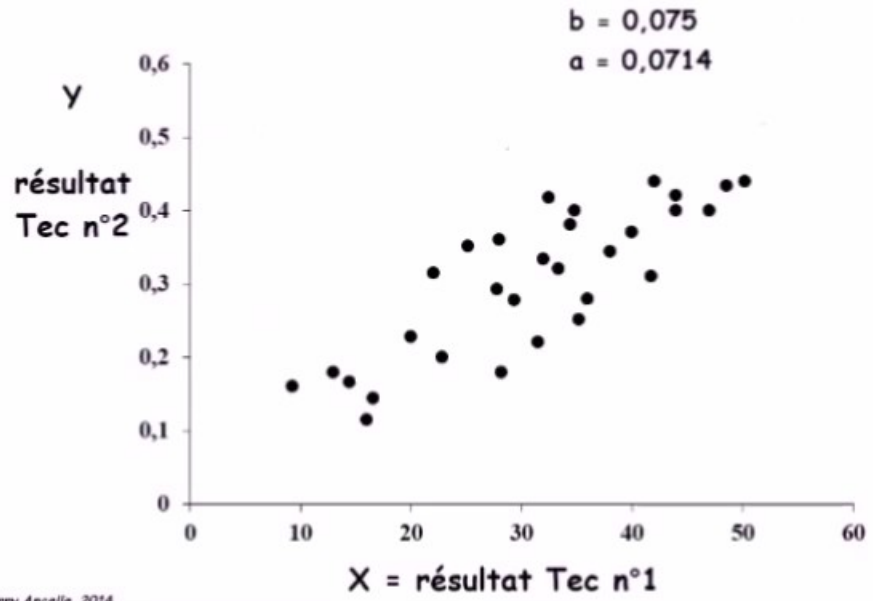
Recherche de la droite des moindres carrés



Droite des moindres carrés

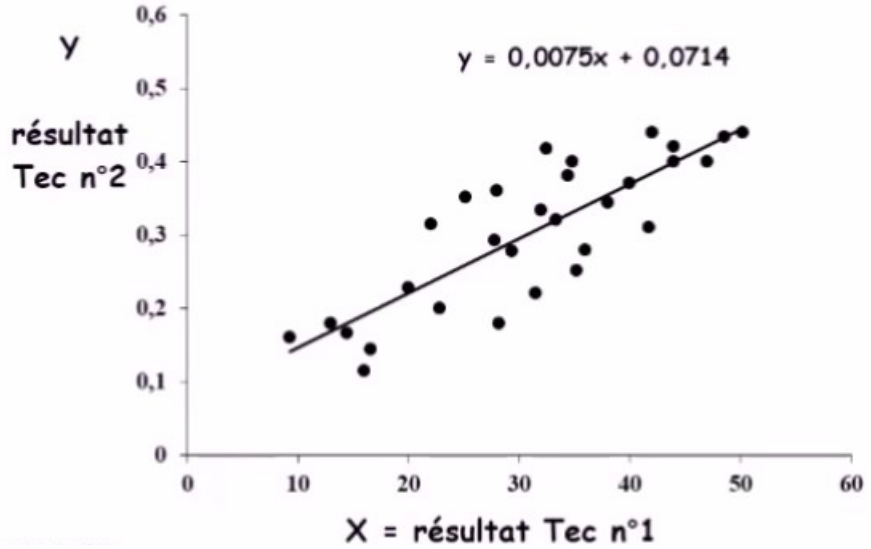


Droite des moindres carrés



© Thierry Agnelle, 2014

Droite des moindres carrés



Coefficient de corrélation

de Pearson ou de Bravais-Pearson

Coefficient de corrélation : r

$$r = \frac{\sum (x - m_x)(y - m_y)}{\sqrt{\sum (x - m_x)^2 \sum (y - m_y)^2}}$$

Coefficient de corrélation : r

$$r = \frac{\sum (x - m_x)(y - m_y)}{\sqrt{\sum (x - m_x)^2 \sum (y - m_y)^2}}$$

$$\text{Var } X = \frac{\sum (x - m_x)^2}{n - 1}$$

Coefficient de corrélation : r

$$r = \frac{\sum (x - m_x)(y - m_y)}{\sqrt{\sum (x - m_x)^2 \sum (y - m_y)^2}}$$

$$\text{Var } X = \frac{\sum (x - m_x)^2}{n - 1} \quad \text{Var } Y = \frac{\sum (y - m_y)^2}{n - 1}$$

Coefficient de corrélation : r

$$\text{Covariance XY} = \frac{\sum(x - m_x)(y - m_y)}{n - 1}$$

$$r = \frac{\sum(x - m_x)(y - m_y)}{\sqrt{\sum(x - m_x)^2 \sum(y - m_y)^2}}$$

$$\text{Var X} = \frac{\sum(x - m_x)^2}{n - 1} \quad \text{Var Y} = \frac{\sum(y - m_y)^2}{n - 1}$$

Coefficient de corrélation

$$r = \frac{\text{covariance } XY}{\sqrt{\text{var } X \text{ var } Y}}$$

Coefficient de corrélation formule simplifiée !

$$r = \frac{\sum xy - \frac{\sum x \sum y}{n}}{\sqrt{\left[\sum x^2 - \frac{(\sum x)^2}{n}\right]\left[\sum y^2 - \frac{(\sum y)^2}{n}\right]}}$$

Coefficient r avec Excel

	A	B
1	tec n°1	tec n°2
2	9,3	0,16
3	13	0,18
4	14,4	0,166
5	16	0,115
6	16,6	0,144
7	20	0,228
8	22	0,315
9	22,8	0,2
10	25,1	0,352
11	27,8	0,293
12	28	0,36
13	28,2	0,18
14	29,3	0,278
15	31,5	0,22
16	32	0,333
17	32,5	0,417
18	33,3	0,32
19	34,4	0,38
20	34,8	0,4
21	35,2	0,251
22	36	0,28
23	38	0,344
24	40	0,37
25	41,7	0,31
26	42	0,44
27	44	0,42
28	44	0,4
29	47	0,4
30	48,5	0,434
31	50,2	0,44
32		

Coefficient r avec Excel

	A	B
1	tec n°1	tec n°2
2	9,3	0,16
3	13	0,18
4	14,4	0,166
5	16	0,115
6	16,6	0,144
7	20	0,228
8	22	0,315
9	22,8	0,2
10	25,1	0,352
11	27,8	0,293
12	28	0,36
13	28,2	0,18
14	29,3	0,278
15	31,5	0,22
16	32	0,333
17	32,5	0,417
18	33,3	0,32
19	34,4	0,38
20	34,8	0,4
21	35,2	0,251
22	36	0,28
23	38	0,344
24	40	0,37
25	41,7	0,31
26	42	0,44
27	44	0,42
28	44	0,4
29	47	0,4
30	48,5	0,434
31	50,2	0,44
32		

=COEFFICIENT.CORRELATION (A2:A31;B2:B31)

Coefficient r avec Excel

	A	B
1	tec n°1	tec n°2
2	9,3	0,16
3	13	0,18
4	14,4	0,166
5	16	0,115
6	16,6	0,144
7	20	0,228
8	22	0,315
9	22,8	0,2
10	25,1	0,352
11	27,8	0,293
12	28	0,36
13	28,2	0,18
14	29,3	0,278
15	31,5	0,22
16	32	0,333
17	32,5	0,417
18	33,3	0,32
19	34,4	0,38
20	34,8	0,4
21	35,2	0,251
22	36	0,28
23	38	0,344
24	40	0,37
25	41,7	0,31
26	42	0,44
27	44	0,42
28	44	0,4
29	47	0,4
30	48,5	0,434
31	50,2	0,44
32		

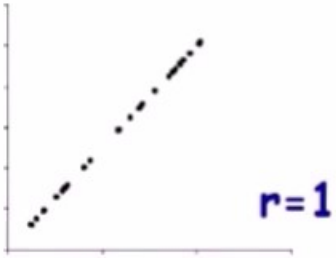
=COEFFICIENT.CORRELATION (A2:A31;B2:B31)

r = 0,83

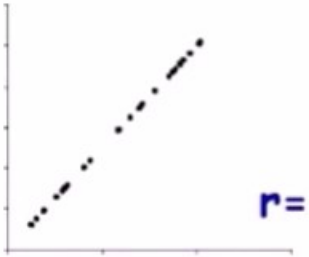
Interprétation d'un coefficient de corrélation

Interprétation d'un coefficient de corrélation

$$-1 \leq r \leq +1$$

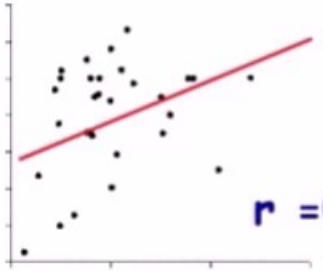


Corrélation parfaite



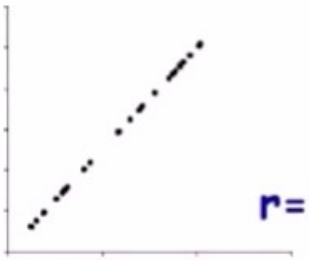
r=1

Corrélation parfaite



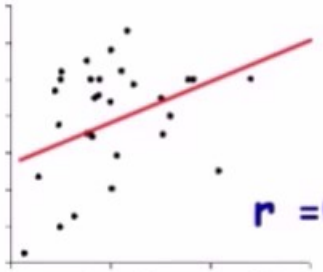
r =0,4

Corrélation médiocre



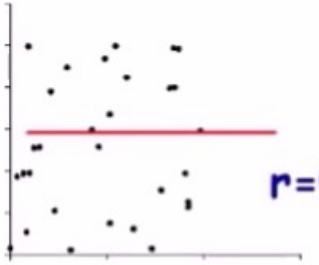
r=1

Corrélation parfaite



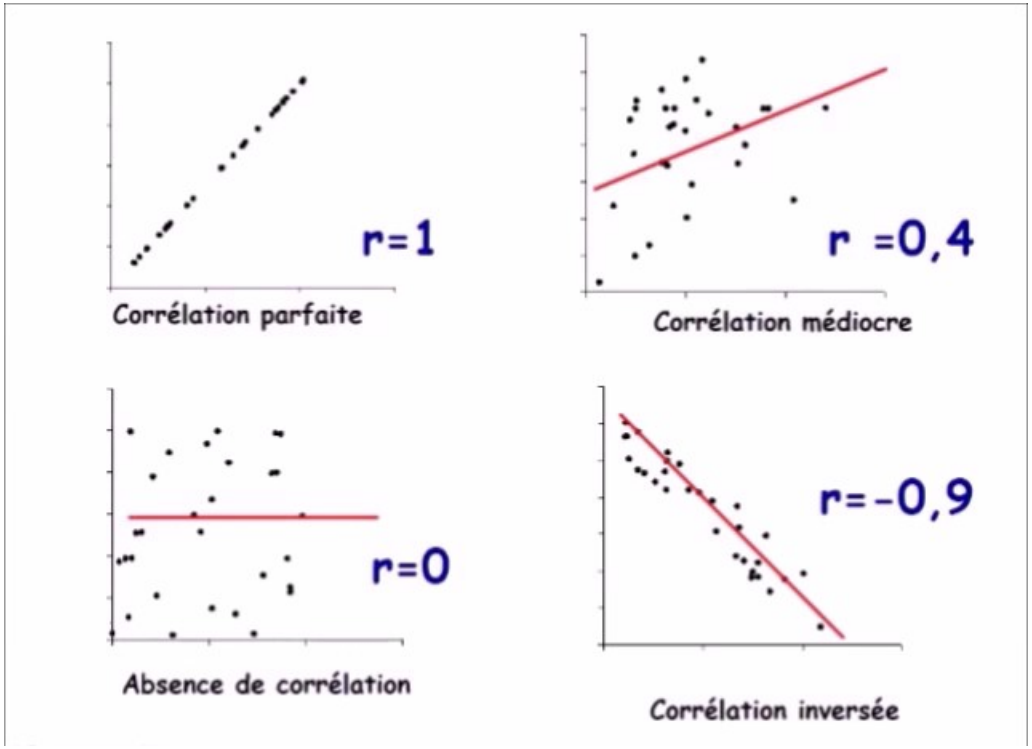
r =0,4

Corrélation médiocre



r=0

Absence de corrélation


r=1
Corrélation parfaite
r =0,4
Corrélation médiocre
r=0
Absence de corrélation
r=-0,9
Corrélation inversée

- Le coefficient de corrélation est un coefficient sans dimension.
- Il mesure la présence et l'intensité de la liaison linéaire entre X et Y

1. Corr (X, Y) = 1 : liaison linéaire exacte Y = aX + b avec a > 0 ;
2. Corr (X, Y) = −1 : liaison linéaire exacte, Y = aX + b avec a < 0 ;
3. Corr (X, Y) = 0 : non corrélation : on a indépendance possible, mais non certaine ;
4. Corr (X, Y) > 0 : liaison relative, X et Y ont tendance `a varier dans le meme sens ;
5. Corr (X, Y) < 0 : liaison relative, X et Y ont tendance à varier dans le sens contraire ;
6. Corr (X, Y)| > 0.9 (0.75) la liaison linéaire est considérée comme très forte.

Détermination des coefficients

$$a = \frac{\mathrm{cov}(X,Y)}{V(X)} = \frac{\sigma_{XY}}{{\sigma_X}^2}$$

$$b = \overline{y} - a\overline{x}$$

$$\sigma_{xy} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})$$

$$\sigma_{xy} = \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \overline{x}\cdot\overline{y}$$

Conclusion

- Réviser vos cours et rester à jours vous permettra de mieux assimiler le contenu