ANALYSE DE DONNEES
TESTS D'ASSOCIATION

Dr Houda Boukheris

Faculté de Médecine de Béjaïa

Existence d'une association significative d'indépendance: le test du Khi-deux

- Le test du **Khi-deux** est couramment utilisé. Il cherche à tester si deux variables qualitatives sont significativement associées.
- C'est l'indépendance des variables qualitatives, présentées dans un tableau croisé, qui est testée.
- On cherche à vérifier si l'association des deux variables est suffisamment forte pour que l'hypothèse de leur indépendance puisse être rejetée.
- Le principe est de comparer la distribution observée (les effectifs que l'on peut lire dans le tableau croisé), à une distribution théorique, qui correspond à l'hypothèse selon laquelle les deux variables sont indépendantes.

Exemple de calcul de la « distribution théorique »

	Possèdent une carte fidélité	Ne possèdent pas de carte fidélité	Total
Hommes	100	100	200
Femmes	200	200	400
Total	300	300	600

Calculer les fréquences théoriques

	Possèdent une carte fidélité	Possèdent pas de carte fidélité	Total
Hommes	250	750	1 000
Femmes	150	450	600
Total	400	1 200	1 600

25% des clients possèdent une carte fidélité

Procédure de test

On pose l'hypothèse nulle :

H_0 : Il n'y a pas de relation entre les deux variables.

$H_{1\,;}$ Il existe une relation statistiquement significative entre les deux variables.

On rejette l'hypothèse nulle (on conclut que la relation existe dans la population) si :

$$\chi^2 > \chi^2_{0,05\ [(r\text{-}1)(c\text{-}1)]}$$

- *On rejettera l'hypothèse nulle d'indépendance entre les variables si le χ^2 calculé est supérieur à la valeur de référence du χ^2 se trouvant dans la table de χ^2 pour n degrés de liberté (en lignes dans la table) et pour un (niveau de risque de se tromper en rejetant l'hypothèse nulle donné en colonnes, fixé généralement à 5%.*

$$\chi^2 > \chi^2_{0,05\ [(r-1)(c-1)]}$$

- *H0 : Il n'y a pas de relation entre les deux variables.*

• *Les logiciels statistiques donnent une signification ou p-value, s'interprétant comme le niveau risque de se tromper* H_0

•*Ainsi, si elle est inférieure à 5 %, on rejette l'hypothèse d'indépendance entre les deux variables, qui sont alors significativement associées.*

•*Il est important de noter que ce test est assez sensible à la taille de l'échantillon, à la taille du tableau croisé et que, normalement, chaque case*

- *Le test d'indépendance du khi-carré (l'écriture anglaise est « chi-square ») a été développé par Karl PEARSON (1857-1936). L'expression test du khi-carré recouvre plusieurs tests statistiques*

  - *Le test d'ajustement ou d'adéquation, qui compare globalement la distribution observée dans un échantillon statistique à une distribution théorique, celle du khi-carré.*

  - *Le test d'indépendance du khi-carré qui permet de contrôler l'indépendance de deux caractères dans une population donnée.*

  - *Le test d'homogénéité du khi-carré qui teste si des échantillons sont issus d'une même population.*

- *Le test qui nous intéresse ici est uniquement le test d'indépendance du khi-carré. Ce test sert à apprécier l'existence ou non d'une relation entre deux caractères au sein d'une population, lorsque ces caractères sont qualitatifs où lorsqu'un caractère est quantitatif et l'autre qualitatif, ou bien encore lorsque les deux caractères sont quantitatifs mais que les valeurs ont été regroupées.*

- *Ce test permet de contrôler l'existence d'une dépendance mais en aucun cas le sens de cette dépendance*

  - *Sauf dans certains cas particuliers où l'existence d'une relation implique une causalité univoque.*

Etapes d'application du test de khi-deux de contingence

- *Vérifier si le test de khi-deux est applicable sur le tableau.*
- *Si oui, formuler l'hypothèse d'indépendance : "On formule l'hypothèse qu'il y a une relation d'indépendance entre les lignes et les colonnes du tableau".*
- *Calculer l'indicateur de khi-deux en calculant le tableau des effectifs théorique et le tableau des écarts à l'indépendance.*
- *Confronter l'indicateur de khi-deux à la table de loi de khi-deux ce qui nous permet d'accepter ou de rejeter l'hypothèse d'indépendance.*
- *Interpréter les résultats du test en examinant le tableau d'origine (ou tableau des effectifs observés), le tableau des effectifs théoriques et le tableau des écarts à l'indépendance*

- *Voici notre tableau de départ intitulé "Faites-vous faire des recherches sur internet à vos élèves ?". L'effectif total est de 179 observations, chaque case du tableau a plus de 5 observations, les conditions d'applications du test de khi deux de contingence sont donc réunis*

	oui	non
disciplines dominantes	68	60
disciplines secondaires	37	14

- *Formulons l'hypothèse d'indépendance : il y a indépendance entre les lignes et les colonnes de ce tableau.*
- *Notre hypothèse est : "Dans cet échantillon de réponses à un questionnaire, il n'y a pas de lien statistique significatif entre l'utilisation d'internet par les élèves et la discipline enseignée".*
- *Ajoutons à ce tableau une ligne et une colonne de totaux.*
- *La lig[illegible]harges du table*

	oui	non	total
disciplines dominantes	68	60	128
disciplines secondaires	37	14	51
total	105	74	179

- *Calculons le tableau des effectifs théoriques ou tableau d'indépendance que l'on appelle. Ce calcul s'effectue grâce aux marges du tableau.*

	oui	non	total
disciplines dominantes	75,1	52,9	128
disciplines secondaires	29,9	21,1	51
total	105	74	179

- *On calcule l'effectif théorique de chaque case du tableau en multipliant les totaux qui lui correspondent et en divisant par l'effectif total.*
- *Ainsi pour la première case du tableau on multiplie le nombre total d'enseignants appartenant à une discipline dominante (128) par le nombre total de réponses "oui" (105) divisé par l'effectif total (179)*
- *Pour la deuxième case du tableau (celle des enseignants appartenant à une discipline dominante ayant répondu non) on fait la même chose:*

$$\frac{128 \times 105}{179} = 75,1$$

- *On obtient ainsi le tableau des effectifs théoriques ou tableau d'indépendance.*

- *Le tableau des effectifs théoriques ou d'indépendance représente une distribution équiprobable c'est à dire la distribution pour laquelle il n'y a aucun lien statistique entre les deux variables. Nous allons comparer ce tableau à notre tableau*

	oui	non
disciplines dominantes	68-75,1	60-52,9
disciplines secondaires	37-29,9	14-21,1

- *Une fois le ca* *st le suivant :*

	oui	non
disciplines dominantes	-7,1	7,1
disciplines secondaires	7,1	-7,1

- *On va ensuite* *pour obtenir le tableau*

	oui	non
disciplines dominantes	50,2	50,2
disciplines secondaires	50,2	50,2

- *Enfin on divise termes à termes le tableau par le tableau des effectifs théoriques*

$$\chi^2 = \sum \frac{R^2}{T_0}$$

	oui	non
disciplines dominantes	50,2/75,1	50,2/52,9
disciplines secondaires	50,2/29,9	50,2/21,1

- *On remet ensuite les colonnes de totaux pour obtenir le tableau suivant :*

	oui	non	total
disciplines dominantes	0,668	0,948	1,61
disciplines secondaires	1,67	2,38	4,05
total	2,34	3,32	5,67=indicateur du khi deux

- *L'indicateur du khi deux est le total de ce tableau soit 5,67. On appelle ce tableau, le tableau des écarts à l'indépendance* ($\frac{R^2}{T_0}$).

- **Interprétation de l'indicateur de khi-deux : Table de loi de**

Table de la loi de khi-deux ou de Karl Pearson

Valeur de khi-deux pour laquelle la probabilité d'une valeur inférieure à khi-deux suivant le nombre n de degrés de liberté est $p = F_n(\chi^2)$

Pour un test de khi deux de contingence le nombre de degrés de liberté n de votre tableau est égal a (nombre de lignes - 1) x (nombre de colonnes - 1)

n\p	0,005	0,010	0,025	0,050	0,100	0,250	0,500	0,750	0,900	0,950	0,975	0,990	0,995
1	0,0000	0,0002	0,0010	0,0039	0,0158	0,102	0,455	1,32	2,71	3,84	5,02	6,63	7,88
2	0,0100	0,0201	0,0506	0,103	0,211	0,575	1,39	2,77	4,61	5,99	7,38	9,21	10,6
3	0,0717	0,115	0,216	0,352	0,584	1,21	2,37	4,11	6,25	7,81	9,35	11,3	12,8
4	0,207	0,297	0,484	0,711	1,06	1,92	3,36	5,39	7,78	9,49	11,1	13,3	14,9
5	0,412	0,554	0,831	1,15	1,61	2,67	4,35	6,63	9,24	11,1	12,8	15,1	16,7
6	0,676	0,872	1,24	1,64	2,20	3,45	5,35	7,84	10,6	12,6	14,4	16,8	18,5
7	0,989	1,24	1,69	2,17	2,83	4,25	6,35	9,04	12,0	14,1	16,0	18,5	20,3
8	1,34	1,65	2,18	2,73	3,49	5,07	7,34	10,2	13,4	15,5	17,5	20,1	22,0
9	1,73	2,09	2,70	3,33	4,17	5,90	8,34	11,4	14,7	16,9	19,0	21,7	23,6
10	2,16	2,56	3,25	3,94	4,87	6,74	9,34	12,5	16,0	18,3	20,5	23,2	25,2
11	2,60	3,05	3,82	4,57	5,58	7,58	10,3	13,7	17,3	19,7	21,9	24,7	26,8
12	3,07	3,57	4,40	5,23	6,30	8,44	11,3	14,8	18,5	21,0	23,3	26,2	28,3
13	3,57	4,11	5,01	5,89	7,04	9,30	12,3	16,0	19,8	22,4	24,7	27,7	29,8
14	4,07	4,66	5,63	6,57	7,79	10,2	13,3	17,1	21,1	23,7	26,1	29,1	31,3
15	4,60	5,23	6,26	7,26	8,55	11,0	14,3	18,2	22,3	25,0	27,5	30,6	32,8
16	5,14	5,81	6,91	7,96	9,31	11,9	15,3	19,4	23,5	26,3	28,8	32,0	34,3
17	5,70	6,41	7,56	8,67	10,1	12,8	16,3	20,5	24,8	27,6	32,0	33,4	35,7
18	6,26	7,01	8,23	9,39	10,9	13,7	17,3	21,6	26,0	28,9	31,5	34,8	37,2
19	6,84	7,63	8,91	10,1	11,7	14,6	18,3	22,7	27,2	30,1	32,9	36,2	38,6
20	7,43	8,26	9,56	10,9	12,4	15,5	19,3	23,8	28,4	31,4	34,2	37,6	40,0
21	8,03	8,90	10,3	11,6	13,2	16,3	20,3	24,9	29,6	32,7	35,5	38,9	41,4
22	8,64	9,54	11,0	12,3	14,0	17,2	21,3	26,0	30,8	33,9	36,8	40,3	42,8
23	9,26	10,2	11,7	13,1	14,8	18,1	22,3	27,1	32,0	35,2	38,1	41,6	44,2
24	9,89	10,9	12,4	13,8	15,7	19,0	23,3	28,2	33,2	36,4	39,4	43,0	45,6
25	10,5	11,5	13,1	14,6	16,5	19,9	24,3	29,3	34,4	37,7	40,6	44,3	46,9
26	11,2	12,2	13,8	15,4	17,3	20,8	25,3	30,1	35,6	38,9	41,9	45,6	48,3
27	11,8	12,9	14,6	16,2	18,1	21,7	26,3	31,5	36,7	40,1	43,2	47,0	49,6
28	12,5	13,6	15,3	16,9	18,9	22,7	27,3	32,6	37,9	41,3	44,5	48,3	51,0
29	13,1	14,3	16,0	17,7	19,8	23,6	28,3	33,7	39,1	42,6	45,7	49,6	52,3
30	13,8	15,0	16,8	18,5	20,6	24,5	29,3	34,8	40,3	43,8	47,0	50,9	53,7
40	20,7	22,2	24,4	26,5	29,1	33,7	39,3	45,6	51,8	55,8	59,3	63,7	66,8
50	28,0	29,7	32,4	34,8	37,7	42,9	49,3	56,3	63,2	67,5	71,4	76,2	79,5
60	35,5	37,5	40,5	43,2	46,5	52,3	59,3	67,0	74,4	79,1	83,3	88,4	92,0
70	43,3	45,4	48,8	51,7	55,3	61,7	69,3	77,6	85,5	90,5	95,0	100,4	104,2
80	51,2	53,5	57,2	60,4	64,3	71,1	79,3	88,1	96,6	101,9	106,6	112,4	116,3
90	59,2	61,8	65,6	69,1	73,3	80,6	89,3	98,6	107,6	113,1	118,1	124,1	128,3
100	67,3	70,1	74,2	77,9	82,4	90,1	99,3	109,1	118,5	124,3	129,6	135,8	140,2

- ***Qu'est ce que cette table ?***
  - *C’est un moyen d'évaluer la "rareté" de notre indicateur de khi-deux en fonction du nombre de lignes et de colonnes de notre tableau.*
    - *En colonne figure une probabilité, c'est la "rareté" d'un indicateur de khi-deux et c'est ce que nous cherchons à évaluer au travers du test de khi-deux d'indépendance*
    - *Cette table va nous permettre de trouver une probabilité d'acceptation de l'hypothèse d'indépendance en fonction de notre indicateur de khi deux.*
- ***Qu'est ce que l'hypothèse d'indépendance ?***
  - *Lorsque l'on réalise notre test, on fait l'hypothèse qu'il n'y a pas de différence significative entre les deux tableaux.*
  - *C'est ce que l'on appelle l'hypothèse d'indépendance (parfois appelée hypothèse nulle ou H_0). À l'issue du test on se prononce sur l'acceptation ou le rejet de cette hypothèse d'indépendance.*
  - *Si on ne peut pas accepter l'hypothèse d'indépendance quelle est la probabilité que l'on se trompe ?*
    - *La table de la loi de khi-deux nous permet d'évaluer cette probabilité.*

- ***Comment lire cette table ?***
  - *Dans tous les cas une seule ligne de cette table nous intéresse. On doit donc d'abord identifier à quelle ligne du tableau nous devons nous reporter pour ensuite trouver le seuil de probabilité d'acceptation ou de rejet de l'hypothèse d'indépendance.*
- *En ligne figurent les degrés de libertés*
- *pour calculer le nombre de degrés de liberté on effectue le calcul suivant (nombres de lignes – 1) (nombres de colonnes – 1)*
- *Notre tableau d'origine a 2 lignes et 2 colonnes. Le nombre de degré de libertés est donc de : 1. On va donc s'intéresser à la première ligne de la table.*
- *Notre indicateur de khi deux est de 5,67 il se situe donc entre la 11ème et 12ème colonnes. En effet 5,67 est compris entre 5,02 et 6,63.*
- *Explications :* ***Ainsi l'intersection entre la 11ème colonne et le première ligne de la table indique que 2,5%*** *( )* ***des tableaux de contingence à un degré de liberté, ont un indicateur de khi-deux supérieur ou égal à 5,02.***

$n \backslash \alpha$	0,005	0,010	0,025	0,050	0,100	0,250	0,500	0,750	0,900	0,950	0,975	0,990	0,995
1	0,0000	0,0002	0,0010	0,0039	0,0158	0,102	0,455	1,32	2,71	3,84	5,02	6,63	7,88
2	0,0100	0,0201	0,0506	0,103	0,211	0,575	1,39	2,77	4,61	5,99	7,38	9,21	10,6
3	0,0717	0,115	0,216	0,352	0,584	1,21	2,37	4,11	6,25	7,81	9,35	11,3	12,8

- En colonne figure ce que l'on peut considérer comme le seuil de probabilité d'acceptation ou de rejet de l'hypothèse d'indépendance.
- Comme 5,02 correspond à 0,975 on peut dire que nous rejetons l'hypothèse d'indépendance au seuil de 0,975. Autrement dit, on rejette l'hypothèse d'indépendance entre les lignes et les colonne de notre tableau avec 97,5 % (0,975) de chances de ne pas se tromper ou bien avec 2,5% (que l'on appelle p-value=1-0,975=100%-97,5%=2,5%) de chances de se tromper.
- Par convention, on rejette le plus souvent l'hypothèse d'indépendance lorsque l'on a au maximum 5% de chance de se tromper. Si le p-value avait été supérieur à 5% on aurait accepté l'hypothèse d'indépendance. Par exemple, si notre indicateur de khi-deux avait été de 2,71, ce qui correspond à une p-value=1-0,900=0,10=10% on aurait accepté l'hypothèse d'indépendance.
- Khi deux = 5,67
- Degrés de liberté = (nombre de lignes-1) x (nombres de colonnes -1) = 1
- Seuil de rejet ou p-value : inférieur à 2,5 %
- On rejette l'hypothèse d'indépendance entre les lignes et les colonnes du tableau avec moins de 2,5 % de chances de se tromper. On peut donc affirmer, avec moins de 2,5 % de chances de se tromper, qu'il existe, dans ce tableau, un lien entre le type de disciplines enseignées et l'utilisation d'internet par les élèves.

- *En général, les tests de khi deux, et les analyses descriptives ne permettent pas de répondre à la question : pourquoi ? Il est nécessaire de confronter ces résultats a des éléments non statistiques comme le contexte de réalisation de l'enquête, des entretiens, des observations pour comprendre le phénomène...*