Présentation graphique

,I.MEDKOUR
Maitre Assistant en Epidémiologiste
Université Mira Abderrahmane /
.Faculté de Médecine. CHU Béjaia

- 3 procédés pour décrire une distribution:

Tableaux.

Graphes (Diagrammes).

Paramètres.

Description des données:
Présentation tabulaire

Tableaux

Définition:

- Un tableau est une matrice comportant au moins deux entrées,
  - L'une horizontale: lignes
  - L'autre verticale: colonnes

- Titre doit être en haut du tableau.
- Les tableau doivent être numéroté avec des chiffre romain.

Tableaux

1. Tableau brut de données:

- Tableau élémentaire: toutes les données y figurent.

- En lignes: individus (unités statistiques)
- En colonnes: les variables

- Comporte 2 sortes de variables:
  - V. d'identification (non analysées)
  - V. mesurées (se prête à l'analyse)

Tableaux

1. Tableau brut de données:

N°	Secteur	Etabliss	Classe	DDN	Age en années	mois	sexe	BMI
11	Bab el kantra	Baskri	2m1	02-Aug-2000	12	6	0	29,43
23	41460	Ibn khaldoune	1m3	20-Feb-2001	12	0	1	21,82
30	Guemass	Boumaaza	1m6	10-mars-01	11	11	1	18,19
32	Guemass	Boumaaza	1m3	28-juil-01	11	7	1	16,02
35	Guemass	Boumaaza	1m1	29-Aug-2000	12	6	0	18,32
40	Guemass	Boumaaza	1m6	01-sept-01	11	6	1	18,09
41	Guemass	Boumaaza	1m4	15-Dec-2001	11	2	0	16,19
47	Quatrième	Ibn Sina	1m4	22-juil-01	11	7	0	22,31
56	Bab el kantra	Mentouri	1m1	07-Aug-2001	11	6	1	17,08
58	Bab el kantra	Mentouri	1m2	30-juil-01	11	7	0	15,5
70	centr ville	Waled Ali	1m2	24-Apr-2001	11	10	1	19,02

Tableaux

1. Tableau de fréquences:

- Présenter un ensemble de données sous forme **agrégée**.

- Une entrée: classes de la variable
- Seconde entrée: effectif (ou fréquence) des sujets dans chaque classe de la variable.

Tableaux

1. Tableau de fréquences:

Sexe	effectif	%
M	6	54,5%
F	5	45,5%

Age (ans)	effectif	%
11	8	72,2%
12	3	27,3%

Tableaux

- **Données aberrantes:** dues à des erreurs de mesure, de recopiage ou de saisie

- **Données manquantes:** refus de réponse, mesures non pratiquées ou oublis lors de la saisie.

Variables qualitatives et ordinales

- Fréquence absolue : dénombrement par classe

Exemple : n = 180 ; variable : groupe sanguin

Tableau d'effectif

A+	A-	B+	B-	AB+	AB-	O+	O-
80	10	20	5	5	2	50	8

A	B	AB	O
90	25	7	58

- Fréquences relatives : rapport, pour chaque classe, de son effectif au nombre total d'individus de la série des mesures
- Somme des fréquences relatives = 1

Exemple : n = 180 ; variable : groupe sanguin

Tableau des fréquences relatives

A	B	AB	O
90 / 180 = 50 %	25 / 180 = 14 %	7 / 180 = 4 %	58 / 180 = 32 %

- Fréquences cumulées (relatives et absolues) : somme cumulée des fréquences
- Pour des données ordinales

Exemple : n = 500 cancéreux ; variable : stade

Stade	N	Fréquence relative (%)	Fréquence relative cumulée (%)
1	350	70	70
2	110	22	92
3	30	6	98
4	10	2	100

Présentation paramétriques

,I.MEDKOUR
Maitre assistant en épidémiologiste
Université Mira Abderrahmane /
.Faculté de Médecine. CHU Béjaia

- 3 procédés pour décrire une distribution:

Tableaux.

Graphes (Diagrammes).

Paramètres.

Présentation paramétriques

- Paramètres de tendance centrale.

- Paramètres de dispersion.

Les paramètres de tendance centrale

- I- La moyenne

- Définition
- La moyenne est la mesure la plus commune de tendance centrale.

- La moyenne est la somme des valeurs divisée par l'effectif total.

Les paramètres de tendance centrale

- I- La moyenne
- Pour les variables quantitatives continues
- Non groupée

Moyenne

$$\overline{X} = \frac{\sum_{i=1}^{p} x_i}{n}$$

- Avec :
  - xi = valeur de la variable X
  - n = taille de l'échantillon (effectif total)

Les paramètres de tendance centrale

- I- La moyenne
- Pour les variables quantitatives continues

* Groupée en classes

Pour des données groupées en classes, on peut calculer une valeur approximative de la moyenne en supposant que tous les individus d'une classe se situent au centre de celle-ci.

Les paramètres de tendance centrale

- I- La moyenne
- Pour les variables quantitatives continues

* Groupée en classes

Moyenne $$\overline{X} = \frac{\sum_{i=1}^{p} n_i C_i}{n}$$

Avec : C_i = centre de la classe

n_i = effectif correspondant à la valeur x_i

n = taille de l'échantillon (effectif total)

Les paramètres de tendance centrale

- I- La moyenne
- Pour les variables quantitatives continues

* Groupée en classes

Exemple : Moyenne en histoire-géographie dans une classe de terminale

	n_i	C_i	$n_i C_i$
[6; 8[	3		
[8; 10[	6		
[10; 12[	11		
[12; 14]	7		
[14; 16[	4		
Total	31		

Les paramètres de tendance centrale

- I- La moyenne
- Pour les variables quantitatives continues

* Groupée en classes

	n_i	C_i	$n_i C_i$
[6; 8[	3	7	21
[8; 10[	6	9	54
[10; 12[	11	11	121
[12; 14]	7	13	91
[14; 16[	4	15	60
Total	31		347

$$\overline{X} = \frac{347}{31} = 11,2$$

Les paramètres de tendance centrale

- I- La moyenne
- Pour les variables quantitatives discrète

Moyenne

$$\overline{X} = \frac{\sum_{i=1}^{p} n_i x_i}{n}$$

Avec : x_i = valeur de la variable X

n_i = effectif correspondant à la valeur x_i

n = taille de l'échantillon (effectif total)

Les paramètres de tendance centrale

- I- La moyenne
- Pour les variables quantitatives discrètes
- *Exemple : Notes de philosophie dans une classe de terminale*

x_i	n_i	$n_i x_i$
6	1	
7	2	
8	1	
9	10	
10	4	
11	3	
12	5	
13	4	
14	1	
Total	31	

Les paramètres de tendance centrale

- I- La moyenne
- Pour les variables quantitatives discrètes
- *Exemple : Notes de philosophie dans une classe de terminale*

x_i	n_i	$n_i x_i$
6	1	6
7	2	14
8	1	8
9	10	90
10	4	40
11	3	33
12	5	60
13	4	52
14	1	14
Total	31	317

$$\overline{X} = \frac{317}{31} = 10{,}2$$

Les paramètres de tendance centrale

- **II- La médiane:**

- Définition
- La valeur qui partage en 2 parties égales égaux la population.
- Elle divise une ***série*** statistique ***ordonnée*** en deux ensembles comportant chacun 50% des données.
- 50% des valeurs > à la médiane et 50% <.

Les paramètres de tendance centrale

- II- La médiane:
- Pour les variables quantitatives discrètes
- Pour déterminer la médiane :
  - (1) on classe les individus par ordre croissant
  - (2) on prend celui du milieu
- Avec n le nombre d'individus, la médiane porte le numéro d'ordre $\frac{n+1}{2}$ dans la suite des individus classés par ordre croissant.

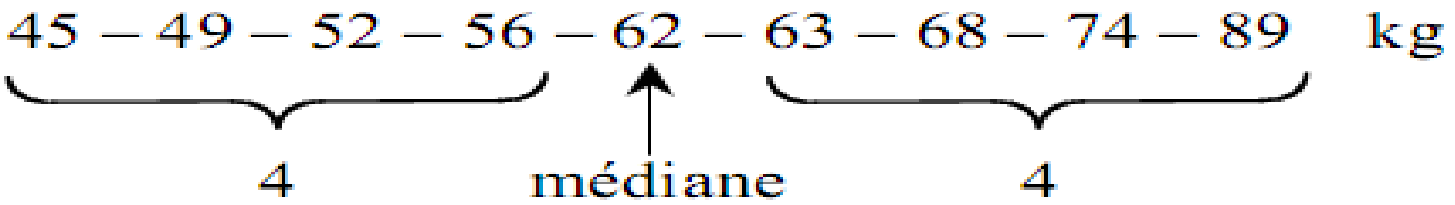
Les paramètres de tendance centrale

- II- La médiane:
- Pour les variables quantitatives discrètes
- 2 cas:
- Si n est impair, la médiane est la valeur d'ordre $\frac{n+1}{2}$

- Si n est pair, la médiane est la moyenne entre la valeur d'ordre $\frac{n}{2}$ et la valeur d'ordre $\frac{n+2}{2}$

Les paramètres de tendance centrale

- II- La médiane:
- Pour les variables quantitatives discrètes
- Ex:
- Soit 9 personnes dont le poids est :45 – 68 – 89 – 74 – 62 – 56 – 49 –52 – 63
- classés par ordre croissant :



Les paramètres de tendance centrale

- II- La médiane:
- Pour les variables quantitatives discrètes
- Ex:

Soit un échantillon de 10 personnes dont le poids est :

$$\underbrace{45 - 49 - 52 - 55 - 56}_{5} - \underbrace{62 - 63 - 68 - 74 - 89}_{5}$$

$$\text{médiane} = \frac{56 + 62}{2} = 59 \quad \text{kg}$$

Les paramètres de tendance centrale

- II- La médiane:
- Pour les variables quantitatives discrètes

Exemple 2 :

Nombres d'enfants de 0 à 16 ans par famille	Effectif	Fréquences f_i	Fréquences cumulées F_i
0	7130	0,505	0,505
1	3201	0,227	0,732
2	2498	0,178	0,910
3	919	0,065	0,975
4	241	0,017	0,992
5	130	0,009	1,000
Total	14119	1	

Les paramètres de tendance centrale

- II- La médiane:
- Pour les variables quantitatives discrètes

Nombres d'enfants de 0 à 16 ans par famille	Effectif	Fréquences f_i	Fréquences cumulées F_i
0	7130	0,505	0,505
1	3201	0,227	0,732
2	2498	0,178	0,910
3	919	0,065	0,975
4	241	0,017	0,992
5	130	0,009	1,000
Total	14119	1	

$Me = 0$

Les paramètres de tendance centrale

- II- La médiane:
- Pour les variables quantitatives continues
- Groupée en classes

Âge	Fréquences	Fréquences cumulées
Moins de 15 ans	0	0
De 15 à moins de 20 ans	0,058	0,058
De 20 à moins de 30 ans	0,248	0,306
De 30 à moins de 40 ans	0,205	0,511
De 40 à moins de 50 ans	0,148	0,659
De 50 à moins de 60 ans	0,142	0,801
De 60 à moins de 70 ans	0,107	0,908
De 70 à moins de 95 ans	0,092	1,000

Les paramètres de tendance centrale

- II- La médiane:

$$Me = Li + \left(\frac{n/2 - (n_1 + \ldots + n_{i-1})}{n_i} \right) \times C$$

Avec :

L_i = borne inférieure de la classe médiane

n = taille de l'échantillon (effectif total)

n_i = effectif de la classe médiane

C = amplitude de la classe médiane

$n_1 + \ldots + n_{i-1}$ = effectifs cumulés des classes précédant la classe médiane

Les paramètres de tendance centrale

- II- La médiane:
- Pour les variables quantitatives continues
- Groupée en classes

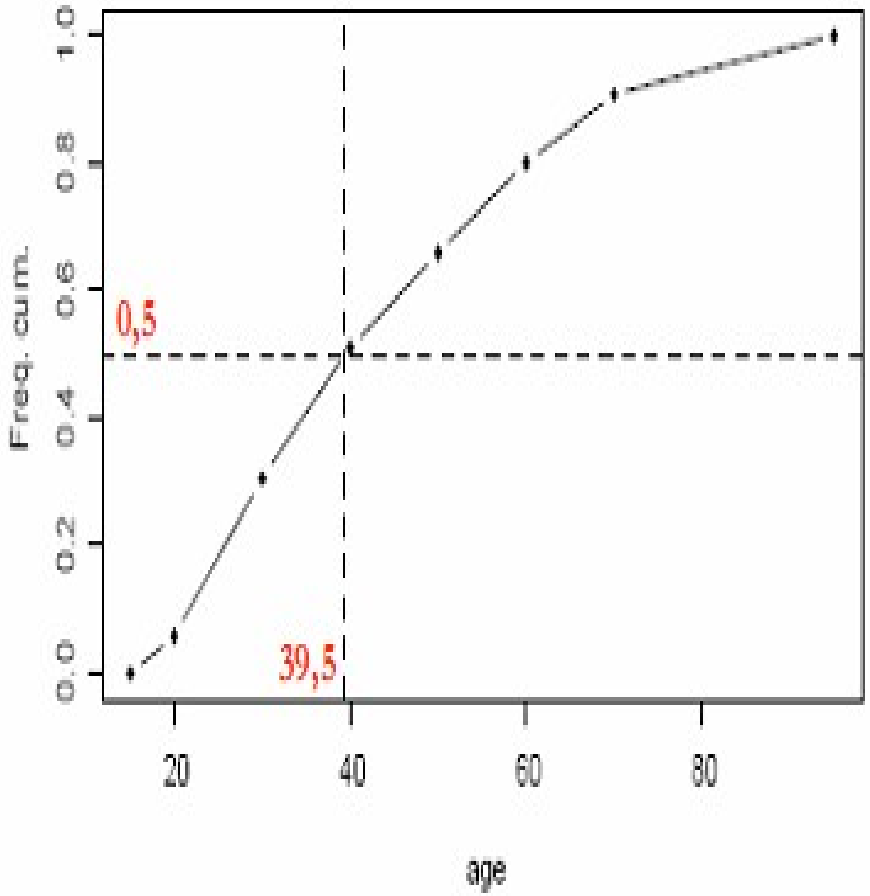
Âge	Fréquences	Fréquences cumulées
Moins de 15 ans	0	0
De 15 à moins de 20 ans	0,058	0,058
De 20 à moins de 30 ans	0,248	0,306
De 30 à moins de 40 ans	0,205	0,511
De 40 à moins de 50 ans	0,148	0,659
De 50 à moins de 60 ans	0,142	0,801
De 60 à moins de 70 ans	0,107	0,908
De 70 à moins de 95 ans	0,092	1,000

La médiane se situe dans la classe d'âge [30;40[

$Me = 30 + ((0{,}5 - 0{,}306)/0{,}205)*10 = 39{,}5$ ans

Les paramètres de tendance centrale

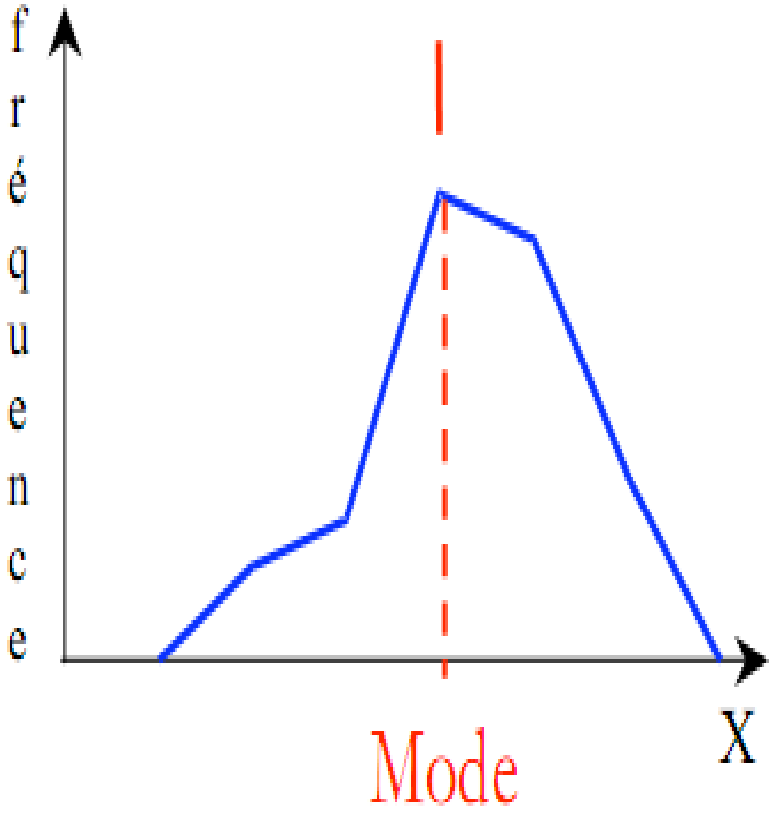
- II- La médiane:
- Pour les variables quantitatives continues
- Groupée en classes
- La médiane peut être lue graphiquement à partir de la courbe des fréquences cumulées.



Les paramètres de tendance centrale

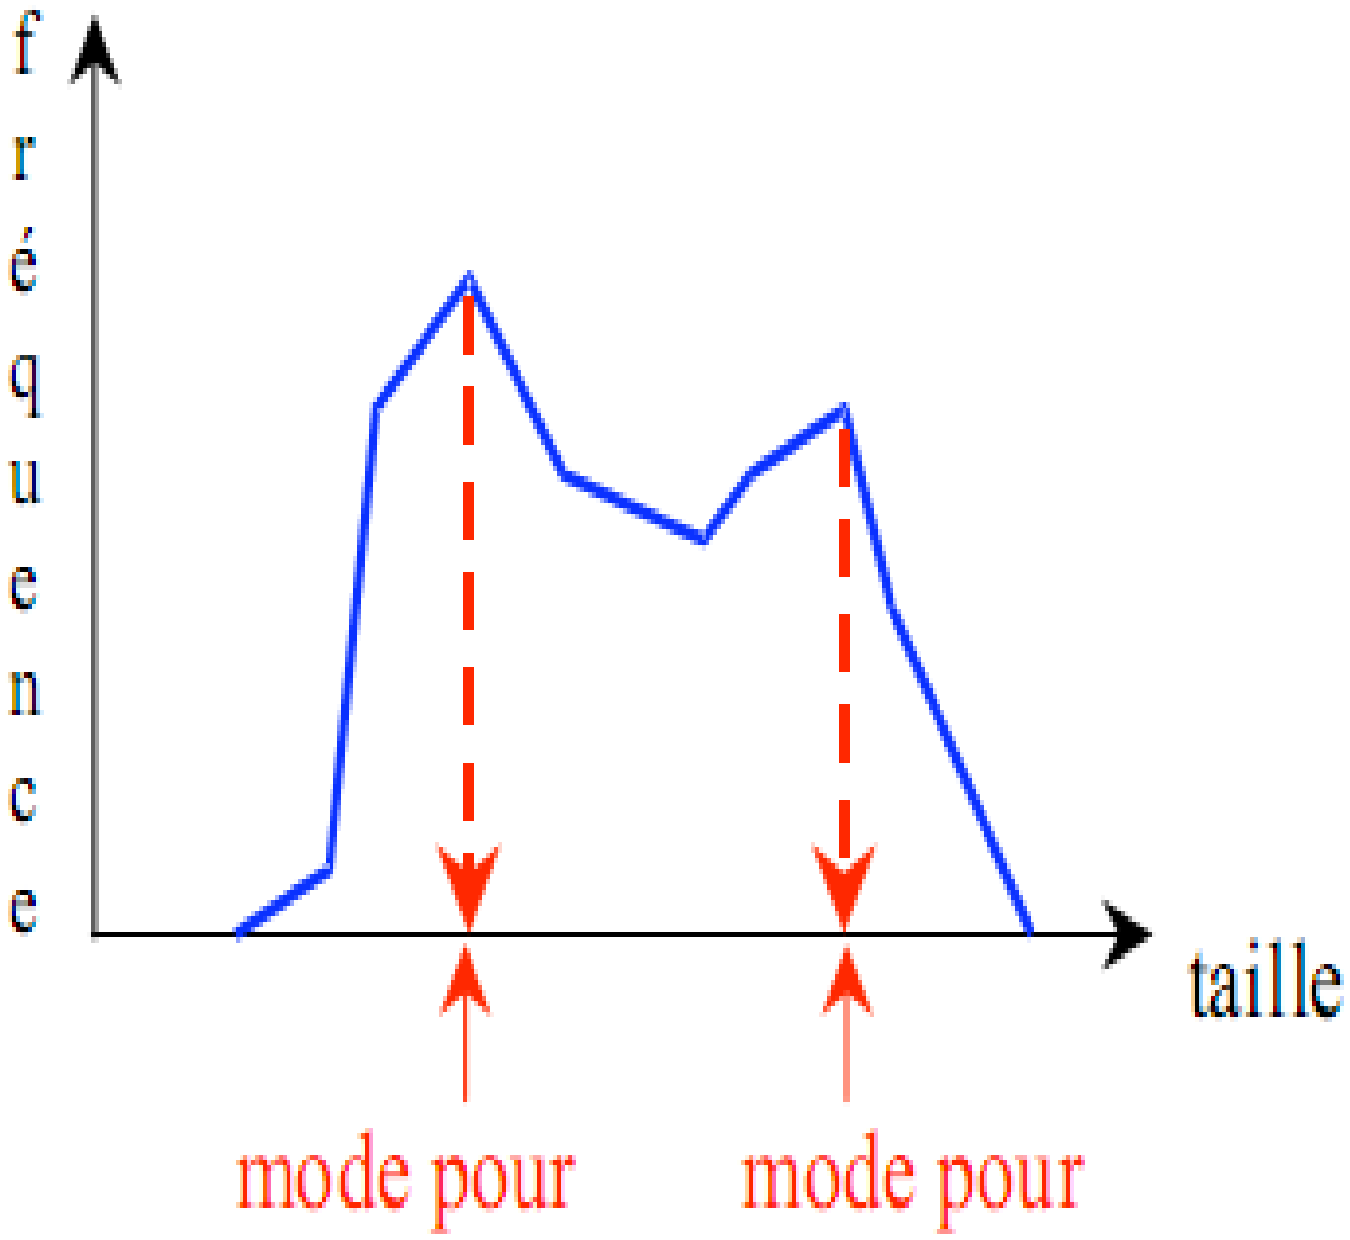
- III- Le mode (Mo)
- La modalité qui a le plus grand effectif.
- Une distribution peut avoir un mode:

  « distribution unimodale »



Les paramètres de tendance centrale

- III- Le mode
- Une distribution peut aussi avoir plusieurs modes.
  * distribution bimodale (deux modes)
  * distribution multimodale (plusieurs modes). Elle est souvent le reflet d'une population composée de plusieurs sous-populations distinctes.


f
r
é
q
u
e
n
c
e
taille
mode pour
mode pour

Les paramètres de tendance centrale

- I- Le mode

Pour les variables qualitatives

- Le mode d'une variable qualitative est la modalité la plus fréquemment observée.
- Le mode est la seule mesure de tendance centrale applicable aux variables qualitatives.

Exemple : Perception de l'état de santé

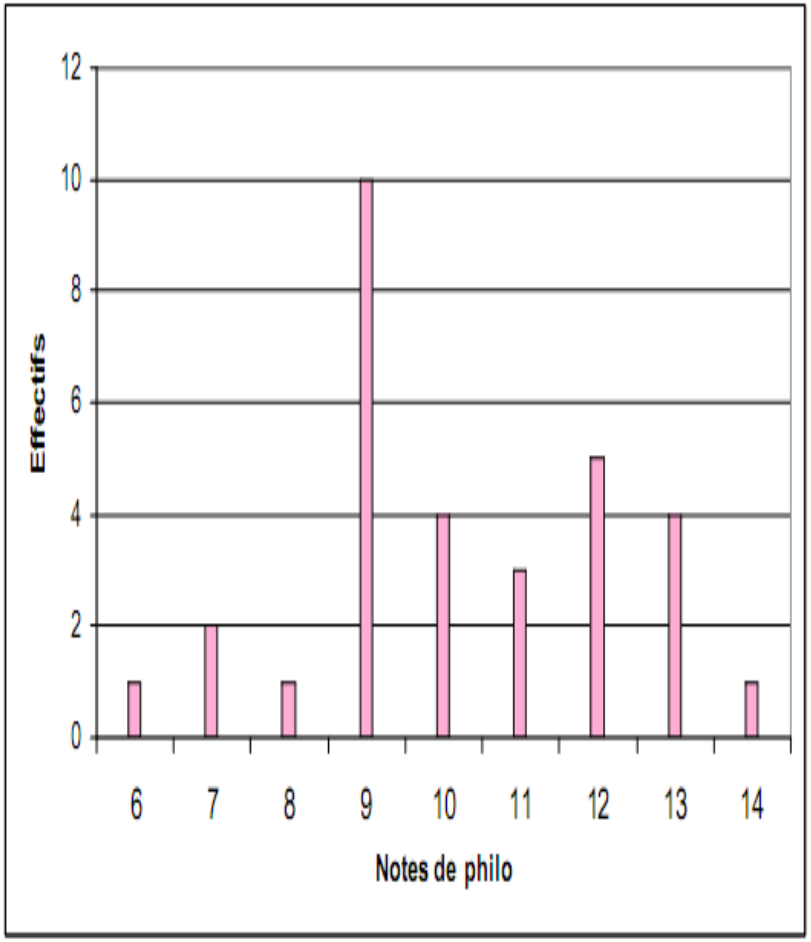
	Effectifs
« très bon »	3303
« bon »	6337
« moyen »	2325
« mauvais »	354
« très mauvais »	71
Total	12390

Les paramètres de tendance centrale

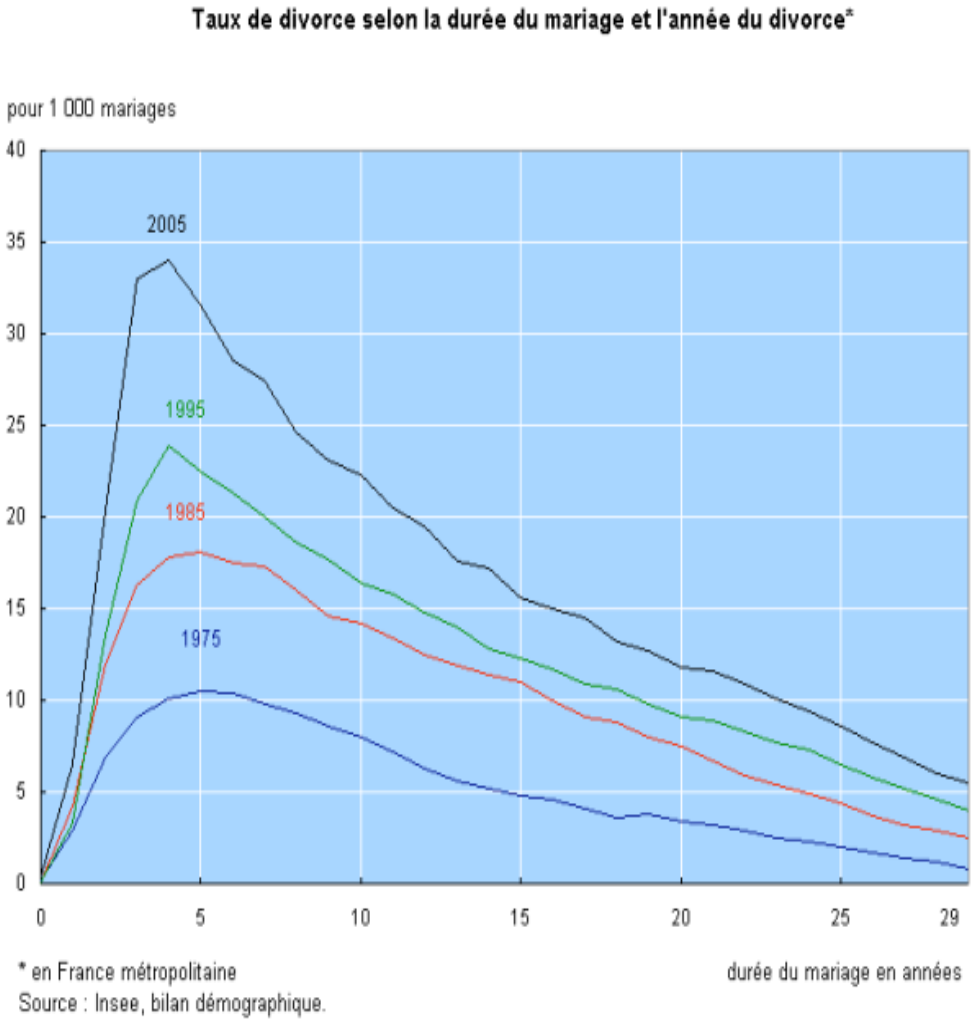
- III- Le mode

Pour les variables quantitatives discrètes

Comme pour les variables qualitatives, le mode d'une variable quantitative discrète est la valeur la plus fréquemment observée.



Les paramètres de tendance centrale



- III- Le mode

Pour les variables quantitatives continues

Non groupées

Le mode est 5 ans de mariage en 1975 et en 1985, 4 ans de mariage en 1995 et en 2005.

La fréquence modale est de 34 pour 1000 en 2005.

Les paramètres de tendance centrale

- III- Le mode
- Pour les variables quantitatives continues

Groupée en classes d'amplitude constante

Ex: Moyenne en histoire-géographie dans une classe de terminale

Classes	Effectifs(n_i)
[6; 8[	3
[8; 10[	6
[10; 12[	11
[12; 14]	7
[14; 16[	4
Total	31

La classe modale est [10;12[avec un effectif modal de 11

Les paramètres de tendance centrale

- III- Le mode

La classe modale est [20;30[avec un effectif rapporté à l'amplitude de la classe de 200.

Exemple : Répartition en 3 tranches d'âge

	n_i	Amplitude	$H_i (n_i/A)$
[20;30[	2000	10	200
[30;50[	3000	20	150
[50;55[	500	5	100
	5500		

Avantages et inconvénients du mode, de la moyenne et de la médiane

- Le mode est la plus mauvaise mesure du centre, car la classe la mieux représentée n'est pas nécessairement au centre de la distribution.

- Si les valeurs extrêmes sont modifiées, la médiane ne change pas car elle n'est pas sensible aux valeurs extrêmes.

Avantages et inconvénients du mode, de la moyenne et de la médiane

- Par contre, la moyenne change car elle tient compte de toutes les valeurs

- **On préférera la <u>médiane</u> ou la <u>moyenne</u> selon que l'on veut une mesure sensible ou non aux valeurs extrêmes.**

- La comparaison des trois valeurs centrales ou l'examen de l'histogramme permettent de définir **la forme des distributions**.

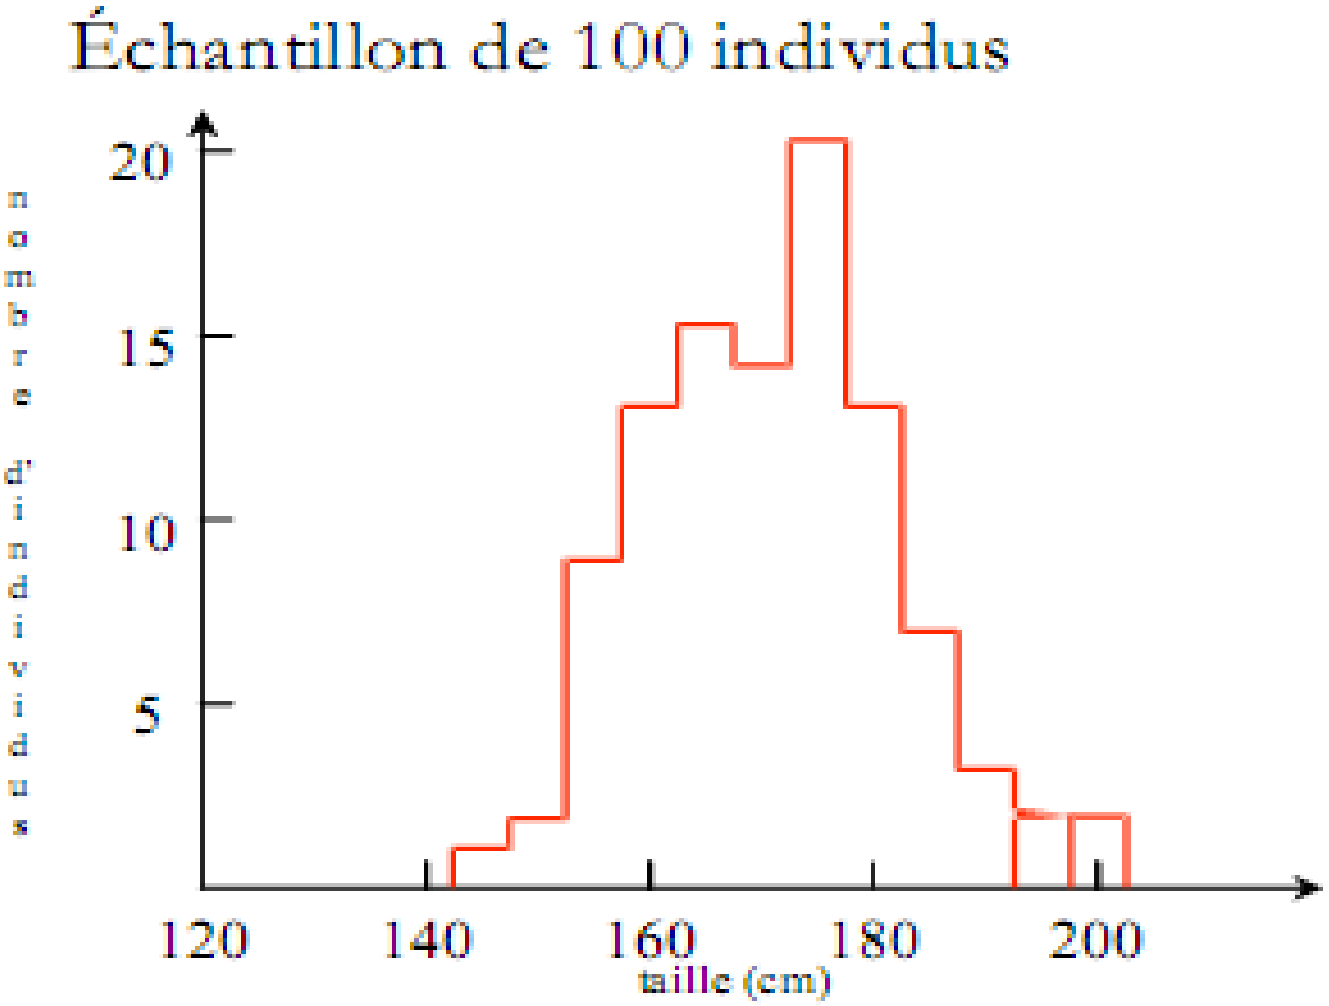
- Selon la forme d'une distribution le meilleur résumé sera fourni par l'une ou l'autre des trois valeurs centrales.

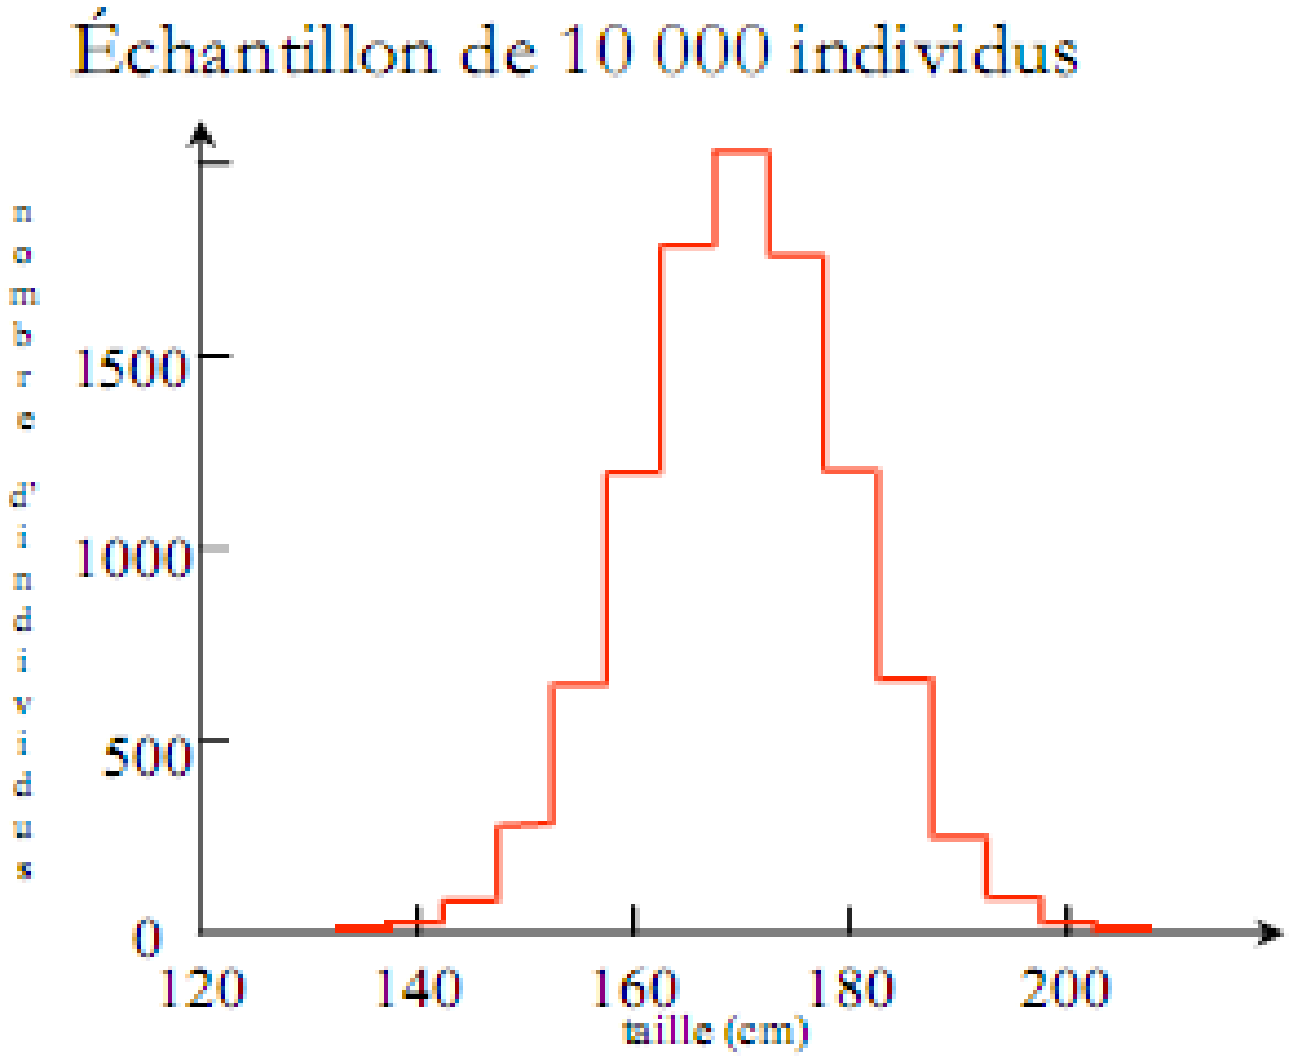
- Distributions unimodales symétriques
- Lorsque la distribution est unimodale et symétrique, on trouve à peu près **moyenne = médiane = mode.**

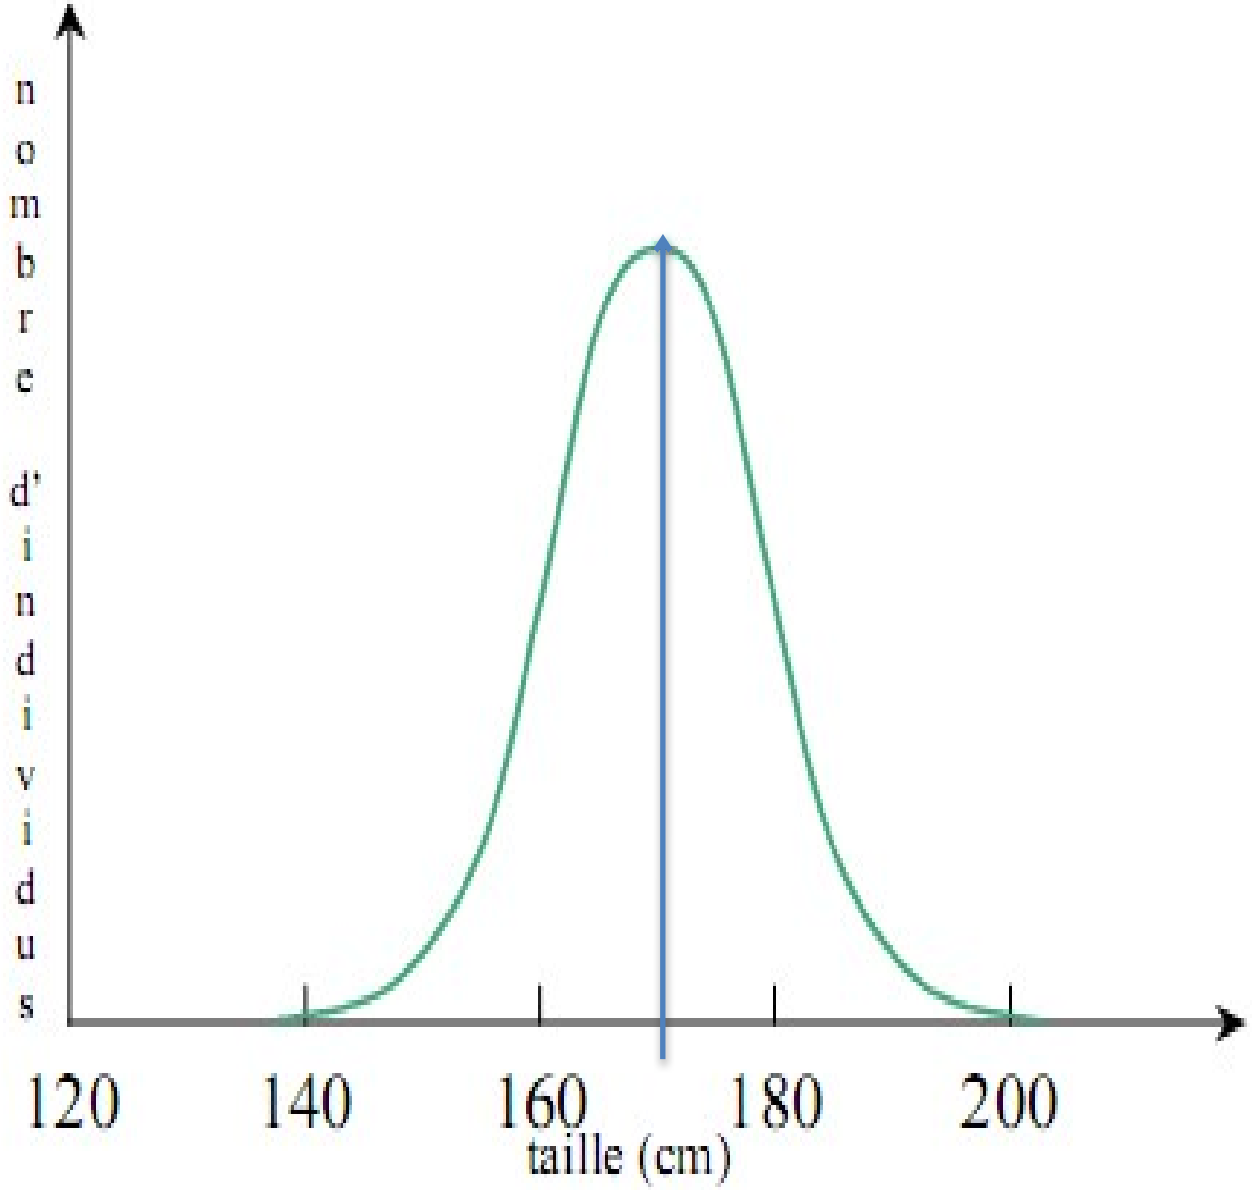
=> Le **meilleur résumé** est donné par **la moyenne** car elle tient compte de toutes les observations et elle possède des propriétés statistiques intéressantes.

Valeurs centrales et formes des distributions

- **Un cas fréquent: la loi normale**
- La distribution normale est le seul cas où la moyenne, la médiane et le mode prennent des valeurs identiques.
- Au fur et à mesure que la taille de l'échantillon augmente, l'histogramme devient de plus en plus régulier et se rapproche d'une courbe en cloche, appelée loi normale.


Échantillon de 100 individus
nombre d'individus
20
15
10
5
120
140
160
180
200
taille (cm)


Échantillon de 10 000 individus
nombre d'individus
1500
1000
500
0
120
140
160
180
200
taille (cm)



Mode
=
Médiane
=
Moyenne

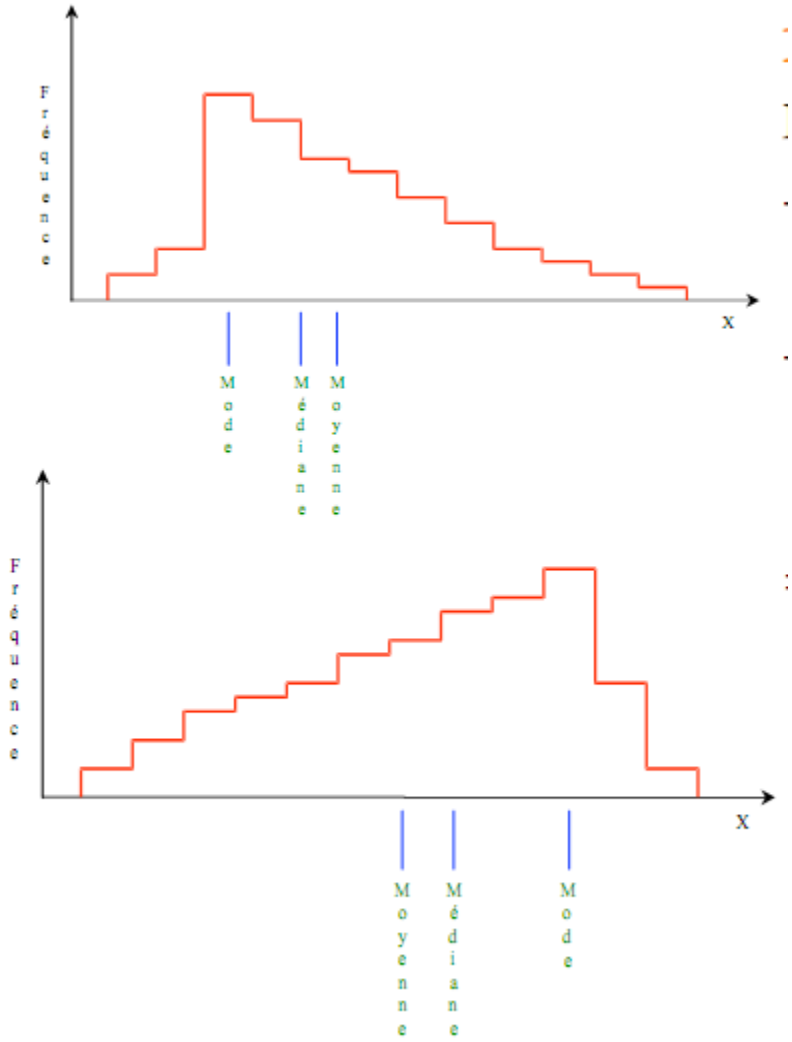
Valeurs centrales et formes des distributions

- Distributions uni modales dissymétriques
- Deux cas peuvent se présenter :

- La distribution est étalée à droite

mode < médiane < moyenne

- La distribution est étalée à gauche moyenne < médiane <mode



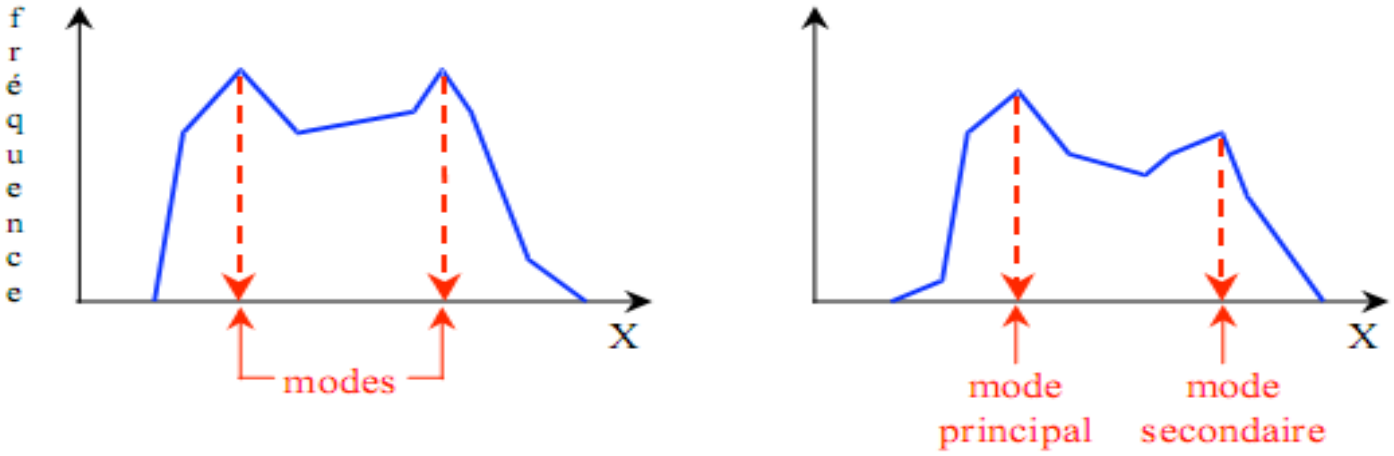
Valeurs centrales et formes des distributions

- => Lorsqu'il y a une **dissymétrie** marquée, la **médiane** est généralement préférable à la moyenne car elle est moins influencée par les valeurs extrêmes qui sont souvent à l'origine de la dissymétrie.

- Si la dissymétrie est peu marquée, on pourra néanmoins utiliser la moyenne.

Valeurs centrales et formes des distributions

- Distributions bimodales ou multimodales
- La distribution comporte plusieurs modes.
- Le mode principal est différent de la moyenne et de la médiane qui ont de fortes chances de correspondre à une zone de dispersion des valeurs.



Valeurs centrales et formes des distributions

- Distributions bimodales ou multimodales

- Dans ce cas, ni la moyenne ni la médiane ne sont significatives. La distribution ne peut pas être résumée par une seule valeur. Elle se compose de deux groupes très différenciés.

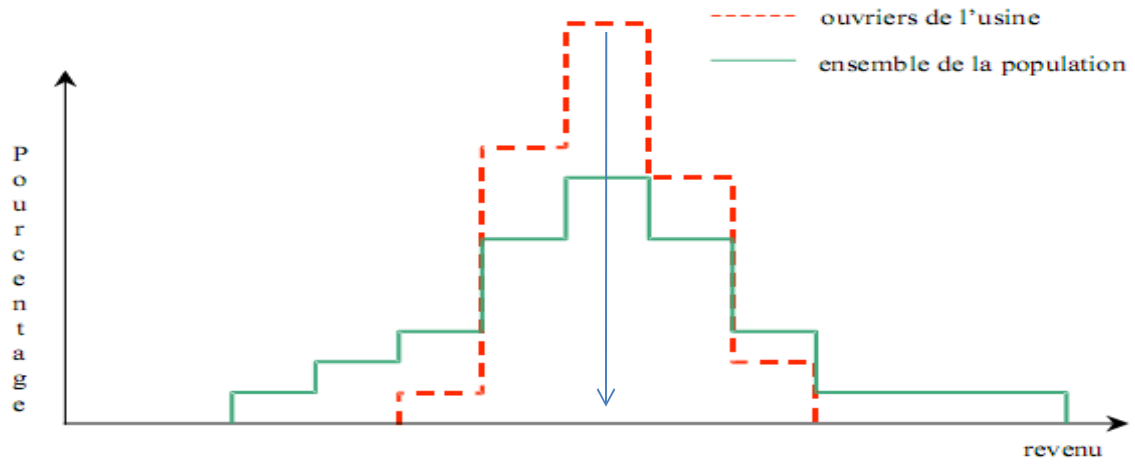
=> le meilleur résumé est alors donné par les **modes** principaux et secondaires de la distribution.

Les paramètres de dispersion

,I.MEDKOUR
Maitre assistant en épidémiologiste
Université Mira Abderrahmane /
.Faculté de Médecine. CHU Béjaia

La notion de dispersion

- Ex : On désire comparer les revenus des ouvriers d'une usine à ceux de l'ensemble de la population de leur région.



- Dans ce cas, les deux distributions ont le même centre mais elles sont manifestement différentes : => elles diffèrent par leur dispersion (leur variabilité).

- I- L’étendue
- Définition : L’étendue est la mesure de dispersion la plus simple à déterminer.
- Elle mesure l’écart entre la plus grande et la plus petite valeur observée d’une série statistique quantitative.

$$E = V_{max} - V_{min}$$

- I- L’étendue
- Définition :
- Prend en compte les valeurs extrêmes d’une série statistique => Elle est donc très influencée par la présence d’une valeur aberrante très faible ou au contraire très élevée.

Ex : Temps pour accomplir une tâche (en secondes)

Série statistique	Etendue
4,4,5,7,8,8,9,10,11,6,7,12,5,8,5	12 - 4 = 8
4,4,5,7,8,8,9,10,11,6,7,12,5,8,5,25	25 – 4 = 21

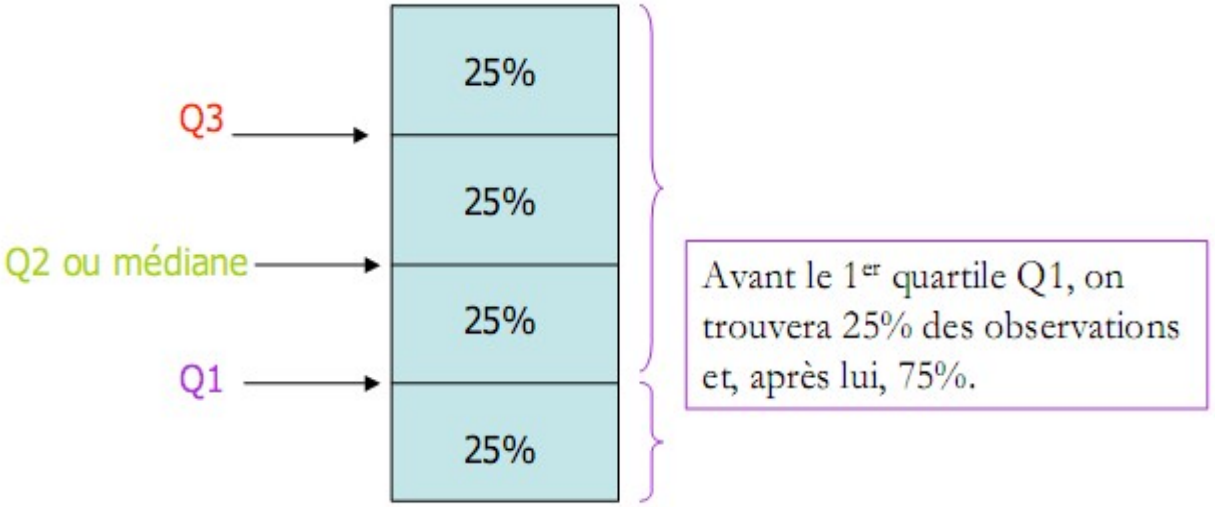
L'individu le plus lent a mis 8 secondes de plus que l'individu le plus rapide pour accomplir la tâche demandée.

- II- Les quantiles
- Définition : Les quantiles sont des valeurs qui divisent **une série statistique ordonnée** en plusieurs groupes comportant la même proportion de données.
- Ce sont des valeurs de position, qui se calculent sur les mêmes principes que la médiane.

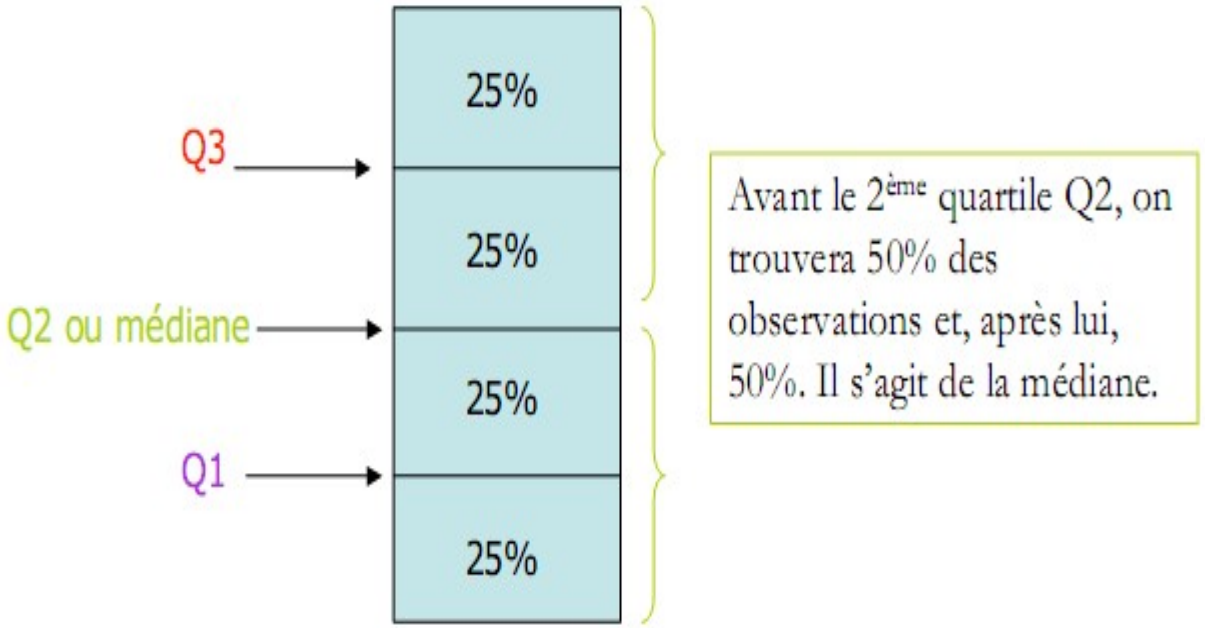
- II- Les quantiles

- Les quantiles les plus couramment utilisés sont :
  - Les quartiles (4 groupes)
  - Les déciles (10 groupes)
  - Les centiles (100 groupes)

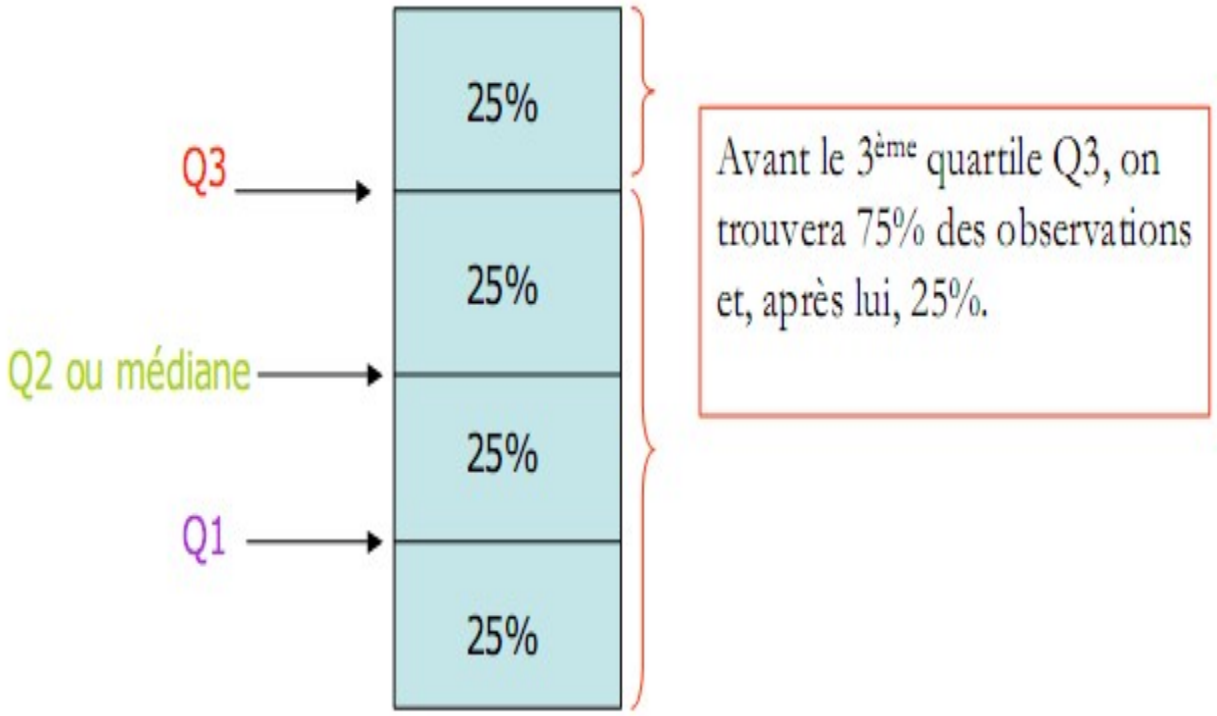
- A- Les quartiles
- Divisent une série statistique ordonnée, non plus en 2 comme la médiane, mais en 4 groupes comprenant chacun environ 25% des données de la série. Il y en a donc 3 : Q1, Q2 et Q3



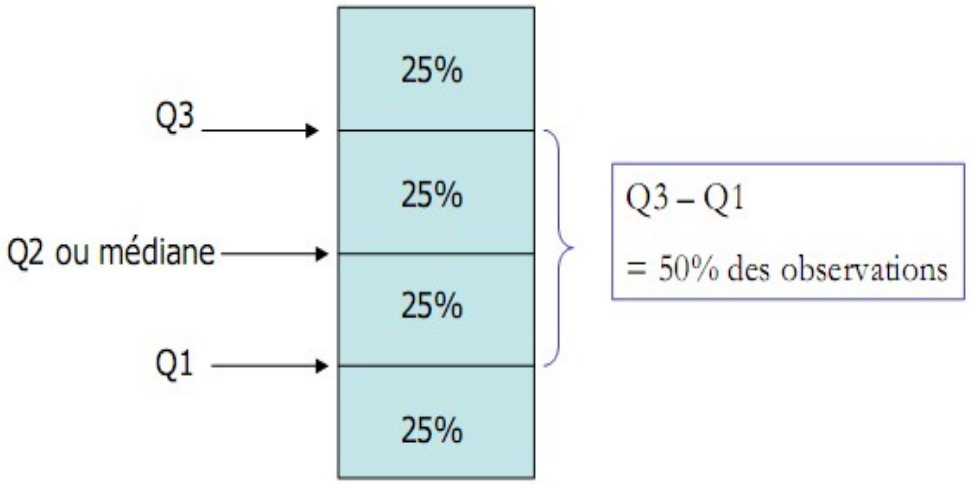
- A- Les quartiles



- A- Les quartiles



- A- Les quartiles
- L'utilisation des quartiles permet de raisonner sans tenir compte des valeurs aberrantes.
- **L'intervalle interquartile** Q 3 – Q1 comprend 50% des observations en ayant éliminé les valeurs extrêmes.



- A- Les quartiles
- Calcul des quartiles:

  - Calcul de n/4 pour Q1 et 3n/4 pour Q3.
  - Calcul des effectifs cumulés.
  - Lecture des quartiles à l'endroit où on atteint n/4 et 3n/4.

- B- Les déciles
- Définition : les déciles correspondent aux valeurs de la variable qui partagent l'effectif total en 10 groupes d'effectifs identiques.
- On calcule 9 déciles de D1 à D9 pour séparer la population en 10 parties égales.
- Intervalle interdécile : D9 – D1

- C- Les centiles
- Définition : les centiles correspondent aux valeurs de la variable qui partagent l'effectif total en 100 groupes d'effectifs identiques.

- On calcule 99 déciles de C1 à C99 pour séparer la population en 100 parties égales.

- Classe 19, 1 moy=10 var 9
- Classe 9, 11 moy= 10 var 1

- Variance et écart-type
- L’indice habituellement retenu est la moyenne des carrés des écarts à la moyenne, appelée la variance.

- Variance et écart-type
- On utilise la racine carrée de la variance, appelé écart-type, qui est exprimé dans la même unité de la variable x :

$$\sigma = \sqrt{V}$$

- Variance et écart-type:

$$\sigma^2 = \frac{\Sigma(x-\mu)^2}{N}$$

$$\sigma^2 = \frac{\Sigma x^2 - \frac{(\Sigma x)^2}{N}}{N}$$

IV- La mesure des inégalités

A- Le coefficient de variation

$$C_V = \frac{\sigma_x}{\overline{x}}$$

Comparer deux séries par rapport à leur dispersion, alors que les observations ne sont pas exprimées dans la même unité.

IV- La mesure des inégalités

A- Le coefficient de variation

$$C_V = \frac{\sigma_x}{\overline{x}}$$

Il rapporte l'écart-type à la moyenne.

Plus grand est le coefficient de variation, plus grande est la dispersion.

On l'exprime souvent en pourcentage.

Merci pour votre aimable attention