Statistique descriptive bivariée

Dr Houda Boukheris

Faculté de Médecine de Béjaia

houdaboukh@yahoo.fr

Plan

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative

Plan

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative

Plan

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative

Plan

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative

Motivations

- Pour approfondir l'analyse, il est souvent utile de **croiser** certaines variables entre elles :
  - Croiser le niveau de satisfaction avec le sexe (les femmes sont-elles plus satisfaites que les hommes par rapport à ce produit ?)
  - Croiser l'âge avec le sexe (quelle est la moyenne d'âge chez les hommes ? Chez les femmes ?)
  - Croiser l'âge avec le poids (l'âge est-il corrélé au poids ?)

- Les représentations statistiques diffèrent en fonction du type de variables croisées :
  - qualitative/qualitative
  - qualitative/quantitative
  - quantitative/quantitative

- L'analyse descriptive bivariée prépare l'inférence statistique :
  - Liaison entre variables
  - Corrélation entre variables

Point étudié

1. Introduction
2. Variable qualitative / Variable qualitative
   - Présentation des données
   - Représentations graphiques
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative

Point étudié

1. Introduction
2. Variable qualitative / Variable qualitative
   - Présentation des données
   - Représentations graphiques
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative

Présentation des données

Considérons

$$X = \{x_1, x_2, \ldots, x_l\}$$

$$Y = \{y_1, y_2, \ldots, y_m\}$$

deux variables qualitatives ayant respectivement l et m modalités.

Exemple

- Niveau de satisfaction : Mauvais, Passable, Bon, Excellent.
- Sexe : Masculin, Féminin

Tableau de contingence

- Basé sur l'effectif et la fréquence de chaque croisement de modalité
- Notions supplémentaires : fréquences lignes et fréquences colonnes (conditionnelles)
- Permet, d'une manière descriptive, d'étudier le "lien" entre deux variables qualitatives

Présentation des données - Effectifs joints / Effectifs marginaux

$X = \{x_1, x_2, \ldots, x_I\}$, $Y = \{y_1, y_2, \ldots, y_m\}$

		Variable Y						
		y_1	y_2	$\ldots$	y_j	$\ldots$	y_m	Total
Variable X	x_1	n_{11}	n_{12}	$\ldots$	n_{1j}	$\ldots$	n_{1m}	$n_{1.}$
	x_2	n_{21}	n_{22}	$\ldots$	n_{2j}	$\ldots$	n_{2m}	$n_{2.}$
	$\vdots$	$\vdots$	$\vdots$	$\ldots$	$\vdots$	$\ldots$	$\vdots$	$\vdots$
	x_i	n_{i1}	n_{i2}	$\ldots$	n_{ij}	$\ldots$	n_{im}	$n_{i.}$
	$\vdots$	$\vdots$	$\vdots$	$\ldots$	$\vdots$	$\ldots$	$\vdots$	$\vdots$
	x_I	n_{I1}	n_{I2}	$\ldots$	n_{Ij}	$\ldots$	n_{Im}	$n_{I.}$
	Total	$n_{.1}$	$n_{.2}$	$\ldots$	$n_{.j}$	$\ldots$	$n_{.m}$	n

n_{ij} : effectif joint de la modalité x_i et de la modalité y_j
$n_{i.}$: effectif marginal de la modalité x_i
$n_{.j}$: effectif marginal de la modalité y_j
n : taille de l'échantillon

Présentation des données - Fréquences jointes / Fréquences marginales

Fréquence jointe : Fréquence du couple de modalités (x_i, y_j)

$$f_{ij} = \frac{n_{ij}}{n}$$

Fréquence marginale : Fréquence de la modalité (x_i)

$$f_{i.} = \frac{n_{i.}}{n}$$

(resp. $f_{.j} = \frac{n_{.j}}{n}$ pour (y_j))

		Variable Y						
		y_1	y_2	$\dots$	y_j	$\dots$	y_m	Total
Variable X	x_1	f_{11}	f_{12}	$\dots$	f_{1j}	$\dots$	f_{1m}	$f_{1.}$
	x_2	f_{21}	f_{22}	$\dots$	f_{2j}	$\dots$	f_{2m}	$f_{2.}$
	$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$	$\dots$	$\vdots$	$\vdots$
	x_i	f_{i1}	f_{i2}	$\dots$	f_{ij}	$\dots$	f_{im}	$f_{i.}$
	$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$	$\dots$	$\vdots$	$\vdots$
	x_l	f_{l1}	f_{l2}	$\dots$	f_{lj}	$\dots$	f_{lm}	$f_{l.}$

Présentation des données - Fréquences conditionnelles lignes

Fréquence conditionnelle ligne : Fréquence de la modalité y_j parmi les individus présentant la modalité x_i

$$f_{j/i} = \frac{n_{ij}}{n_{i.}}$$

		Variable Y						
		y_1	y_2	$\dots$	y_j	$\dots$	y_m	Total
Variable X	x_1	$f_{1/1}$	$f_{2/1}$	$\dots$	$f_{j/1}$	$\dots$	$f_{m/1}$	1
	x_2	$f_{1/2}$	$f_{2/2}$	$\dots$	$f_{j/2}$	$\dots$	$f_{m/2}$	1
	$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$	$\dots$	$\vdots$	$\vdots$
	x_i	$f_{1/i}$	$f_{2/j}$	$\dots$	$f_{j/i}$	$\dots$	$f_{m/i}$	1
	$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$	$\dots$	$\vdots$	$\vdots$
	x_l	$f_{1/l}$	$f_{2/l}$	$\dots$	$f_{j/l}$	$\dots$	$f_{m/l}$	1

Présentation des données - Fréquences conditionnelles colonnes

Fréquence conditionnelle colonne : Fréquence de la modalité x_i parmi les individus présentant la modalité y_j

$$f_{i/j} = \frac{n_{ij}}{n_{.j}}$$

		Variable Y					
		y_1	y_2	$\dots$	y_j	$\dots$	y_m
Variable X	x_1	$f_{1/1}$	$f_{1/2}$	$\dots$	$f_{1/j}$	$\dots$	$f_{1/m}$
	x_2	$f_{2/1}$	$f_{2/2}$	$\dots$	$f_{2/j}$	$\dots$	$f_{2/m}$
	$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$	$\dots$	$\vdots$
	x_i	$f_{i/1}$	$f_{j/2}$	$\dots$	$f_{i/j}$	$\dots$	$f_{i/m}$
	$\vdots$	$\vdots$	$\vdots$	$\dots$	$\vdots$	$\dots$	$\vdots$
	x_l	$f_{l/1}$	$f_{l/2}$	$\dots$	$f_{l/j}$	$\dots$	$f_{l/m}$
	Total	1	1	$\dots$	1	$\dots$	1

Présentation des données - Exemple

Croisement du niveau de satisfaction et du sexe

Effectifs % %ligne %colonne	Homme	Femme	total
Mauvais	30 0,11 0.75 0.20	10 0.04 0.25 0.08	40 0,14
Passable	45 0.16 0.69 0.30	20 0.07 0.31 0.15	65 0.23
Bon	50 0.18 0.43 0.33	65 0.23 0.57 0.27	115 0.41
Excellent	25 0.09 0.42 0.17	35 0.13 0.58 0.27	60 0.21
Total	150 0.54	130 0.46	280 1

Présentation des données - Exemple

Croisement du niveau de satisfaction et du sexe

Effectifs	
%	
%ligne	
%colonne	Homme
	30
	0,11
	0.75
Mauvais	0.20



Effectifs : Parmi 280 individus, 30 hommes ont noté « mauvais »

% : Parmi 280 individus, 11% sont des hommes qui ont noté « mauvais »

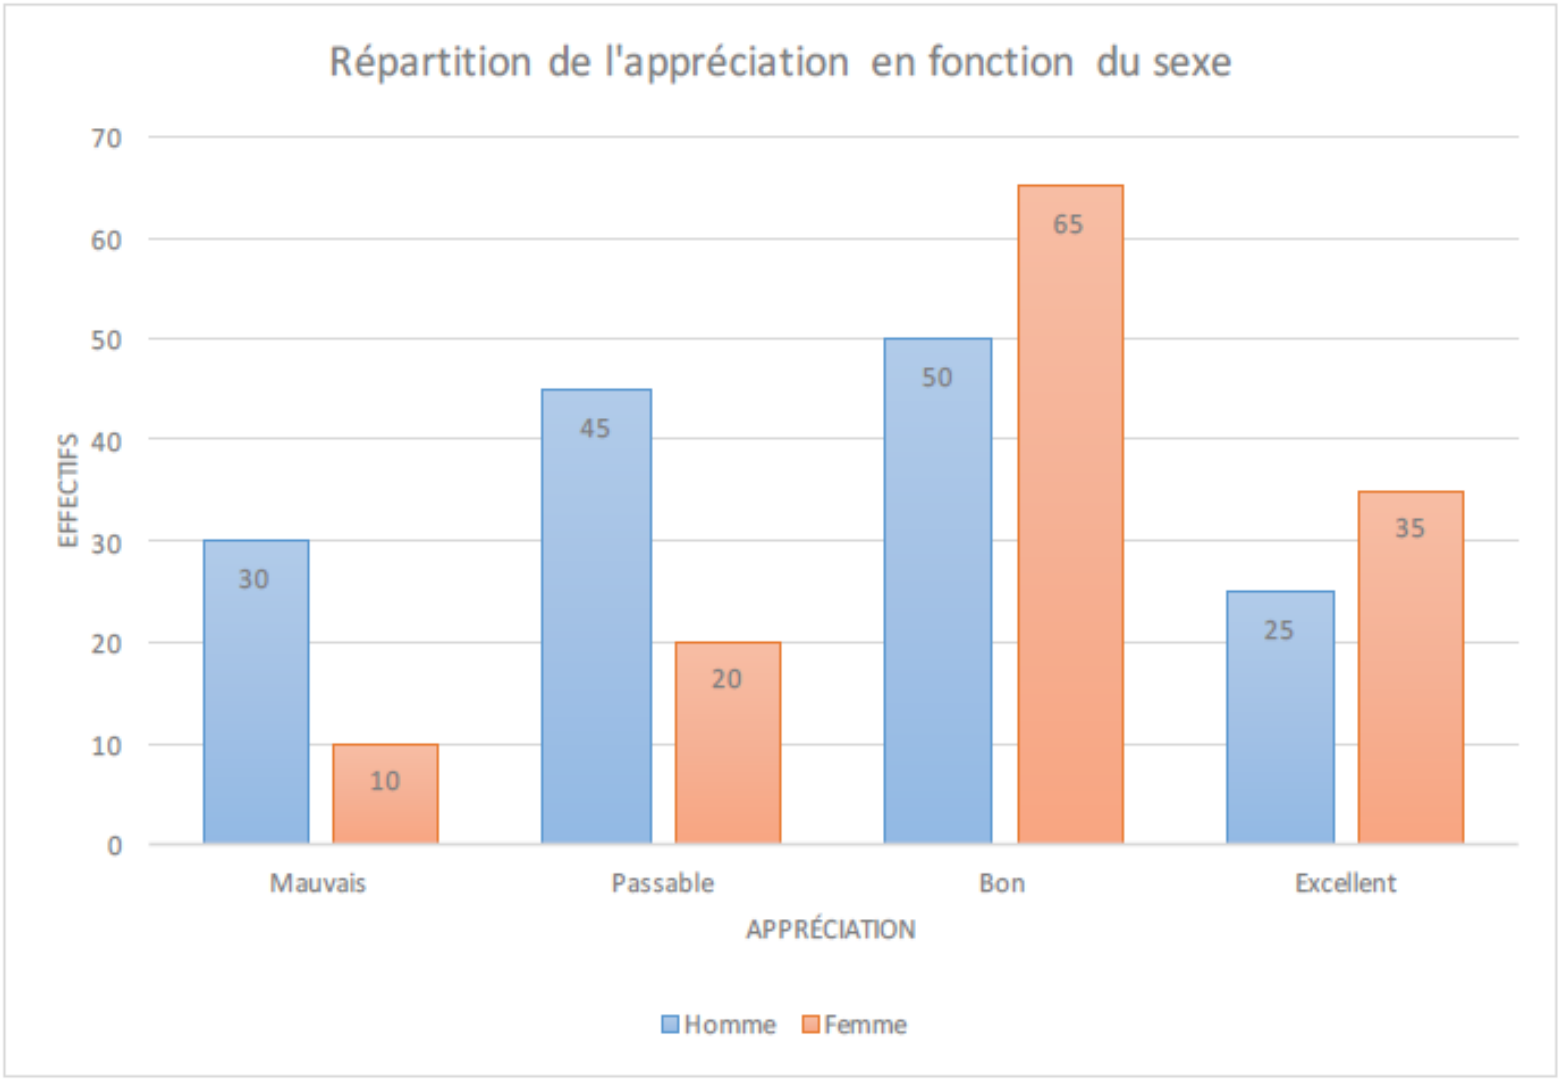
%ligne : Parmi 40 individus qui ont noté « mauvais », 75% étaient des hommes (30/40)

%colonne : Parmi 150 hommes ,20% ont noté « mauvais » (30/150)

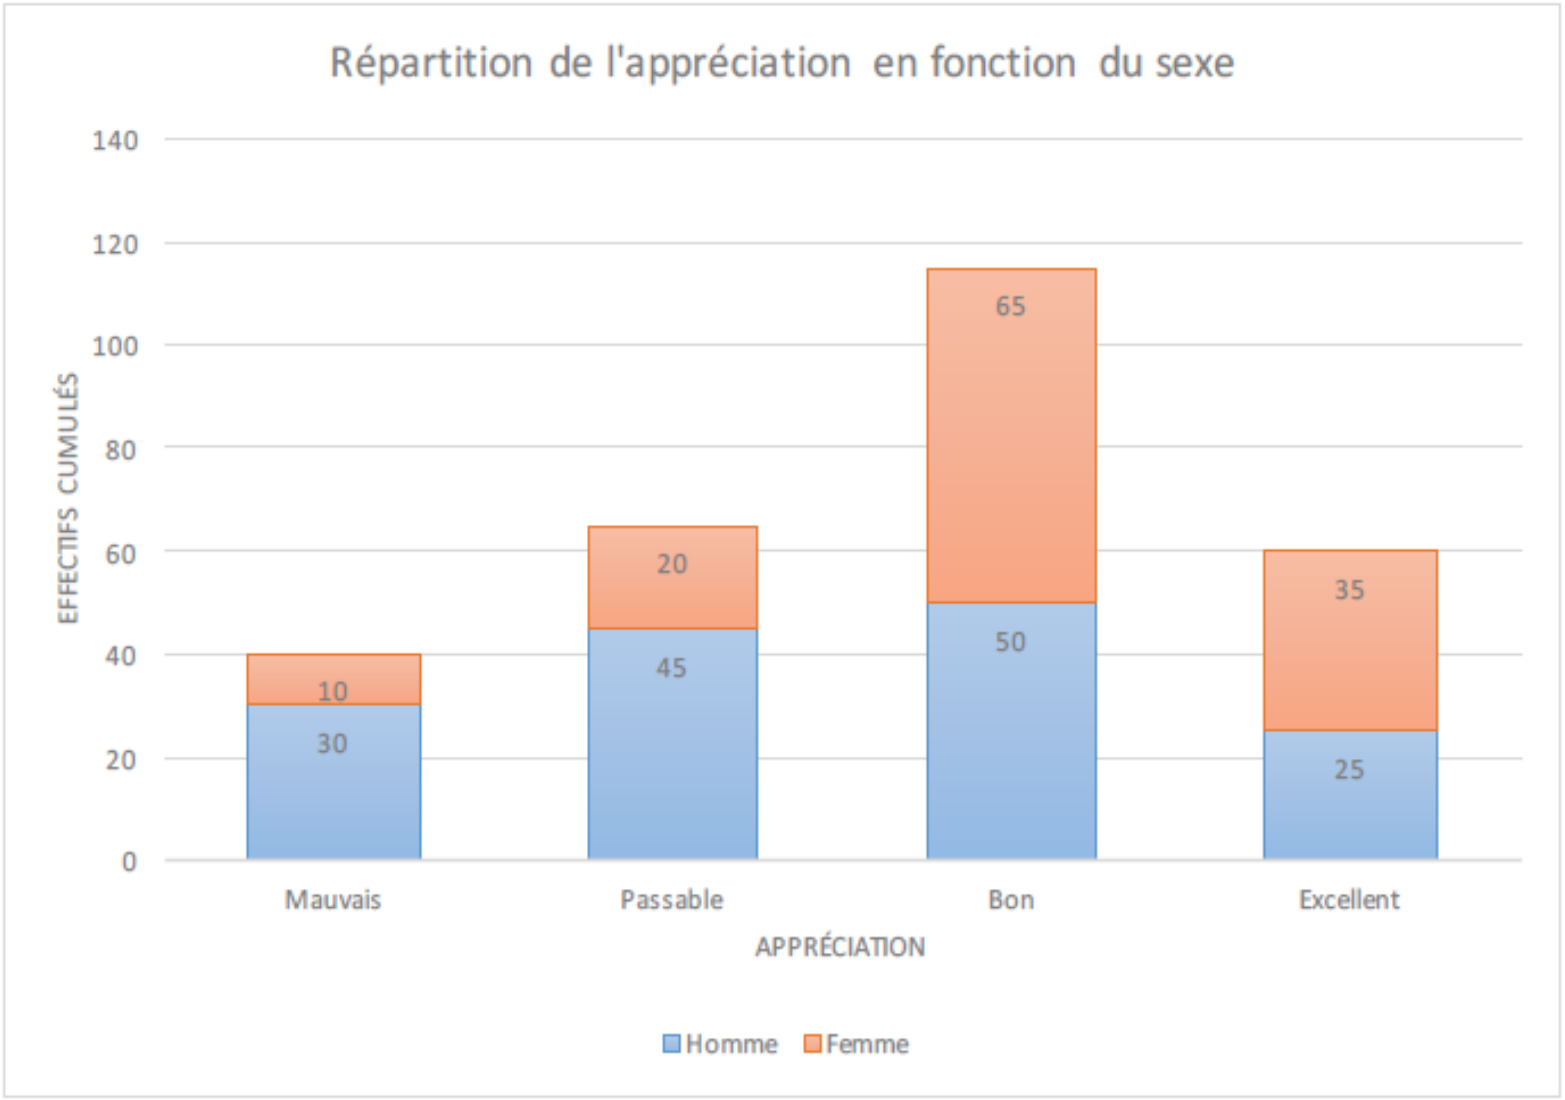
Point étudié

1. Introduction
2. Variable qualitative / Variable qualitative
   - Présentation des données
   - Représentations graphiques
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative

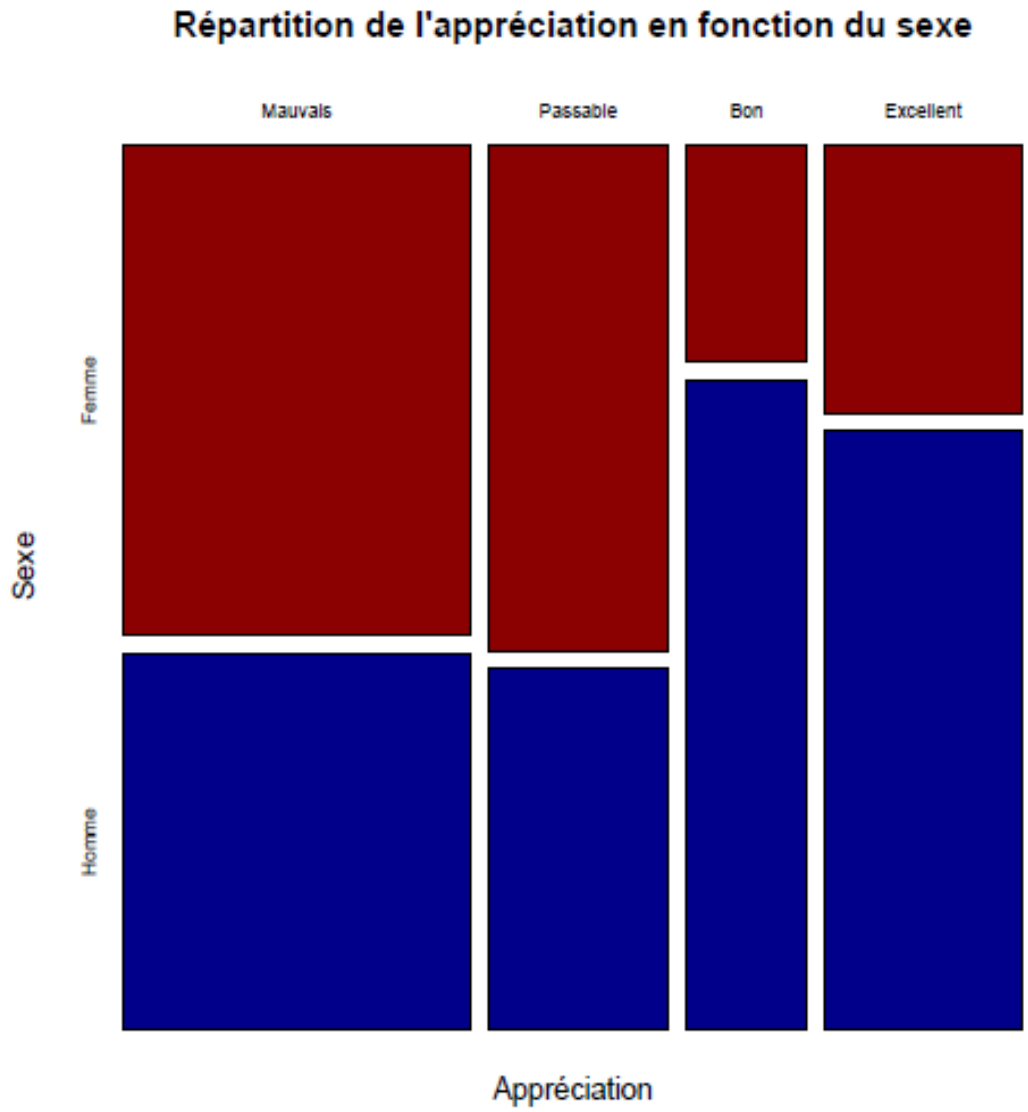
Représentations graphiques - Diagramme en barre groupé



Représentations graphiques - Diagramme en barre empilé



Représentations graphiques - Diagramme en mosaïque



Point étudié

1. Introduction
2. Variable qualitative / Variable qualitative
3. **Variable quantitative / Variable qualitative**
   - Présentation des données
   - Représentations graphiques
4. Variable quantitative / Variable quantitative

Point étudié

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
   - Présentation des données
   - Représentations graphiques
4. Variable quantitative / Variable quantitative

Présentation des données

Considérons

$$\text{Variable quantitative : } X \in \mathbb{R}$$

$$\text{Variable qualitative : } Y = \{y_1, y_2, \ldots, y_m\}$$

Variable Y	Moyenne	Ecart-type
y_1	$\bar{x}_{y_1}$	s_{y_1}
y_2	$\bar{x}_{y_2}$	s_{y_2}
$\vdots$	$\vdots$	$\vdots$
y_m	$\bar{x}_{y_m}$	s_{y_m}

Variable Y	Médiane	Q_1	Q_3
y_1	$\text{med}(x)_{y_1}$	$Q_{1(y_1)}$	$Q_{3(y_1)}$
y_2	$\text{med}(x)_{y_2}$	$Q_{1(y_2)}$	$Q_{3(y_2)}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
y_m	$\text{med}(x)_{y_m}$	$Q_{1(y_m)}$	$Q_{3(y_m)}$

Présentation des données

Exemple : croisement de l'âge en fonction du sexe

Sexe	Moyenne	Ecart-type
Homme	35	12
Femme	29	9

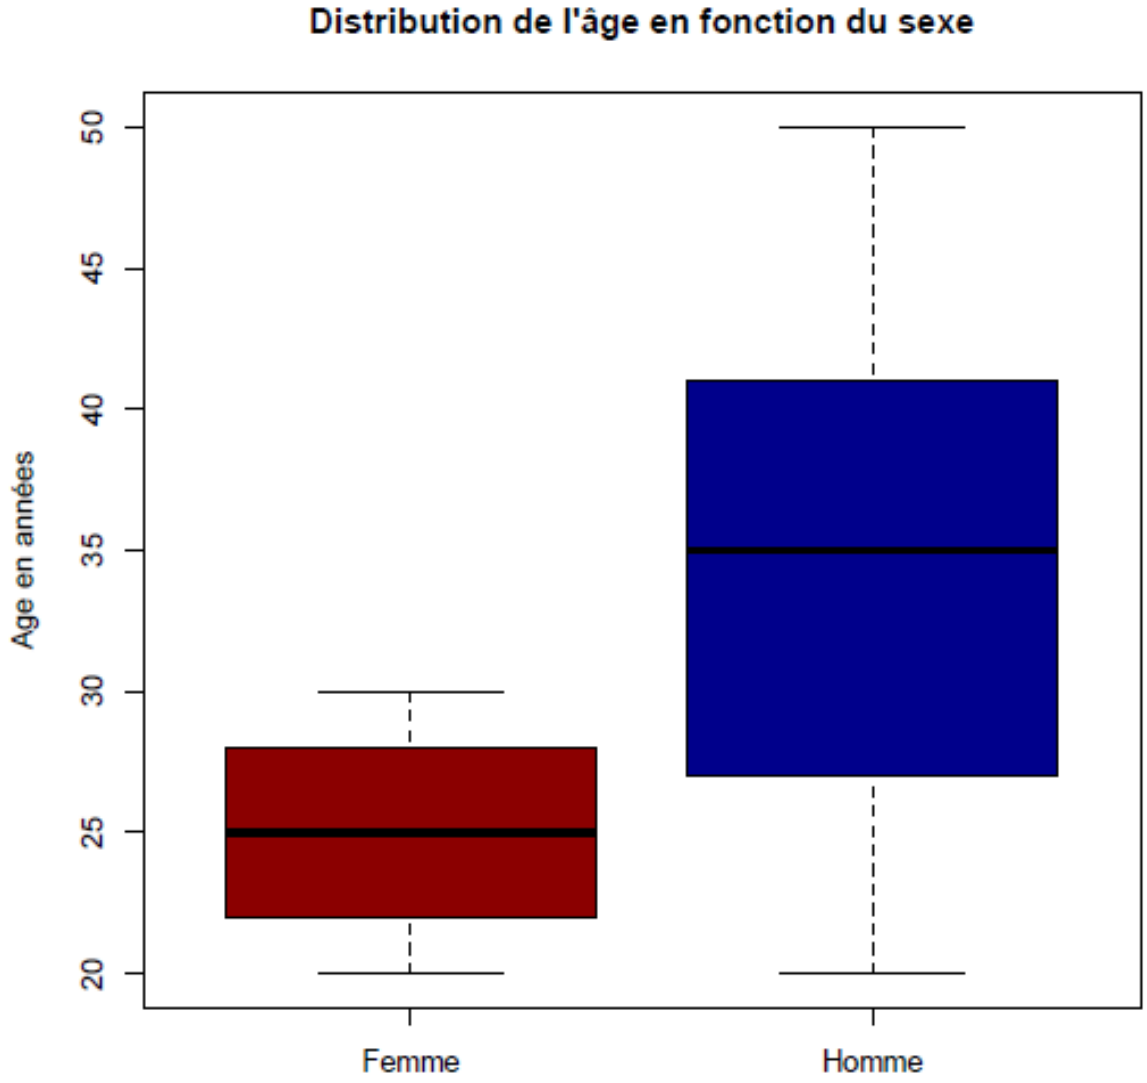
Sexe	Médiane	Q_1	Q_3
Homme	22	33	45
Femme	21	28	38

Point étudié

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
   - Présentation des données
   - Représentations graphiques
4. Variable quantitative / Variable quantitative

Représentations graphiques - Boîtes à moustaches

Croisement de l'âge et du sexe



Point étudié

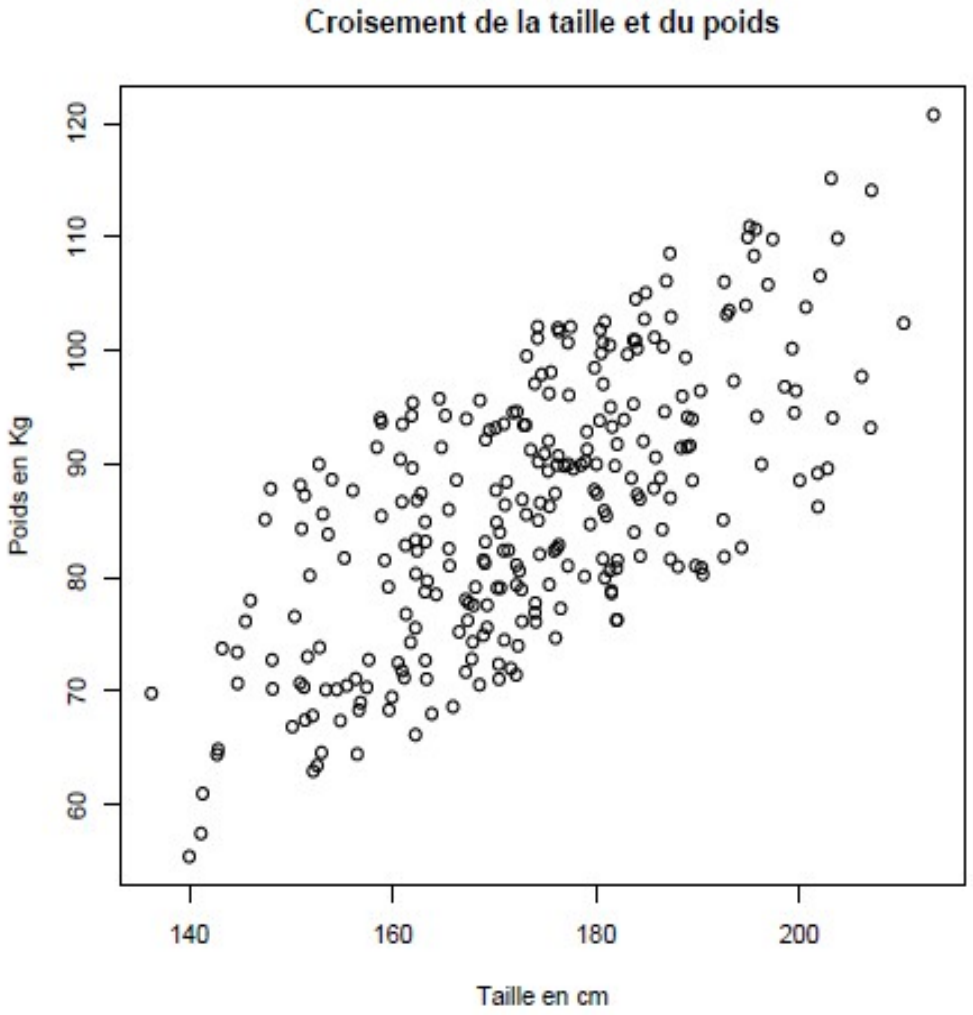
1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative
   - Représentation graphique
   - Indicateur statistique

Point étudié

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative
   - Représentation graphique
   - Indicateur statistique

Représentation graphique - Nuage de points

Croisement de la taille et du poids



Point étudié

1. Introduction
2. Variable qualitative / Variable qualitative
3. Variable quantitative / Variable qualitative
4. Variable quantitative / Variable quantitative
   - Représentation graphique
   - Indicateur statistique

Indicateur statistique - Coefficient de corrélation

Coefficient de corrélation linéaire de Pearson ($N \geqslant 30$)

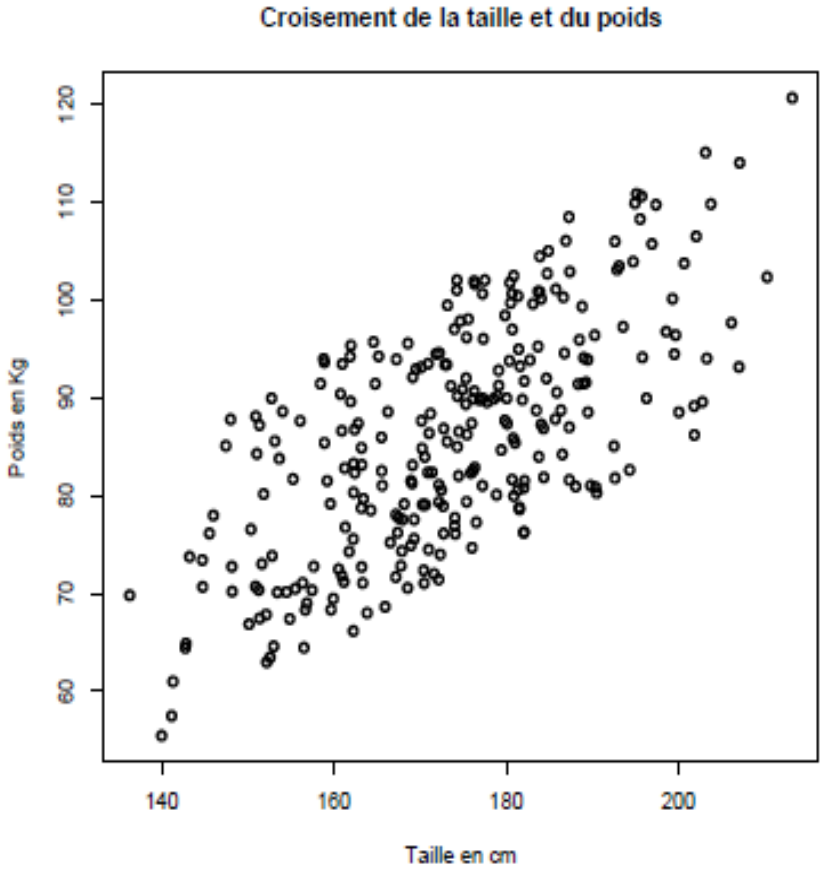
- Mesure l'intensité du lien entre X et Y
- Coefficient compris entre -1 et 1 ($R \in [1, 1]$)
- Si $R = 0$ il n'y a pas de corrélation linéaire entre X et Y. Réciproquement, si $R = |1|$, il y a une corrélation linéaire parfaite entre X et Y

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum_{i=1}^{n} \sum_{j=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n} (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^{n} (y_i - \bar{y})^2}}$$

Attention : l'absence de relation linéaire entre deux variables ne permet de conclure à l'absence de relation $\Rightarrow$ (exponentiel, puissance, ...) $\Rightarrow$ Coefficient de corrélation de Spearman.

Indicateur statistique - Coefficient de corrélation

Croisement de la taille et du poids



$$r = 0.68$$